


**METODE PENINGKATAN DETEKSI DEEPPAKE BERBASIS
ARSITEKTUR HYBRID XCEPTIONNET DAN ANALISIS ARTEFAK
DOMAIN FREKUENSI**

SKRIPSI

Oleh:

**NAOMI PRISELLA
NIM. 221111798
GIOVANNY HALIMKO
NIM. 221110058
SAMUEL ONASIS
NIM. 221110680**




**PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN
2025**

**AN ENHANCED DEEFAKE DETECTION METHOD BASED ON
HYBRID XCEPTIONNET ARCHITECTURE AND FREQUENCY-
DOMAIN ARTIFACT ANALYSIS**

FINAL RESEARCH

By:

**NAOMI PRISELLA
ID NUMBER. 221111798
GIOVANNY HALIMKO
ID NUMBER. 221110058
SAMUEL ONASIS
ID NUMBER. 221110680**



**MAJOR OF S-1 INFORMATICS ENGINEERING
FACULTY OF INFORMATICS
UNIVERSITAS MIKROSKIL
MEDAN**

LEMBARAN PENGESAHAN

**METODE PENINGKATAN DETEKSI DEEPPAKE BERBASIS
ARSITEKTUR HYBRID XCEPTIONNET DAN ANALISIS ARTEFAK
DOMAIN FREKUENSI**

SKRIPSI

Diajukan untuk Melengkapi Persyaratan Guna
Mendapatkan Gelar Sarjana
Program Studi S-1 Teknik Informatika

Oleh:

**NAOMI PRISELLA
NIM. 221111798
GIOVANNY HALIMKO
NIM. 221110058
SAMUEL ONASIS
NIM. 221110680**

Disetujui Oleh:

Dosen Pembimbing I,

Dosen Pembimbing II,

Medan, 20xx
Diketahui dan Disahkan Oleh:

Ketua Program Studi
S-1 Teknik Informatika,

HALAMAN PERNYATAAN

Saya yang membuat pernyataan ini adalah mahasiswa Program Studi S-1 Teknik Informatika Universitas Mikroskil Medan dengan identitas mahasiswa sebagai berikut:

Nama : Samuel Onasis

NIM : 221110680

Saya telah melaksanakan penelitian dan penulisan Skripsi dengan judul dan tempat penelitian sebagai berikut:

Judul Skripsi : Metode Peningkatan Deteksi Deepfake Berbasis Arsitektur Hybrid XceptionNet dan Analisis Artefak Domain Frekuensi

Tempat Penelitian :

Alamat Tempat Penelitian :

No. Telp. Tempat Penelitian :

Sehubungan dengan Skripsi tersebut, dengan ini saya menyatakan dengan sebenar-benarnya bahwa penelitian dan penulisan Skripsi tersebut merupakan hasil karya saya sendiri (tidak menyuruh orang lain yang mengerjakannya) dan semua sumber, baik yang dikutip maupun dirujuk, telah saya nyatakan dengan benar. Bila di kemudian hari ternyata terbukti bahwa bukan saya yang mengerjakannya (membuatnya), maka saya bersedia dikenakan sanksi yang telah ditetapkan oleh Universitas Mikroskil Medan, yakni pencabutan ijazah yang telah saya terima dan ijazah tersebut dinyatakan tidak sah.

Selain itu, demi pengembangan ilmu pengetahuan, saya menyetujui untuk memberikan kepada Universitas Mikroskil Medan Hak Bebas Royalti Non-eksklusif (Non-exclusive Royalty Free Right) atas Skripsi saya beserta perangkat yang ada (jika diperlukan). Dengan hak ini, Universitas Mikroskil Medan berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (database), merawat, dan mempublikasikan Skripsi saya, secara keseluruhan atau hanya sebagian atau hanya ringkasannya saja dalam bentuk format tercetak dan/atau elektronik, selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik hak cipta. Menyatakan juga bahwa saya akan mempertahankan hak eksklusif saya untuk menggunakan seluruh atau sebagian isi Skripsi saya guna pengembangan karya di masa depan, misalnya dalam bentuk artikel, buku, ataupun perangkat lunak/sistem informasi.

Demikian pernyataan ini saya perbuat dengan sungguh-sungguh, dalam keadaan sadar dan tanpa ada tekanan dari pihak manapun.

Medan, 20xx
Saya yang membuat pernyataan,

Materai Rp. 10.000,-

HALAMAN PERNYATAAN

Saya yang membuat pernyataan ini adalah mahasiswa Program Studi S-1 Teknik Informatika Universitas Mikroskil Medan dengan identitas mahasiswa sebagai berikut:

Nama : Naomi Prisella

NIM : 221111798

Saya telah melaksanakan penelitian dan penulisan Skripsi dengan judul dan tempat penelitian sebagai berikut:

Judul Skripsi : Metode Peningkatan Deteksi Deepfake Berbasis Arsitektur Hybrid XceptionNet dan Analisis Artefak Domain Frekuensi

Tempat Penelitian :

Alamat Tempat Penelitian :

No. Telp. Tempat Penelitian :

Sehubungan dengan Skripsi tersebut, dengan ini saya menyatakan dengan sebenar-benarnya bahwa penelitian dan penulisan Skripsi tersebut merupakan hasil karya saya sendiri (tidak menyuruh orang lain yang mengerjakannya) dan semua sumber, baik yang dikutip maupun dirujuk, telah saya nyatakan dengan benar. Bila di kemudian hari ternyata terbukti bahwa bukan saya yang mengerjakannya (membuatnya), maka saya bersedia dikenakan sanksi yang telah ditetapkan oleh Universitas Mikroskil Medan, yakni pencabutan ijazah yang telah saya terima dan ijazah tersebut dinyatakan tidak sah.

Selain itu, demi pengembangan ilmu pengetahuan, saya menyetujui untuk memberikan kepada Universitas Mikroskil Medan Hak Bebas Royalti Non-eksklusif (Non-exclusive Royalty Free Right) atas Skripsi saya beserta perangkat yang ada (jika diperlukan). Dengan hak ini, Universitas Mikroskil Medan berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (database), merawat, dan mempublikasikan Skripsi saya, secara keseluruhan atau hanya sebagian atau hanya ringkasannya saja dalam bentuk format tercetak dan/atau elektronik, selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik hak cipta. Menyatakan juga bahwa saya akan mempertahankan hak eksklusif saya untuk menggunakan seluruh atau sebagian isi Skripsi saya guna pengembangan karya di masa depan, misalnya dalam bentuk artikel, buku, ataupun perangkat lunak/sistem informasi.

Demikian pernyataan ini saya perbuat dengan sungguh-sungguh, dalam keadaan sadar dan tanpa ada tekanan dari pihak manapun.

Medan, 20xx
Saya yang membuat pernyataan,

Materai Rp. 10.000,-

HALAMAN PERNYATAAN

Saya yang membuat pernyataan ini adalah mahasiswa Program Studi S-1 Teknik Informatika Universitas Mikroskil Medan dengan identitas mahasiswa sebagai berikut:

Nama : Giovanny Halimko

NIM : 221110058

Saya telah melaksanakan penelitian dan penulisan Skripsi dengan judul dan tempat penelitian sebagai berikut:

Judul Skripsi : Metode Peningkatan Deteksi Deepfake Berbasis Arsitektur Hybrid XceptionNet dan Analisis Artefak Domain Frekuensi

Tempat Penelitian :

Alamat Tempat Penelitian :

No. Telp. Tempat Penelitian :

Sehubungan dengan Skripsi tersebut, dengan ini saya menyatakan dengan sebenar-benarnya bahwa penelitian dan penulisan Skripsi tersebut merupakan hasil karya saya sendiri (tidak menyuruh orang lain yang mengerjakannya) dan semua sumber, baik yang dikutip maupun dirujuk, telah saya nyatakan dengan benar. Bila di kemudian hari ternyata terbukti bahwa bukan saya yang mengerjakannya (membuatnya), maka saya bersedia dikenakan sanksi yang telah ditetapkan oleh Universitas Mikroskil Medan, yakni pencabutan ijazah yang telah saya terima dan ijazah tersebut dinyatakan tidak sah.

Selain itu, demi pengembangan ilmu pengetahuan, saya menyetujui untuk memberikan kepada Universitas Mikroskil Medan Hak Bebas Royalti Non-eksklusif (Non-exclusive Royalty Free Right) atas Skripsi saya beserta perangkat yang ada (jika diperlukan). Dengan hak ini, Universitas Mikroskil Medan berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (database), merawat, dan mempublikasikan Skripsi saya, secara keseluruhan atau hanya sebagian atau hanya ringkasannya saja dalam bentuk format tercetak dan/atau elektronik, selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik hak cipta. Menyatakan juga bahwa saya akan mempertahankan hak eksklusif saya untuk menggunakan seluruh atau sebagian isi Skripsi saya guna pengembangan karya di masa depan, misalnya dalam bentuk artikel, buku, ataupun perangkat lunak/sistem informasi.

Demikian pernyataan ini saya perbuat dengan sungguh-sungguh, dalam keadaan sadar dan tanpa ada tekanan dari pihak manapun.

Medan, 20xx
Saya yang membuat pernyataan,

Materai Rp. 10.000,-

METODE PENINGKATAN DETEKSI DEEPFAKE BERBASIS ARSITEKTUR HYBRID XCEPTIONNET DAN ANALISIS ARTEFAK DOMAIN FREKUENSI

ABSTRAK

Abstrak minimal 100 kata dan maksimal 200 kata berbahasa Indonesia, dicetak miring dengan huruf Times New Roman 12 pt, serta dibuat dalam satu paragraf. Abstrak harus jelas, deskriptif, dan harus memberikan gambaran singkat masalah yang diteliti. Abstrak meliputi alasan pemilihan topik atau pentingnya topik penelitian, metodologi penelitian, dan ringkasan hasil. Abstrak harus diakhiri dengan komentar tentang pentingnya hasil atau kesimpulan singkat.

Kata kunci: 3 s/d 5 kata kunci dicetak miring

Abstract

A minimum 100 words and maximum 200 words of abstract in English, in italics with Times New Roman 12 pt, and within one paragraph. Abstract should be clear, descriptive, and provide a brief overview of the problem studied. Abstract include reasons for the selected topics or the importance of research topics, research methodology, and a summary of the results. Abstract should end with comments about the importance of the results or brief conclusion.

Keywords: 3 to 5 keywords in italics

KATA PENGANTAR

Puji syukur saya panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat, karunia, dan bimbingan-Nya sehingga saya dapat menyelesaikan skripsi yang berjudul “*Metode Peningkatan Deteksi Deepfake Berbasis Arsitektur Hybrid XceptionNet dan Analisis Artefak Domain Frekuensi*”.

Skripsi ini dilakukan karena fenomena *deepfake* yang semakin berkembang, baik dari sisi kualitas maupun aksesibilitas. *Deepfake* bisa menyebarkan hoax, fitnah, menimbulkan pelanggaran privasi, dan merusak kepercayaan publik terhadap media. Oleh karena itu, diperlukan metode deteksi *deepfake* yang lebih *robust*, terutama terhadap generasi terbaru yang sangat menyerupai citra atau video asli.

Saya menyampaikan terima kasih yang sebesar-besarnya kepada:

1. Bapak Gunawan S.Kom., M.T.I., selaku Dosen Pembimbing I.
2. Bapak Heru Kurniawan S.Kom., M.Kom., selaku Dosen Pembimbing II.
3. Bapak Hardy S.Kom., M.SC., PH.D., selaku Rektor Universitas Mikroskil Medan.
4. Bapak Sunaryo Winardi S.Kom., M.T., selaku Dekan Fakultas Informatika Universitas Mikroskil Medan.
5. Bapak Carles Juliandy S.Kom., M.Kom., selaku Ketua Program Studi S-1 Teknik Informatika Fakultas Informatika Universitas Mikroskil Medan.
6. Orang tua dan keluarga

Medan, 20xx

Penulis,

DAFTAR ISI

1.	Abstrak.....	1
2.	KATA PENGANTAR.....	2
3.	DAFTAR ISI	3
4.	DAFTAR GAMBAR.....	9
5.	DAFTAR TABEL	10
6.	DAFTAR LAMPIRAN	11
1.	BAB I PENDAHULUAN	1
1.1	Latar Belakang.....	1
1.2	Rumusan Masalah.....	3
1.3	Tujuan.....	3
1.4	Manfaat.....	4
1.5	Ruang Lingkup	4
2.	BAB II KAJIAN LITERATUR.....	6
2.1	Deepfake.....	6
2.1.1	Ancaman Deepfake.....	6
2.1.2	Tantangan dalam Deteksi Deepfake	7
2.2	Generative Adversarial Networks (GAN)	7
2.2.1	Peran GAN dalam Pembuatan Deepfake.....	8
2.2.2	Upsampling dan Interpolasi dalam Proses Generatif Deepfake	9
2.2.3	Artefak yang Dihasilkan Proses Generatif Deepfake	10
2.3	Pendekatan Deteksi Deepfake	10
2.3.1	Deteksi Berbasis Domain Spasial.....	11
2.3.2	Deteksi Berbasis Domain Frekuensi.....	12
2.3.3	Perbandingan Domain Spasial dengan Domain Frekuensi.....	13
2.3.4	Pendekatan Hybrid Domain Spasial-Frekuensi	14
2.4	Frequency Domain Analysis	15

2.4.1	Konsep Domain Frekuensi	15
2.4.2	Transformasi <i>Fourier</i> (FFT).....	17
2.4.3	Artefak Frekuensi pada Citra Deepfake	18
2.4.4	Peran Frequency Domain Analysis dalam Deteksi Deepfake	19
2.5	Spectral Distortions dalam Deteksi Deepfake	19
2.5.1	Akar Kemunculan Spectral Distortions pada Model Generatif.....	20
2.5.2	Jenis-Jenis Spectral Distortions pada Gambar dan Video Deepfake.....	20
2.5.3	Relevansi Spectral Distortions untuk Deteksi Deepfake	21
2.5.4	Pendekatan Modern yang Memanfaatkan Spectral Distortions	22
2.5.5	Relevansi Spectral Distortions terhadap Penelitian Ini	22
2.6	Spectral Dropoff	22
2.6.1	Spectral Dropoff pada Citra Alami.....	23
2.6.2	Anomali Spectral Dropoff pada Deepfake	23
2.7	Periodic Noise dalam Domain Frekuensi	24
2.7.1	Definisi dan Karakteristik Periodic Noise	24
2.7.2	Sumber Periodic Noise pada Citra Deepfake	24
2.7.3	Peran Periodic Noise dalam Deteksi Deepfake	25
2.7.4	Contoh Pola Periodic Noise pada Spektrum Frekuensi.....	25
2.8	Warping dalam Domain Frekuensi.....	26
2.8.1	Low-Frequency Warping.....	26
2.8.2	High-Frequency Warping	26
2.9	Deep Learning	27
2.9.1	Arsitektur Dasar Deep Learning.....	27
2.9.2	Peran Deep Learning dalam Pembuatan Deepfake	28
2.9.3	Peran Deep Learning dalam Deteksi <i>Deepfake</i>	28
2.9.4	Convolution Neural Network (CNN)	29
2.10	XceptionNet.....	33

2.10.1	Arsitektur XceptionNet.....	34
2.10.2	Transfer Learning pada XceptionNet	35
2.10.3	Keunggulan XceptionNet dalam Deteksi Deepfake	35
2.11	<i>Squeeze-and-Excitation Networks</i>	36
2.11.1	Konsep <i>Channel Attention</i>	37
2.11.2	Arsitektur <i>SE Block</i>	37
2.11.3	Relevansi <i>SE Block</i> untuk Fusi <i>Multi-Domain</i>	38
2.12	FaceForensics	38
2.12.1	Struktur dan Komposisi Dataset	39
2.12.2	Karakteristik Artefak pada FaceForensics++	39
2.12.3	Alasan Pemilihan FaceForensics++ untuk Penelitian Ini	40
2.12.4	Peran FaceForensics++ dalam Sistem Hybrid XceptionNet–FFT	41
2.13	Celeb-DF	41
2.13.1	Komposisi dan Karakteristik Dataset	42
2.13.2	Peran Celeb-DF dalam Evaluasi Cross-Dataset	42
2.14	Analisis Citra	43
2.15	Analisis Video	43
2.16	Preprocessing	44
2.16.1	Tahapan dan Alur Preprocessing	45
2.16.2	Fast Fourier Transform (FFT)	46
2.17	Optimasi Model	48
2.17.1	Stochastic Gradient Descent dan Perkembangannya.....	48
2.17.2	AdamW (<i>Decoupled Weight Decay Regularization</i>)	49
2.17.3	Keunggulan AdamW untuk Deteksi Deepfake	50
2.17.4	Binary Cross-Entropy sebagai Fungsi Loss.....	50
2.18	Metrik Evaluasi Model	50
2.18.1	Confusion Matrix.....	51

2.18.2	Accuracy	51
2.18.3	Precision	52
2.18.4	Recall	52
2.18.5	F1-Score.....	52
2.18.6	AUC (Area Under the ROC Curve)	52
2.18.7	Perhitungan Metrik Evaluasi	53
2.18.8	Relevansi Metrik Evaluasi terhadap Penelitian Deepfake.....	56
2.19	Cross Dataset Generalization.....	57
2.20	<i>Cross-GAN</i> pada Deteksi <i>Deepfake</i>	58
2.20.1	Faktor Penyebab Kesulitan Generalisasi <i>Cross-GAN</i>	59
2.20.2	Indikator Evaluasi Cross-GAN.....	59
2.20.3	Pendekatan untuk Meningkatkan Generalisasi <i>Cross-GAN</i>	60
2.20.4	Relevansi <i>Cross-GAN</i> terhadap Penelitian Ini.....	61
2.21	Dasar Pemilihan Metode	61
2.21.1	Pemilihan Transformasi FFT dalam Deteksi Deepfake	62
2.21.2	Pemilihan Arsitektur XceptionNet dalam Domain Spasial	63
2.21.3	Perbandingan Akurasi dan Ketahanan Metode FFT dan XceptionNet	64
3.	BAB III TAHAPAN PELAKSANAAN	66
3.1	Kerangka Umum Penelitian.....	66
3.1.1	Jenis dan Pendekatan Penelitian	66
3.1.2	Tahapan Pelaksanaan Penelitian.....	67
3.2	Dataset dan Sumber Data	68
3.2.1	FaceForensics++ (FFPP)	69
3.2.2	Celeb-DF v2 (CDF).....	69
3.2.3	Pembagian Dataset	70
3.2.4	Variasi Ukuran Sampel.....	71
3.3	Tahapan Preprocessing Data	72

3.3.1	Ekstraksi Frame dari Video	72
3.3.2	Deteksi Wajah dan Cropping.....	73
3.3.3	Konversi Domain Frekuensi (FFT)	74
3.3.4	Augmentasi Data	79
3.4	Arsitektur Model yang Diusulkan	82
3.4.1	Model Spasial XceptionNet.....	83
3.4.2	Model Frekuensi FreqCNN	86
3.4.3	Model <i>Hybrid</i> HybridTwoBranch (<i>Late Fusion</i>)	89
3.4.4	Perbandingan Arsitektur Model.....	92
3.5	Strategi Pelatihan Model	93
3.5.1	<i>Transfer Learning</i> dan <i>Backbone Freezing</i>	94
3.5.2	<i>Differential Learning Rate</i>	94
3.5.3	Penjadwalan <i>Learning Rate</i>	95
3.5.4	Fungsi <i>Loss</i> , BCEWithLogitsLoss dengan <i>Label Smoothing</i>	96
3.5.5	Optimisasi AdamW dengan <i>Gradient Accumulation</i>	97
3.5.6	<i>Gradient Clipping</i>	97
3.5.7	<i>Mixed Precision Training</i> (AMP).....	98
3.5.8	<i>Early Stopping</i>	98
3.5.9	Seleksi Model Terbaik.....	99
3.6	Desain Eksperimen	100
3.6.1	Matriks Eksperimen.....	100
3.6.2	Evaluasi <i>In-Dataset</i>	100
3.6.3	Evaluasi <i>Cross-Dataset</i>	101
3.6.4	Variabel Penelitian	101
3.7	Metode Evaluasi Model.....	102
3.7.1	Generalization Drop	102
3.7.2	Contoh Perhitungan Metrik	102

3.8	Analisis Sistem	103
3.8.1	Kebutuhan Perangkat Keras	103
3.8.2	Kebutuhan Perangkat Lunak	103
3.8.3	Konfigurasi dan Orkestrasi <i>Pipeline</i>	104
3.8.4	Keluaran Sistem.....	105
4.	BAB IV HASIL DAN PEMBAHASAN.....	106
4.1	Hasil.....	106
4.2	Pembahasan	106
5.	BAB V PENUTUP	107
6.	DAFTAR PUSTAKA.....	108

DAFTAR GAMBAR

Gambar 2.1 Distribusi Komponen <i>Low-Frequency</i> dan <i>High-Frequency</i>	16
Gambar 2.2 Representasi Domain Frekuensi [30].....	17
Gambar 2.3 Arsitektur XceptionNet [6]	34
Gambar 3.1 Flowchart Utama <i>Pipeline</i> Penelitian	68
Gambar 3.2 Contoh <i>Frame Real</i> dan <i>Fake</i> dari Dataset FaceForensics++ dan Celeb-DF..	71
Gambar 3.3 <i>Pseudocode</i> ekstraksi frame dari video	73
Gambar 3.4 Tahapan augmentasi visual pada cabang spasial (RGB)	80
Gambar 3.5 Contoh Penerapan <i>Spectral Band Masking</i> pada Peta <i>Magnitude</i> FFT.....	81
Gambar 3.6 Perbandingan Peta <i>Magnitude</i> FFT: <i>Frame Real</i> vs <i>Fake</i>	82
Gambar 3.7 Diagram Arsitektur XceptionNet [6]	83
Gambar 3.8 Diagram Arsitektur FreqCNN	86
Gambar 3.9 Arsitektur FreqBlock dengan Koneksi <i>Residual</i>	87
Gambar 3.10 Diagram Arsitektur HybridTwoBranch (<i>Late Fusion</i>)	89
Gambar 3.11 Kurva Penjadwalan <i>Learning Rate</i> (<i>Warmup Cosine Decay</i>)	95

DAFTAR TABEL

Tabel 1.1 Komposisi total <i>dataset</i> yang digunakan.....	5
Tabel 2.1 Perbandingan Pendekatan Domain Spasial dan Domain Frekuensi	13
Tabel 2.2 Komponen dalam Domain Frekuensi [8, 9]	16
Tabel 2.3 Karakteristik Artefak Frekuensi pada Deepfake [8, 9, 11, 16].....	18
Tabel 2.4 Tahapan Preprocessing.....	45
Tabel 2.5 Struktur Confusion Matrix	51
Tabel 2.6 Ringkasan Hasil Perhitungan Metrik.....	55
Tabel 2.7 Perbandingan tiga metode transformasi frekuensi [28].....	62
Tabel 2.8 Perbandingan performa model CNN [3, 4, 13, 7]	63
Tabel 2.9 Ringkasan Perbandingan FFT vs XceptionNet [3, 8, 9, 13, 16, 7].....	65
Tabel 3.1 Komposisi total <i>dataset</i> yang digunakan.....	70
Tabel 3.2 Pembagian Dataset	70
Tabel 3.3 Variasi Ukuran Sampel per Dataset	71
Tabel 3.4 Contoh Matriks <i>Grayscale</i> 4x4	76
Tabel 3.5 Contoh Perhitungan <i>Magnitude</i> dan <i>Log Scaling</i>	78
Tabel 3.6 Arsitektur Layer-by-Layer FreqCNN (<i>depth</i> = 5, <i>base_channels</i> = 64)	87
Tabel 3.7 Perbandingan Tiga Arsitektur Model	92
Tabel 3.8 Dimensi Fitur per Komponen Model <i>Hybrid</i>	93
Tabel 3.9 <i>Learning Rate</i> per Kelompok Parameter	94
Tabel 3.10 Ringkasan <i>Hyperparameter</i> Penelitian.....	99
Tabel 3.11 Matriks Eksperimen.....	100
Tabel 3.12 Variabel Penelitian	101
Tabel 3.13 Contoh <i>Confusion Matrix</i>	102
Tabel 3.14 Perhitungan Metrik Evaluasi	102
Tabel 3.15 Kebutuhan Perangkat Keras	103
Tabel 3.16 Kebutuhan Perangkat Lunak	104

DAFTAR LAMPIRAN

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan *Generative Adversarial Networks* (GAN) telah memungkinkan terciptanya citra dan video sintetis yang sulit dibedakan dari rekaman asli, dan teknologi inilah yang melahirkan istilah *deepfake*, yaitu konten visual atau audio yang dimanipulasi sedemikian rupa sehingga menampilkan adegan atau ucapan yang tidak pernah terjadi. Meskipun awalnya dikembangkan untuk hiburan dan riset sintesis media, *deepfake* kini menjadi ancaman serius pada beberapa tingkatan. Pada tingkat geopolitik, teknologi ini dipakai sebagai instrumen disinformasi dan propaganda [1]. Pada tingkat individual, 96% video *deepfake* yang beredar global berbentuk pornografi non-konsensual yang sebagian besar menargetkan perempuan, menimbulkan kerugian reputasi, psikologis, dan hukum yang nyata [2]. Skala dan kecepatan distribusi konten ini menjadikan deteksi otomatis *deepfake* bukan sekadar tantangan riset, melainkan kebutuhan forensik digital yang mendesak.

Berbagai metode telah dikembangkan untuk mendeteksi *deepfake*, salah satunya berbasis domain spasial yang menganalisis informasi visual langsung dari citra atau *frame* video. Beberapa arsitektur yang terbukti efektif di domain ini antara lain *MesoNet*, *ResNet*, dan *XceptionNet* [3, 4]. *MesoNet* dirancang untuk mendeteksi artefak lokal seperti batas *blending* dan perbedaan warna pada wajah hasil manipulasi, namun memiliki keterbatasan pada citra resolusi tinggi [4]. *ResNet-50* memperkenalkan *residual learning* untuk merepresentasikan fitur spasial yang lebih dalam, dan dilaporkan mencapai akurasi di atas 90% pada FaceForensics++ namun turun signifikan ketika diuji lintas dataset [3, 5]. *XceptionNet* (*Extreme Inception Net*) menjadi *baseline* domain spasial yang paling banyak dipakai karena *depthwise separable convolution* memberikan efisiensi komputasi tanpa mengorbankan akurasi, dan dilaporkan mencapai akurasi deteksi 99,26% pada FaceForensics++ tanpa kompresi [6, 7]. Namun, akurasi tinggi ini tidak konsisten pada pengujian lintas dataset, yang mengindikasikan ketergantungan model terhadap artefak visual khas dataset pelatihan.

Namun, pendekatan berbasis spasial memiliki kelemahan yang fundamental, yaitu fokusnya yang hanya mendeteksi pada artefak visual yang tampak, bukan pada pola algoritmik yang dihasilkan selama proses generatif. Penyebab utama dari kegagalan generalisasi model *deepfake* biasanya terletak pada sifat fundamental artefak, yang bersifat algoritmik, bukan visual [8]. Artefak biasanya muncul dari kelemahan dalam operasi

upsampling, yang digunakan oleh GAN untuk meningkatkan resolusi citra, yang cenderung menciptakan pola *noise* atau *spectral distortion* yang tidak alami, dan biasanya dikenal sebagai *GAN fingerprints*, yang tidak terlihat jelas dalam *spatial domain* [9].

Untuk mengatasi keterbatasan tersebut, riset deteksi *deepfake* bergeser ke domain frekuensi. Pendekatan berbasis *Fast Fourier Transform* (FFT) memanfaatkan asimetri spektral pada citra GAN dan terbukti dapat membedakan citra sintetis dari citra natural meski manipulasi visualnya tidak terlihat di domain spasial [8]. Pendekatan berbasis *Discrete Cosine Transform* (DCT) bekerja pada koefisien blok dan menyingkapkan anomali pada band frekuensi menengah yang konsisten antar-arsitektur GAN [10]. Sementara itu, pembelajaran adaptif pada representasi frekuensi seperti *Frequency-aware Clues* [11] dan *Frequency-Aware Deepfake Detection* berbasis spektrum [12] meningkatkan kemampuan generalisasi terhadap teknik sintesis baru dan citra terkompresi. Konvergensi ketiga pendekatan ini menunjukkan bahwa jejak generatif paling stabil bukan pada piksel, melainkan pada distribusi spektralnya.

Sebagai besar *generator deepfake* gagal mereplikasi distribusi spektral citra natural pada frekuensi tinggi. Pengukuran *azimuthal frequency profile* memperlihatkan kelebihan energi konsisten pada *frame* sintetis di empat arsitektur GAN yang diuji [8], dan FDA dapat mendeteksi perbedaan tersebut bahkan ketika manipulasi visual tampak realistis di domain spasial [8]. Studi terkini mulai mengombinasikan deteksi spasial dengan pendekatan frekuensi. *Alam et al.* menunjukkan bahwa penggabungan domain spasial dan domain frekuensi dapat meningkatkan kemampuan generalisasi dan ketahanan terhadap kompresi [13]. Temuan-temuan ini memperkuat pentingnya integrasi dua domain analisis untuk menciptakan detektor *deepfake* yang lebih *robust*.

Di luar laboratorium, detektor *deepfake* harus menghadapi distribusi data yang sangat berbeda dari data pelatihan: generator baru bermunculan setiap tahun, kompresi platform sosial bervariasi, dan teknik pasca-pemrosesan adversarial dipakai untuk menyamarkan jejak. Studi sistematis melaporkan penurunan AUC 10 hingga 20 poin ketika detektor berbasis CNN spasial dipindahkan dari satu dataset ke dataset lain [14, 15]. Karena itu, kemampuan generalisasi lintas dataset, bukan akurasi *in-domain*, adalah metrik yang paling relevan untuk menilai kelayakan deteksi *deepfake* di dunia nyata, dan menjadi fokus utama penelitian ini.

Studi awal hibridisasi domain spasial dan frekuensi telah menunjukkan potensi peningkatan generalisasi. *SpecXNet* menggabungkan cabang spasial *XceptionNet* dengan cabang frekuensi untuk meningkatkan ketahanan deteksi terhadap berbagai manipulasi [13].

FSBI memanfaatkan *self-blended image* yang ditingkatkan frekuensi untuk memperkuat generalisasi lintas dataset [16]. *Frequency-Domain Masking* mengintegrasikan informasi spasial dan frekuensi melalui mekanisme adaptif [17]. Studi-studi ini berhasil membuktikan bahwa fusi dua domain bermanfaat, tetapi sebagian besar masih dioptimalkan untuk performa *in-domain* pada FaceForensics++, dan belum mengevaluasi secara sistematis fusi *late* dan *gating* sebagai mekanisme spesifik untuk meningkatkan *robustness* lintas dataset.

Penelitian ini mengisi celah tersebut dengan mengusulkan arsitektur *hybrid XceptionNet* dan FFT dengan *late fusion* dan *Squeeze-and-Excitation gating* yang dioptimalkan untuk generalisasi lintas dataset. Berbeda dari pekerjaan sebelumnya yang berfokus pada *in-domain accuracy*, penelitian ini secara eksplisit mengevaluasi skenario FFPP ke CDF dan CDF ke FFPP untuk mengukur seberapa besar fitur frekuensi mampu menahan *performance drop* yang lazim terjadi pada detektor spasial murni.

1.2 Rumusan Masalah

Berdasarkan latar belakang masalah yang menggarisbawahi kegagalan detektor spasial murni dan potensi yang belum dimanfaatkan dari FDA, permasalahan utama dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Se jauh mana detektor *deepfake* berbasis domain spasial murni (*XceptionNet*) mengalami penurunan performa ketika diuji pada **video sintetis** dari dataset yang berbeda dengan data pelatihannya?
2. Se jauh mana penambahan analisis domain frekuensi (FFT) ke dalam arsitektur *XceptionNet* dapat memperkecil penurunan tersebut?
3. Seberapa besar kontribusi masing-masing komponen (fitur spasial vs fitur frekuensi) terhadap akurasi, presisi, *recall*, dan AUC pada pengujian *in-dataset* maupun *cross-dataset*?

1.3 Tujuan

Tujuan yang hendak dicapai pada penelitian ini adalah:

1. Mengimplementasikan arsitektur hybrid *XceptionNet*–FFT dengan *late fusion* dan *SE gating* untuk deteksi *deepfake* tingkat *frame* video.
2. Melakukan **ablation study** (spasial-saja vs frekuensi-saja vs hybrid) untuk memisahkan kontribusi masing-masing domain.

3. Mengevaluasi generalisasi model pada skenario *in-dataset* (FFPP→FFPP, CDF→CDF) dan *cross-dataset* (FFPP→CDF, CDF→FFPP) menggunakan akurasi, presisi, *recall*, dan AUC.

1.4 Manfaat

Penelitian ini diharapkan memberikan kontribusi terhadap komunitas riset, serta diharapkan memberikan manfaat sebagai berikut:

1. Manfaat Akademik: Memberikan kontribusi ilmiah berupa evaluasi sistematis terhadap kontribusi fitur frekuensi dalam arsitektur *hybrid* deteksi *deepfake*.
2. Manfaat Teknologi: Menyediakan rancangan arsitektur dan pipeline reproduktif yang dapat dijadikan acuan oleh peneliti lain yang mengembangkan detektor hibrida domain spasial–frekuensi.
3. Manfaat Sosial: Mendukung upaya mitigasi penyalahgunaan *deepfake* (misinformasi, *deepfake porn*, propaganda politik) dengan menyediakan dasar metodologis yang dapat dievaluasi oleh lembaga forensik digital.
4. Manfaat Praktis: Memberikan *baseline cross-dataset* yang dapat dipakai pengembang sistem verifikasi konten sebagai pembandingan untuk arsitektur deteksi lain.

1.5 Ruang Lingkup

Ruang lingkup penelitian ini difokuskan pada pengembangan dan evaluasi model deteksi *deepfake* berbasis *hybrid* yang menggabungkan analisis domain spasial dan domain frekuensi. Penelitian ini hanya mencakup tahap perancangan, implementasi, dan evaluasi model deteksi menggunakan dataset publik, tanpa membahas aspek produksi video *deepfake* atau sistem penyebarannya.

Penelitian ini difokuskan pada:

1. Cakupan Data: Penelitian menggunakan **video** dari dua dataset publik yang kemudian diekstraksi menjadi **frame citra** untuk diproses model:
 - a. **FaceForensics++** [7], repositori <https://github.com/ondyari/FaceForensics>, kompresi *high-quality* (c23), dengan empat metode manipulasi (*Deepfakes*, *Face2Face*, *FaceSwap*, *NeuralTextures*).
 - b. **Celeb-DF v2** [18], repositori <https://github.com/yuezunli/celeb-deepfakeforensics>, kategori *celebrity face-swap*.

Pengambilan sampel dilakukan dengan rasio 50:50 antara kelas asli dan kelas manipulasi, dan pemisahan *train*, *val*, *test* dilakukan pada level video untuk menghindari kebocoran *frame*. Penelitian tidak mencakup deteksi manipulasi audio atau *text-based deepfake*.

2. Cakupan Metode: Analisis frekuensi dilakukan menggunakan metode FFT untuk mengekstraksi fitur spektral yang merepresentasikan artefak sintesis. Model spasial yang digunakan terbatas pada arsitektur *XceptionNet*.
3. Cakupan Evaluasi: Evaluasi kinerja model dilakukan berdasarkan metrik *accuracy*, *precision*, *recall*, dan *AUC (Area Under Curve)*, serta pengujian *cross-dataset generalization* untuk mengukur ketahanan model terhadap variasi sumber data.
4. Cakupan Sistem: Implementasi dilakukan dalam lingkungan eksperimental, dengan keterbatasan komputasi dan waktu pelatihan tertentu. Penelitian tidak terfokus pada optimasi waktu inferensi secara mendalam.

Tabel 1.1 Komposisi total *dataset* yang digunakan

Dataset	Real videos	Fake videos	Total frame (~)	Sumber
<i>FaceForensics++</i> (n=1000, c23)	500	500	~50.000	[7]
<i>Celeb-DF v2</i> (n=750)	375	375	~37.500	[18]

Dengan batasan ini, penelitian diarahkan untuk menjaga fokus pada validasi efektivitas integrasi antara FDA ke dalam arsitektur *XceptionNet* untuk meningkatkan kemampuan generalisasi serta ketahanan, dan akurasi dalam mendeteksi *deepfake*.

BAB II

KAJIAN LITERATUR

2.1 Deepfake

Istilah *deepfake* berasal dari gabungan dua kata, yaitu *deep learning* dan *fake*. Istilah ini merujuk pada konten multimedia, baik berupa gambar, video maupun audio, yang telah dimodifikasi secara visual, atau auditori dengan menggunakan teknik *deep learning* hingga tampak sangat realisti dan menyerupai aslinya [14]. Secara teknis, *deepfake* memanfaatkan model generatif seperti GAN atau arsitektur *encoder-decoder* untuk memodifikasi konten sintesis seperti *face swapping* atau *face reenactment*.

Secara umum, teknologi *deepfake* dikembangkan berdasarkan jaringan saraf tiruan (*neural network*). Dalam prosesnya, model dilatih untuk mempelajari pola, ekspresi, serta pergerakan wajah manusia, sehingga wajah seseorang pada suatu video dapat digantikan dengan wajah orang lain, sehingga menghasilkan video yang tampak realistis dan meyakinkan [2]. Dengan kemampuan tersebut, *deepfake* menjadi salah satu penerapan *deep learning* yang paling menonjol dalam bidang sintesis media [19].

Tujuan utama dari pengembangan *deepfake* pada awalnya adalah untuk penelitian dan pengembangan teknologi sintesis media yang realistis, bukan untuk penipuan atau penyebaran informasi palsu. Teknologi ini dirancang untuk mengeksplorasi kemampuan dari *neural network* dalam melakukan rekonstruksi ekspresi wajah, pergerakan bibir, serta sinkronisasi audio-visual dalam konteks hiburan, industri film, *lip-sync translation*, dan *virtual reality* [19]. Selain itu, *deepfake* juga dimanfaatkan dalam ranah ilmiah seperti pelatihan model *face recognition*, penciptaan data sintetik untuk meningkatkan generalisasi model, hingga simulasi terhadap perilaku manusia dalam bidang psikologi, dan forensik digital [14, 19].

Dalam konteks penelitian ini, istilah *deepfake* merujuk secara khusus pada manipulasi wajah pada citra dan frame video yang dihasilkan menggunakan model generatif berbasis *deep learning*, seperti GAN. Fokus penelitian ditujukan pada pendeteksian artefak visual dan spektral pada gambar serta frame video, bukan pada manipulasi audio atau bentuk media sintesis lainnya.

2.1.1 Ancaman Deepfake

Deepfake membawa berbagai potensi penyalahgunaan yang serius, mulai dari penyebaran misinformasi, dan propaganda politik, hingga penipuan, dan perusakan reputasi

individu melalui konten palsu [14]. Salah satu bentuk penyalahgunaan yang paling meresahkan adalah *deepfake porn*, yakni video pornografi hasil rekayasa yang menampilkan wajah korban, seolah-olah korban terlibat dalam adegan tersebut. Studi global menunjukkan bahwa 96% dari seluruh video *deepfake* yang beredar di internet, berjenis pornografi, dan menargetkan perempuan [2]. Kondisi ini jelas mengancam privasi, dan kehormatan korban, serta dapat menimbulkan trauma dan kerugian sosial.

Selain ancaman terhadap individu, *deepfake* juga berdampak luas pada aspek sosial, politik, dan keamanan digital. Dalam konteks sosial, *deepfake* dapat menurunkan tingkat kepercayaan publik terhadap media visual, dan memperburuk fenomena *information disorder* di masyarakat [14, 15]. Pada bidang politik, teknologi ini dapat dimanfaatkan untuk menciptakan konten manipulatif yang dapat mengubah persepsi publik terhadap tokoh, atau peristiwa, dan berpotensi digunakan sebagai alat propaganda dan disinformasi terarah [1, 14].

2.1.2 Tantangan dalam Deteksi Deepfake

Seiring berkembangnya teknologi generatif seperti GAN, *deepfake* semakin sulit dibedakan dari konten asli. Kualitas manipulasi yang semakin sempurna membuat konten palsu nyaris tidak dapat dideteksi baik oleh pengamat manusia, maupun oleh sistem pendeteksi konvensional yang berbasis fitur spasial [14]. Oleh karena itu, kemampuan untuk mendeteksi dan memverifikasi keaslian konten digital menjadi sangat krusial dalam menjaga integritas informasi serta melindungi keamanan dan kepercayaan publik di era media generatif.

Ancaman tersebut menunjukkan bahwa teknik deteksi konvensional yang hanya mengandalkan informasi spasial tidak lagi memadai untuk menghadapi kualitas *deepfake* modern. Banyak manipulasi visual kini dibuat sangat halus sehingga artefaknya tidak tampak jelas pada domain spasial. Oleh karena itu, diperlukan pendekatan pendeteksian yang lebih komprehensif dengan memanfaatkan informasi frekuensi untuk mengidentifikasi jejak matematis proses generatif, sehingga sistem deteksi menjadi lebih *robust* terhadap berbagai jenis teknik *deepfake* yang terus berkembang.

2.2 Generative Adversarial Networks (GAN)

Generative Adversarial Networks (GAN) adalah model *deep learning* yang diperkenalkan pada tahun 2014 yang terdiri dari dua jaringan saraf, generator dan

diskriminator. Generator berfungsi untuk menghasilkan data palsu yang menyerupai data asli (misalnya, gambar wajah sintetis), sedangkan diskriminator berfungsi membedakan apakah *input* yang diberikan merupakan data asli atau hasil dari generator. Keduanya dilatih secara bersamaan, dimana generator berusaha untuk “menipu” diskriminator dengan menghasilkan output yang semakin realistis, sementara diskriminator berusaha semakin mahir dalam mendeteksi mana data yang palsu.

Dalam proses pelatihan *adversarial* ini, generator secara bertahap belajar pola-pola dari data latih dan meningkatkan kualitas keluarannya hingga sedemikian rupa sehingga diskriminator tidak lagi mampu membedakan data sintetis dengan data asli. Pada saat generator dan diskriminator mencapai keseimbangan, *output* yang dihasilkan generator memiliki kemiripan statistik dan visual yang tinggi dengan data asli. Biasanya setelah proses *training* selesai, komponen diskriminator dapat diabaikan, dan generator digunakan sendiri untuk menghasilkan data baru yang realistis. Arsitektur ini yang membuat GAN sangat efektif dalam memodelkan distribusi data dan menciptakan sampel-sampel baru yang autentik [15, 20].

2.2.1 Peran GAN dalam Pembuatan Deepfake

Teknologi *deepfake* umumnya mengacu pada pembuatan media sintetis terutama *swap* wajah pada gambar atau video dengan tingkat kemiripan yang tinggi terhadap aslinya. GAN telah menjadi alat utama dalam banyak metode *deepfake* modern. Dalam konteks ini, GAN dimanfaatkan untuk menghasilkan wajah hasil pertukaran (*face swap*) atau wajah sintetis lainnya yang tampak *photo-realistic* dan sulit dibedakan dari wajah asli oleh mata manusia. Pada teknik *face swapping* berbasis GAN, model generator mempelajari ciri-ciri wajah target dan mencoba menggabungkan wajah sumber ke dalam wajah target sehingga sulit terdeteksi perbedaan, sementara diskriminator berperan mengidentifikasi bagian tidak asli pada hasil gabungan tersebut. Proses *adversarial* ini memastikan hasil *deepfake* memiliki detail visual yang konsisten (misalnya pencahayaan, pose, ekspresi) dan seminimal mungkin artefak yang mencurigakan [15].

Metode *deepfake* umumnya menggunakan arsitektur *autoencoder* pada dua wajah (sumber dan target) untuk menukar wajah sumber dan target, lalu ditingkatkan dengan komponen *adversarial* dengan GAN agar hasilnya lebih halus dan nyata. Penerapan GAN dalam *deepfake* memungkinkan generator belajar memadukan wajah ke tubuh target secara rapi dan sulit terdeteksi, sementara diskriminator memastikan video atau gambar asli hasil

manipulasi tampak alami. Pendekatan GAN ini digunakan dalam berbagai perangkat lunak *deepfake* modern untuk menghasilkan video swap wajah yang sulit dibedakan dari video asli [1, 15].

Pada proses manipulasi citra, GAN menggunakan operasi *upsampling* untuk meningkatkan resolusi dari citra berukuran kecil menjadi citra beresolusi tinggi. Proses ini sering kali dilakukan dengan metode interpolasi, yang secara matematis menyisipkan nilai nol dalam sinyal. Langkah ini menyebabkan replikasi spektrum frekuensi dari citra sumber ke area frekuensi tinggi yang baru, menghasilkan pola distorsi khas atau *spectral artifacts* [8, 9]. Artefak ini tidak mudah dikenali secara visual di domain spasial, namun dapat diidentifikasi pada domain frekuensi menggunakan transformasi seperti FFT. Dengan demikian, artefak yang muncul akibat proses pembangkitan GAN menjadi dasar dari metode deteksi *deepfake* berbasis analisis frekuensi [9].

2.2.2 Upsampling dan Interpolasi dalam Proses Generatif Deepfake

Upsampling merupakan proses meningkatkan resolusi citra atau *feature map* pada generator GAN dengan menambah jumlah *pixel* baru. Teknik umum yang digunakan meliputi *nearest-neighbor upsampling*, *bilinear interpolation*, dan *transposed convolution*, yang masing-masing memiliki karakteristik dan kelemahan tersendiri [21, 22]. Pada arsitektur GAN, khususnya saat menggunakan *transposed convolution*, proses *upsampling* dapat menghasilkan pola artefak periodik seperti *checkerboard patterns* karena distribusi kernel yang tidak merata [21]. Selain itu, berbagai studi menunjukkan bahwa citra hasil GAN cenderung memiliki bias frekuensi tinggi yang tidak muncul pada citra natural, sehingga memunculkan pola anomali pada domain frekuensi [8].

Interpolasi adalah teknik estimasi nilai *pixel* baru berdasarkan *pixel* di sekitarnya, dan digunakan dalam berbagai proses manipulasi citra pada *deepfake*, termasuk *face warping*, *resizing*, dan tahap *upsampling* pada GAN. Metode seperti *nearest*, *bilinear*, dan *bicubic interpolation* menghasilkan karakteristik frekuensi yang berbeda, yang pada citra *deepfake* sering meninggalkan distribusi frekuensi tinggi.

Berbagai studi, menunjukkan bahwa proses *upsampling* pada GAN menjadi sumber utama pola artefak *high-frequency* yang tidak muncul pada citra natural. Artefak inilah yang dapat dimanfaatkan oleh metode deteksi berbasis domain frekuensi seperti *Fast Fourier Transform* (FFT) [8, 9].

2.2.3 Artefak yang Dihasilkan Proses Generatif Deepfake

Proses generatif pada *deepfake*, khususnya yang berbasis GAN, menghasilkan sejumlah artefak khas yang menjadi dasar bagi metode deteksi. Artefak-artefak ini muncul karena keterbatasan model generatif dalam mereplikasi seluruh karakteristik statistik citra alami, baik pada domain spasial maupun domain frekuensi [8, 9].

Secara umum, artefak yang dihasilkan proses generatif *deepfake* dapat diklasifikasikan ke dalam dua kategori utama:

1. Artefak Domain Spasial

Artefak spasial merupakan anomali visual yang muncul langsung pada citra atau *frame* video hasil manipulasi. Jenis artefak ini meliputi ketidaksesuaian tekstur kulit antara wajah sintetis dan area sekitarnya, batas *blending* yang tidak halus pada tepi wajah, distorsi geometrik pada area mata, hidung, dan mulut, serta inkonsistensi pencahayaan dan bayangan akibat proses *face warping* [4]. Meskipun artefak spasial dapat dideteksi oleh model CNN seperti *XceptionNet*, kualitas manipulasi yang semakin tinggi pada GAN modern membuat artefak ini semakin sulit diamati [14].

2. Artefak Domain Frekuensi

Artefak frekuensi muncul akibat ketidakmampuan model generatif dalam mereproduksi distribusi spektral alami citra. Jenis artefak ini meliputi distribusi energi frekuensi tinggi yang berlebihan akibat proses *upsampling*, pola *checkerboard* yang dihasilkan oleh *transposed convolution*, *periodic noise* berupa titik-titik intensitas berulang pada spektrum FFT, serta *spectral dropoff* yang tidak konsisten dengan pola penurunan energi alami [8, 9, 21]. Artefak frekuensi bersifat algoritmik dan lebih stabil dibanding artefak spasial, sehingga menjadi dasar penting bagi metode deteksi berbasis FDA [11].

Kedua kategori artefak ini bersifat komplementer: artefak spasial menangkap inkonsistensi visual yang tampak, sedangkan artefak frekuensi mengungkap jejak matematis proses generatif yang tersembunyi. Oleh karena itu, pendekatan deteksi yang menggabungkan analisis kedua domain dapat menghasilkan sistem yang lebih *robust* dan mampu mendeteksi berbagai jenis manipulasi *deepfake* [13, 16].

2.3 Pendekatan Deteksi Deepfake

Pendekatan deteksi *deepfake* dapat diklasifikasikan berdasarkan domain analisis yang digunakan. Secara umum, terdapat dua pendekatan utama: deteksi berbasis domain spasial yang menganalisis fitur visual langsung dari citra, dan deteksi berbasis domain frekuensi

yang menganalisis representasi spektral untuk mengidentifikasi artefak yang tidak terlihat secara kasat mata. Beberapa penelitian terkini juga mengeksplorasi pendekatan *hybrid* yang menggabungkan kedua domain untuk meningkatkan akurasi dan kemampuan generalisasi. Bagian berikut menguraikan masing-masing pendekatan beserta perbandingannya.

2.3.1 Deteksi Berbasis Domain Spasial

Pendekatan berbasis domain spasial merupakan metode deteksi *deepfake* yang berfokus pada analisis langsung terhadap *pixel* citra atau *frame* video untuk menemukan pola dan artefak anomali. Detektor spasial bekerja dengan mempelajari perbedaan visual antara konten asli dan konten hasil manipulasi, seperti ketidaksesuaian tekstur kulit, pencahayaan, tepi wajah, bayangan, maupun distorsi geometrik pada area yang telah dimodifikasi [14].

Beberapa penelitian mengembangkan model deteksi dengan arsitektur *Convolutional Neural Network* (CNN) khusus, seperti *MesoNet*, yang dirancang ringan namun efektif dalam mendeteksi artefak lokal pada wajah sintetis [4]. Selain itu, arsitektur *ResNet* yang diperkenalkan oleh *He et al.* [5], dan *XceptionNet* oleh *Chollet* [6], menjadi *backbone* populer dalam sistem *deepfake*, karena kemampuannya dalam mengekstraksi fitur spasial secara mendalam. Penelitian oleh *Haq* [3] menunjukkan bahwa model *XceptionNet*, dan *ResNet-50* mampu melakukan klasifikasi video *deepfake* dengan akurasi tinggi, terutama ketika dikombinasikan dengan metode ekstraksi fitur seperti *Local Binary Pattern* (LBP).

Dataset seperti FaceForensics++ juga menjadi standar dalam pelatihan dan evaluasi model deteksi berbasis spasial. *Dataset* ini mencakup berbagai jenis manipulasi wajah, tingkat kompresi, dan kondisi pencahayaan, sehingga mendukung penelitian terhadap berbagai variasi *deepfake* [7].

Secara umum, pendekatan spasial menawarkan performa yang baik dalam kondisi data yang serupa dengan data pelatihan, di mana model dapat mendeteksi kepalsuan ketika dihadapkan dengan data yang sama, namun ketika dihadapkan dengan data yang berbeda, model cenderung bergantung pada artefak permukaan yang spesifik terhadap proses pembuatan tertentu, sehingga akurasi dapat menurun, dan model berpotensi tidak dapat mendeteksi anomali tersebut [14]. Oleh karena itu, penelitian terbaru mulai menggabungkan pendekatan spasial dengan FDA untuk meningkatkan *robustness* dan kemampuan generalisasi terhadap berbagai jenis *deepfake* yang semakin kompleks.

2.3.2 Deteksi Berbasis Domain Frekuensi

Pendekatan berbasis domain frekuensi atau FDA merupakan metode deteksi *deepfake* yang terfokus pada menganalisis komponen spektral dari sebuah citra atau video. Berbeda dengan domain spasial yang bekerja secara langsung terhadap intensitas *pixel*, pendekatan dengan FDA mengubah citra ke dalam representasi frekuensi dengan menggunakan transformasi matematis seperti *Fast Fourier Transform* (FFT). Dengan representasi ini, karakteristik yang tersembunyi dan tidak terdeteksi di domain spasial, terutama artefak yang muncul akibat proses generatif seperti *upsampling* atau *interpolation*, dapat terlihat lebih jelas [8, 9, 11].

Durall et al. [7] mengemukakan bahwa model generatif berbasis CNN, seperti *Generative Adversarial Networks* (GAN), kerap tidak mampu mereplikasi karakteristik distribusi spektral yang lazim ditemukan pada citra asli. Hal ini menyebabkan gambar sintetis menampilkan perbedaan pola dalam domain frekuensi, khususnya pada bagian frekuensi tinggi. *Zhang et al.* [8] menyatakan bahwa artefak dalam domain frekuensi dapat ditiru dan dimanfaatkan sebagai semacam sidik jari digital untuk mengidentifikasi gambar yang telah dimanipulasi. Studi lanjutan oleh *Qian et al.* [14] memperkenalkan pendekatan *Thinking in Frequency*, dengan mengeksplorasi petunjuk frekuensi guna memperkuat kemampuan deteksi dan meningkatkan generalisasi pada berbagai *dataset*.

Pendekatan berbasis frekuensi memiliki keunggulan utama dalam mendeteksi anomali spektral yang tidak terlihat oleh mata manusia. Sebagai contoh, citra wajah hasil *deepfake* sering memperlihatkan distribusi spektral yang tidak konsisten, atau pola frekuensi konsentris yang menyimpang dari citra asli. Metode seperti *Frequency-Enhanced Self-Blended Image* (FSBI) oleh *Hasanaath et al.* [17], dan pendekatan *Frequency Space Domain Learning* (FSDL) oleh *Tan et al.* [18], menunjukkan bahwa pemanfaatan informasi dalam domain frekuensi dapat memperbaiki akurasi serta mendukung generalisasi antar-*dataset* pada sistem pendeteksi *deepfake*. Dalam upaya meningkatkan ketahanan model terhadap manipulasi berbasis generatif, *Luo dan Wang* [19] merancang metode *Frequency-Domain Masking* yang secara adaptif menggabungkan elemen spasial dan frekuensi dalam proses pendeteksian.

Secara keseluruhan, berbagai studi tersebut mengindikasikan bahwa informasi dalam domain frekuensi dapat berfungsi sebagai pelengkap penting bagi pendekatan berbasis spasial, karena mampu menangkap karakteristik yang tidak terlihat secara langsung dalam ruang gambar. Kehadiran artefak spektral yang konsisten di berbagai jenis konten *deepfake*

menjadikan pendekatan berbasis analisis domain frekuensi (FDA) lebih andal dalam menghadapi variasi model generatif maupun perbedaan distribusi data (baik lintas model GAN maupun antar dataset). Oleh karena itu, semakin banyak penelitian terkini yang menggabungkan analisis spasial dan frekuensi dalam satu kerangka kerja deep learning, untuk membangun sistem pendeteksi deepfake yang lebih presisi, tangguh, dan responsif terhadap teknik manipulasi yang terus berkembang.

2.3.3 Perbandingan Domain Spasial dengan Domain Frekuensi

Pendekatan deteksi *deepfake* berbasis domain spasial dan domain frekuensi memiliki karakteristik, kekuatan, dan kelemahan yang berbeda. Perbandingan kedua pendekatan ini penting untuk memahami mengapa integrasi keduanya dalam satu arsitektur *hybrid* dapat menghasilkan sistem deteksi yang lebih *robust* [8, 9, 14].

Tabel 2.1 Perbandingan Pendekatan Domain Spasial dan Domain Frekuensi .

Aspek Perbandingan	Domain Spasial	Domain Frekuensi (FDA)
Jenis informasi	Intensitas <i>pixel</i> , tekstur, warna, tepi objek	Distribusi energi frekuensi, pola spektral, amplitudo dan fase
Artefak yang dideteksi	Ketidaksesuaian <i>blending</i> , distorsi geometri, inkonsistensi pencahayaan	<i>Spectral distortions, periodic noise, checkerboard artifacts</i>
Sensitifitas	Tinggi terhadap artefak visual yang tampak	Tinggi terhadap artefak algoritmik yang tersembunyi
Generalisasi lintas dataset	Terbatas, cenderung <i>overfit</i> pada tekstur spesifik dataset	Lebih baik, karena artefak frekuensi bersifat universal
Ketahanan terhadap kompresi	Menurun signifikan pada kompresi tinggi R	elatif stabil, pola spektral tetap terdeteksi
Kelemahan utama	Bergantung pada pola visual yang dapat disamarkan oleh GAN modern	Kehilangan informasi konteks spasial (lokasi artefak)
Contoh arsitektur	<i>XceptionNet, ResNet, MesoNet</i>	FT-based classifier, DCT-based detector

Dari perbandingan tersebut, terlihat bahwa pendekatan spasial unggul dalam menangkap anomali visual lokal seperti tekstur dan tepi wajah, namun rentan terhadap peningkatan kualitas GAN modern yang semakin mampu menyamarkan artefak visual [14]. Sebaliknya, pendekatan frekuensi mampu menangkap pola algoritmik yang bersifat

universal dan stabil, tetapi kehilangan informasi mengenai lokasi spasial dari artefak tersebut [8].

Sifat komplementer kedua domain inilah yang mendorong banyak penelitian terkini untuk menggabungkan analisis spasial dan frekuensi dalam satu kerangka kerja deteksi, guna memperoleh representasi fitur yang lebih lengkap dan *robust* terhadap berbagai variasi *deepfake* [13, 11, 16].

2.3.4 Pendekatan Hybrid Domain Spasial-Frekuensi

Pendekatan *hybrid* domain spasial-frekuensi merupakan strategi deteksi *deepfake* yang mengintegrasikan fitur dari kedua domain dalam satu kerangka kerja *deep learning*. Tujuan utama pendekatan ini adalah memanfaatkan sifat komplementer kedua domain: domain spasial menangkap anomali visual seperti tekstur, tepi, dan konsistensi pencahayaan, sedangkan domain frekuensi mengungkap artefak algoritmik yang tidak terlihat secara visual, seperti *spectral distortions* dan *periodic noise* [13, 16].

Secara arsitektural, terdapat dua strategi utama dalam mengintegrasikan domain spasial dan frekuensi [11, 13, 16]:

1. *Early Fusion* (Fusi Awal)

Pada pendekatan *early fusion*, representasi frekuensi digabungkan dengan citra RGB sebagai kanal tambahan sebelum diproses oleh model CNN. Sebagai contoh, spektrum magnitudo FFT ditambahkan sebagai kanal keempat sehingga input model menjadi tensor 4-kanal (RGB + FFT). Dengan demikian, seluruh informasi spasial dan frekuensi diproses secara bersamaan oleh satu jaringan konvolusional. Pendekatan ini memungkinkan model mempelajari interaksi antara fitur spasial dan frekuensi sejak lapisan konvolusi pertama, namun memerlukan arsitektur yang mampu menangani *input* multi-kanal secara efektif [11].

2. *Late Fusion* (Fusi Akhir) / *Two-Branch Architecture*

Pada pendekatan *late fusion*, fitur spasial dan fitur frekuensi diekstraksi secara terpisah oleh dua *branch* atau cabang jaringan yang independen. *Branch* spasial menggunakan model CNN (misalnya *XceptionNet*) untuk mengekstraksi fitur dari citra RGB, sedangkan *branch* frekuensi menggunakan CNN terpisah yang lebih ringan untuk memproses representasi FFT. Fitur-fitur dari kedua *branch* kemudian digabungkan (*concatenated*) dan diteruskan ke lapisan klasifikasi bersama. Pendekatan ini memberikan fleksibilitas dalam memilih arsitektur yang optimal untuk masing-masing

domain, serta memungkinkan setiap *branch* untuk mengekstraksi fitur secara spesifik tanpa saling mengganggu [11, 13].

Beberapa penelitian terkini yang mengadopsi pendekatan *hybrid* menunjukkan peningkatan performa yang signifikan. *Alam et al.* melalui *SpecXNet* menggabungkan fitur spasial dari *XceptionNet* dengan informasi frekuensi untuk meningkatkan ketahanan deteksi terhadap berbagai jenis manipulasi [13]. *Hasanaath et al.* dengan metode FSBI memanfaatkan fitur frekuensi eksplisit untuk memperkuat kemampuan generalisasi lintas *dataset* [16]. *Luo dan Wang* mengembangkan mekanisme *frequency-domain masking* yang secara adaptif mengintegrasikan informasi spasial dan frekuensi [17]. Penelitian-penelitian ini menunjukkan bahwa pendekatan *hybrid* secara konsisten menghasilkan performa yang lebih baik dibanding model berbasis domain tunggal, terutama dalam skenario *cross-dataset* dan *cross-GAN*.

Dalam penelitian ini, kedua strategi *fusion* diimplementasikan dan dievaluasi: *early fusion* melalui arsitektur *XceptionNet* 4-kanal (RGB + FFT), serta *late fusion* melalui arsitektur *two-branch* yang menggabungkan *XceptionNet* untuk fitur spasial dan CNN ringan untuk fitur frekuensi. Perbandingan kedua strategi ini bertujuan untuk mengidentifikasi pendekatan yang paling efektif dalam meningkatkan akurasi dan kemampuan generalisasi deteksi *deepfake*.


2.4 Frequency Domain Analysis

Analisis domain frekuensi (*Frequency Domain Analysis* / FDA) merupakan pendekatan yang mengubah representasi citra dari domain spasial ke domain frekuensi untuk mengungkap pola-pola yang tidak terdeteksi oleh analisis visual langsung. Dalam konteks deteksi *deepfake*, FDA sangat relevan karena proses sintesis generatif menghasilkan artefak spektral yang khas, seperti distorsi distribusi frekuensi dan puncak periodik pada komponen frekuensi tinggi. Bagian berikut menjelaskan konsep dasar domain frekuensi, transformasi Fourier, dan relevansinya terhadap deteksi *deepfake*.

2.4.1 Konsep Domain Frekuensi

Dalam domain spasial, setiap *pixel* merepresentasikan intensitas atau warna di posisi tertentu dalam citra. Sebaliknya, dalam domain frekuensi, citra dianggap sebagai kombinasi dari gelombang *sinusoidal* dengan berbagai frekuensi dan amplitudo yang secara bersama-sama membentuk pola keseluruhan gambar [8].

Transformasi dari domain spasial ke domain frekuensi dilakukan menggunakan metode matematis seperti *Fast Fourier Transform* (FFT), *Discrete Cosine Transform* (DCT), atau *Wavelet Transform*. Melalui proses ini, citra dapat diuraikan menjadi dua komponen utama, sebagaimana dijelaskan pada berikut:



Gambar 2.1 Distribusi Komponen *Low-Frequency* dan *High-Frequency*

Perbandingan komponen *low-frequency* dan *high-frequency* dalam citra hasil transformasi FFT:


1. Citra kiri: hasil *inverse* FFT menggunakan hanya frekuensi rendah, menampilkan bentuk umum dan pencahayaan lembut.
2. Citra kanan: hasil *inverse* FFT dengan hanya frekuensi tinggi, menonjolkan tepi, detail, dan tekstur tajam.

Tabel 2.2 Komponen dalam Domain Frekuensi [8, 9]

Komponen Frekuensi	Deskripsi	Ciri Visual	Peran dalam Analisis Citra
Low-Frequency Components	Menyimpan informasi global seperti bentuk, pencahayaan, dan area halus citra.	Terpusat di bagian tengah spektrum frekuensi (warna terang di tengah).	Memberikan gambaran umum struktur citra dan pola besar.

High-Frequency Components	Mengandung detail halus seperti tepi, tekstur, dan perubahan intensitas tajam.	Muncul di bagian tepi spektrum (warna terang atau garis halus).	Mengungkap artefak manipulasi, distorsi, atau detail buatan.
---------------------------	--	---	--

Pendekatan ini menjadi penting dalam deteksi *deepfake* karena proses generatif pada *Generative Adversarial Networks* (GAN) sering kali meninggalkan artefak matematis akibat operasi *upsampling* dan *interpolation*, yang sulit diamati pada domain spasial tetapi muncul jelas pada domain frekuensi [8, 9].



Gambar 2.2 Representasi Domain Frekuensi [30]

Domain frekuensi menggambarkan bagaimana berbagai gelombang *sinusoidal* dengan frekuensi berbeda menyusun pola citra. Warna terang di pusat spektrum menandakan frekuensi rendah (bentuk global dan pencahayaan), sementara area terang di tepi menandakan frekuensi tinggi (tepi, tekstur, detail halus).

2.4.2 Transformasi *Fourier* (FFT)

Transformasi *Fourier* dua dimensi mengubah citra spasial $f(x, y)$ berukuran dua dimensi $M \times N$ menjadi representasi frekuensi $F(u, v)$, yang menggambarkan distribusi energi pada berbagai tingkat frekuensi.

Persamaan umum *Discrete Fourier Transform* (DFT) adalah:

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \cdot e^{-j \cdot 2\pi \left(\frac{u \cdot x}{M} + \frac{v \cdot y}{N} \right)} \quad (2.1)$$

Persamaan inversenya (Inverse DFT) untuk mengembalikan ke domain spasial:

$$f(x, y) = \left(\frac{1}{M \cdot N} \right) \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) \cdot e^{j \cdot 2\pi \left(\frac{u \cdot x}{M} + \frac{v \cdot y}{N} \right)} \quad (2.2)$$

Hasil transformasi *Fourier* berupa bilangan kompleks yang terdiri dari bagian real dan imajiner. Untuk mendapatkan distribusi energi, dihitung nilai *magnitude spectrum*:

$$S(u, v) = |F(u, v)| = \sqrt{\text{Re}(F(u, v))^2 + \text{Im}(F(u, v))^2} \quad (2.3)$$

Agar pola energi frekuensi lebih mudah divisualisasikan, nilai magnitudo biasanya diubah ke skala logaritmik:

$$S_{\log(u,v)} = \log(1 + S(u, v)) \quad (2.4)$$

Spektrum magnitudo, yang menampilkan intensitas energi pada berbagai tingkat frekuensi:

1. Pusat spektrum (*DC component*) mewakili frekuensi rendah (informasi global citra),
2. Area tepi menunjukkan frekuensi tinggi (detail halus dan tepi objek).

Distribusi energi yang alami pada citra nyata menurun secara bertahap dari pusat ke arah tepi, sedangkan pada citra hasil GAN, pola ini menunjukkan *spectral anomaly*, seperti pola *radial*, *spike*, atau garis periodik yang tidak wajar [8, 11].

2.4.3 Artefak Frekuensi pada Citra Deepfake

Jaringan GAN dengan operasi *upsampling transposed-convolution* secara sistematis menghasilkan distribusi spektral yang lebih landai (*spectral fall-off*) dibanding citra natural, sehingga rasio energi *high-band* terhadap *low-band* dapat dijadikan ciri pembeda [8]. *Zhang et al.* mengonfirmasi bahwa artefak frekuensi tinggi ini konsisten di berbagai jenis GAN dan dapat berfungsi sebagai “GAN fingerprints” [8, 9].

Selanjutnya, *Qian et al.* memperkenalkan konsep *Frequency-aware Clues*, yang membuktikan bahwa detektor yang memanfaatkan sinyal frekuensi dapat lebih akurat dalam mendeteksi citra sintetis. [11] *Hasanaath et al.* melalui metode *Frequency Enhanced Self-Blended Image* (FSBI) menegaskan bahwa fitur frekuensi membantu meningkatkan robustness dan kemampuan generalisasi antar-dataset. [16] *Tan et al.* dan *Lao et al.* juga menunjukkan bahwa pembelajaran adaptif pada domain frekuensi menghasilkan peningkatan akurasi pada deteksi *cross-GAN* dan *cross-dataset*. [17, 23]

Tabel 2.3 Karakteristik Artefak Frekuensi pada Deepfake [8, 9, 11, 16]

Jenis Artefak	Deskripsi	Penyebab Utama
Distribusi energi tinggi pada high-frequency	Intensitas tinggi di area tepi spektrum.	Proses upsampling GAN.

Pola radial/simetri berulang	Pola garis melingkar di sekitar pusat spektrum.	Interpolasi atau kernel transposed convolution.
Ketidakeimbangan arah energi	Energi condong pada orientasi tertentu.	Struktur jaringan tidak isotropik.
Noise periodik	Pola titik-titik berulang.	Zero-padding atau aliasing.

2.4.4 Peran Frequency Domain Analysis dalam Deteksi Deepfake

FDA memainkan peran penting dalam mendeteksi konten sintetis karena artefak yang muncul di domain frekuensi bersifat universal dan algoritmik, bukan semata-mata visual. Pendekatan ini terbukti efektif dalam:

1. *Cross-GAN detection*, karena setiap GAN meninggalkan sidik jari frekuensi yang unik [9];
2. *Robustness* terhadap kompresi dan *noise*, sebab pola frekuensi relatif stabil meski citra terkompresi [16];
3. Efisiensi representasi fitur, karena hanya memerlukan peta magnitudo atau fase spektrum [12].

Namun, FDA juga memiliki keterbatasan:

1. Hilangnya informasi konteks spasial (lokasi artefak),
2. Sensitivitas terhadap rotasi atau translasi citra,
3. Memerlukan integrasi dengan *spatial feature extractor* agar hasil deteksi lebih komprehensif.

Untuk itu, banyak penelitian terkini menggabungkan FDA dengan jaringan konvolusional seperti *XceptionNet* dalam model *hybrid spatial-frequency*, guna memanfaatkan kekuatan analisis struktural spasial dan deteksi artefak frekuensi secara bersamaan [13, 16, 17, 23].

2.5 Spectral Distortions dalam Deteksi Deepfake

Pendekatan deteksi berbasis domain frekuensi semakin banyak digunakan karena ditemukannya pola *spectral distortions*, yaitu penyimpangan distribusi spektral yang muncul secara sistematis pada citra dan video manipulasi. Distorsi ini muncul akibat keterbatasan model generatif seperti GAN dan *encoder-decoder CNN* dalam mereproduksi distribusi frekuensi yang alami [8, 9]. Berbeda dengan artefak spasial yang dapat disamarkan oleh

model generatif generasi baru, *spectral distortions* bersifat lebih stabil karena berakar pada proses matematis dari *up-convolution*, *interpolation*, dan *feature reconstruction* [8, 21].

2.5.1 Akar Kemunculan Spectral Distortions pada Model Generatif

Model generatif berbasis CNN memiliki keterbatasan dalam mempelajari struktur statistik frekuensi alami. Operasi *up-convolution* dengan *stride* lebih dari 1 menghasilkan pola periodik di domain frekuensi karena *kernel overlap* yang tidak seragam. Fenomena ini dikenal dengan *checkerboard artifacts* [8, 21].

Zhang *et al.* [9] juga menemukan bahwa citra hasil sintesis GAN memiliki anomali spektral pada frekuensi menengah hingga tinggi. Pola ini muncul sebagai “sidik jari” khas citra manipulasi (GAN *fingerprints*), yang dapat dikenali tanpa bergantung pada ciri spasial. Kesulitan model generatif mereproduksi distribusi frekuensi ini merupakan penyebab utama mengapa *spectral distortions* tetap muncul bahkan pada GAN canggih seperti *Progressive Growing of GANs* [23].

2.5.2 Jenis-Jenis Spectral Distortions pada Gambar dan Video Deepfake

1. Distorsi Frekuensi Tinggi

Model generatif sering gagal menghasilkan detail mikro yang alami, menyebabkan ketidakseimbangan energi pada komponen frekuensi tinggi. Qian *et al.* [11] serta Mejri *et al.* [24] menunjukkan bahwa *deepfake* cenderung memiliki tekstur kulit yang terlalu halus dan pola frekuensi tinggi yang tidak konsisten. Distorsi ini menjadi salah satu indikator paling kuat dalam deteksi berbasis domain frekuensi.

2. Checkerboard Patterns

Pola *checkerboard* merupakan artefak klasik yang muncul dari *transposed convolution* dan menjadi penyebab dominan *spectral distortions* pada banyak model GAN [8, 21]. Artefak ini tampak sebagai pola *grid* berulang pada domain spasial dan sebagai titik-titik intensitas periodik pada domain frekuensi.

3. Anomali Koefisien DCT

Giudice *et al.* [10] menemukan bahwa citra GAN menampilkan anomali pada koefisien *Discrete Cosine Transform* (DCT), terutama pada band frekuensi menengah. Ketidakseimbangan ini disebabkan oleh ketidakmampuan GAN untuk mempelajari korelasi alami antar blok DCT yang lazim pada citra asli.

4. Distorsi Frekuensi Menengah

Penelitian FSBI [16] dan SpecXNet [13] melaporkan bahwa *deepfake* menunjukkan perbedaan signifikan pada *band* frekuensi menengah. *Band* ini sangat penting karena berhubungan dengan pola tekstur wajah seperti kontur, lipatan, dan mikro-ekspresi.

5. Distorsi Spektral Temporal pada Video

Deepfake video tidak hanya mengandung anomali frekuensi antar *pixel*, tetapi juga antar *frame*. Kim et al. [25] menemukan bahwa manipulasi wajah menyebabkan *inconsistency temporal frequency*. Temuan ini sejalan dengan penelitian sebelumnya oleh Nguyen et al. dan Guera et al., yang menjelaskan bahwa video *deepfake* cenderung memiliki pola frekuensi temporal yang tidak stabil selama pergerakan wajah [26, 27].

2.5.3 Relevansi Spectral Distortions untuk Deteksi Deepfake

Analisis domain frekuensi memiliki keunggulan penting dibanding pendekatan berbasis spasial. Rao dan Uehara [15] serta Rana et al. [14] menegaskan bahwa peningkatan kualitas *deepfake* modern membuat artefak spasial semakin sulit dideteksi, sedangkan *spectral distortions* tetap muncul karena berasal dari keterbatasan struktural model generatif. Keunggulan utama penggunaan *spectral distortions* dalam deteksi *deepfake* meliputi:

1. Generalisasi yang Lebih Baik

Metode berbasis frekuensi terbukti lebih *generalizable* untuk menghadapi *dataset* dan teknik manipulasi baru [11, 17, 23]. Artefak frekuensi tidak bergantung pada pola *pixel* spesifik *dataset* sehingga lebih stabil dalam pengujian *cross-dataset* dan *cross-GAN*.

2. Ketahanan terhadap Kompresi

Citra dan video yang mengalami kompresi sering kehilangan ciri spasial, namun pola spektral tertentu tetap dapat dipertahankan. Tan et al. menunjukkan bahwa detektor berbasis frekuensi memiliki performa lebih baik pada citra terkompresi [12].

3. Robustness terhadap GAN Generasi Baru

Walaupun GAN modern seperti PGGAN atau StyleGAN meningkatkan kualitas visual, struktur matematis *convolutional upsampling* tetap menghasilkan distorsi spektral. Hal ini membuat *spectral distortions* tetap relevan pada deteksi *deepfake* generasi terbaru.

4. Dukungan untuk Deteksi Berbasis Video

Seiring meningkatnya video *deepfake*, distorsi spektral temporal menjadi ciri esensial yang sulit dihilangkan oleh model generatif. Pendekatan oleh Kim et al. dan Guera et al. memperkuat pentingnya analisis frekuensi dalam dimensi waktu [25, 27].

2.5.4 Pendekatan Modern yang Memanfaatkan Spectral Distortions

1. Frequency-Aware CNN

Penelitian oleh Qian et al. serta Tan et al. mengusulkan pembelajaran langsung dari representasi frekuensi, yang dapat meningkatkan sensitivitas model terhadap distorsi spektral [11, 12].

2. Pendekatan Dual-Domain

SpecXNet dan FSBI memadukan domain spasial dan frekuensi untuk memperkaya representasi fitur. Pendekatan ini menunjukkan peningkatan signifikan dalam robustness detektor terhadap berbagai jenis serangan deepfake [13, 16].

3. Masking dan Interaksi Frekuensi–Spasial

Luo dan Wang mengembangkan mekanisme frequency-domain masking yang meningkatkan kemampuan model dalam menangkap interaksi antara domain spasial dan spektral [17].

4. Analisis Temporal Frequency untuk Video

Metode berbasis frekuensi temporal, seperti yang diperkenalkan Kim et al., memberikan kemampuan untuk mendeteksi anomali antar frame yang tidak dapat ditangkap oleh CNN spasial [25].

2.5.5 Relevansi Spectral Distortions terhadap Penelitian Ini

Integrasi FFT dalam arsitektur deteksi yang memanfaatkan *XceptionNet* memberikan akses langsung pada pola spektral yang tidak dapat ditangkap oleh CNN spasial murni. Dengan memanfaatkan *frequency-aware features*, model tidak hanya mempelajari tekstur dan pola visual, tetapi juga distribusi energi frekuensi yang menjadi ciri khas *deepfake* [6].

Hal ini sejalan dengan tren penelitian modern seperti SpecXNet, FSBI, dan *Frequency-Aware Deepfake Detection* yang menekankan pentingnya penggabungan domain spasial dan frekuensi untuk meningkatkan performa serta generalisasi [13, 16, 12].

2.6 Spectral Dropoff

Spectral dropoff merupakan fenomena penurunan energi spektral seiring meningkatnya frekuensi pada representasi frekuensi suatu citra atau video. Pada citra alami, distribusi spektrum frekuensi umumnya mengikuti pola tertentu, di mana energi terbesar berada pada frekuensi rendah dan secara bertahap menurun pada frekuensi yang lebih tinggi.

Pola ini mencerminkan karakteristik alami dari struktur visual, seperti bentuk global dan tekstur halus yang tersebar secara konsisten .

Dalam konteks *deepfake*, *spectral dropoff* menjadi salah satu indikator penting karena model generatif berbasis *deep learning* sering gagal mereproduksi penurunan spektral yang alami. Ketidaksesuaian pola *spectral dropoff* ini menyebabkan distribusi frekuensi pada citra hasil manipulasi berbeda dari citra asli, sehingga dapat dimanfaatkan sebagai petunjuk forensik dalam deteksi *deepfake* [8, 11].

2.6.1 Spectral Dropoff pada Citra Alami

Pada citra asli, spektrum frekuensi menunjukkan penurunan energi yang relatif halus dan konsisten dari frekuensi rendah ke frekuensi tinggi. Frekuensi rendah merepresentasikan struktur global seperti kontur wajah dan pencahayaan, sedangkan frekuensi tinggi berisi detail lokal seperti tekstur kulit dan tepi objek. Hubungan ini membentuk pola *spectral dropoff* yang stabil dan dapat dianggap sebagai ciri statistik alami dari citra dunia nyata [28].

Distribusi ini relatif konsisten antar citra alami, meskipun terdapat variasi akibat kondisi pencahayaan, resolusi, dan sensor kamera. Konsistensi inilah yang sering tidak dapat direplikasi secara sempurna oleh model generatif, khususnya pada bagian frekuensi menengah hingga tinggi [8, 14].

2.6.2 Anomali Spectral Dropoff pada Deepfake

Citra dan video *deepfake* umumnya menunjukkan anomali pada *spectral dropoff*, seperti penurunan energi yang terlalu cepat (*over-smoothing*) atau sebaliknya, energi frekuensi tinggi yang berlebihan dan tidak alami. Anomali ini muncul akibat proses *upsampling*, *decoder convolution*, dan *face blending* pada arsitektur GAN, yang menyebabkan distorsi distribusi spektral [8, 21].

Beberapa penelitian menemukan bahwa generator GAN cenderung menghasilkan pola spektral dengan kemiringan (*slope*) *spectral dropoff* yang berbeda dari citra asli, terutama pada frekuensi tinggi. Hal ini mengakibatkan tekstur wajah tampak terlalu halus atau justru mengandung artefak berulang yang tidak ditemukan pada citra alami [9, 10].

Selain itu, *spectral dropoff* yang tidak wajar juga berkaitan dengan kegagalan model generatif dalam mempertahankan konsistensi statistik frekuensi antar *frame* pada video *deepfake*, sehingga membuka peluang deteksi berbasis analisis spektrum temporal dan spasial [15, 25].

2.7 Periodic Noise dalam Domain Frekuensi

Periodic noise merupakan salah satu artefak penting dalam analisis domain frekuensi dan menjadi indikator kuat adanya proses generatif atau manipulatif dalam *deepfake*. Dalam konteks deteksi *deepfake*, *periodic noise* berperan sebagai *frequency fingerprint* yang muncul akibat operasi internal model generatif, terutama pada tahap *upsampling* atau rekonstruksi citra.

2.7.1 Definisi dan Karakteristik Periodic Noise

Periodic noise adalah pola gangguan (*noise pattern*) yang muncul secara berulang dan teratur pada citra digital. Pola ini biasanya berbentuk garis-garis atau *grid* berirama yang terlihat secara jelas pada representasi *Fourier Transform* (FFT) sebagai titik-titik (*spikes*) pada lokasi frekuensi tertentu. *Gonzales* dan *Woods* [28] menjelaskan bahwa *noise* periodik terbentuk akibat sinyal gangguan yang terstruktur, sehingga menghasilkan pola simetris pada spektrum frekuensi.

Dalam domain spasial, *periodic noise* seringkali sulit dikenali karena bercampur dengan tekstur natural pada citra. Namun, pada domain frekuensi, pola ini tampak sangat jelas karena FFT memisahkan komponen citra berdasarkan frekuensi dan mengungkapkan pola berulang yang tidak terlihat pada domain spasial [28, 29].

2.7.2 Sumber Periodic Noise pada Citra Deepfake

Pada citra hasil manipulasi *deepfake*, *periodic noise* umumnya muncul sebagai efek sampling dari operasi pembangkitan citra (*image synthesis*) yang dilakukan oleh model berbasis CNN generatif, seperti GAN maupun *encoder-decoder*. Sejumlah penelitian telah mengidentifikasi sumber *periodic noise* sebagai berikut:

1. Upsampling berbasis *transposed convolution* (*deconvolution*)

Penggunaan *deconvolution* dapat menghasilkan *checkerboard artifacts*. *Odena et al.* [21] menunjukkan bahwa artefak ini termanifestasi sebagai sinyal periodik di domain frekuensi.

2. Ketidakmampuan model mereplikasi distribusi spektral alami

Durall et al. [8] menemukan bahwa model generatif gagal menghasilkan distribusi frekuensi tinggi yang konsisten dengan citra asli, sehingga muncul pola spektral yang tidak natural, termasuk *periodic noise*.

3. Proses *blending* dan *warping* pada *face swapping*

Zhang *et al.* [9] melaporkan bahwa proses *blending* antar wajah menghasilkan pola frekuensi berulang yang dapat diamati melalui FFT.

4. *Generative priors* yang kurang stabil

Penelitian Chadha *et al.* [19] dan Mejri *et al.* [24] menunjukkan bahwa model *deepfake* cenderung menghasilkan komponen frekuensi tinggi yang tidak stabil dan berulang, karena generator mengoptimalkan sinyal tekstur untuk tampilan realistis tetapi tidak menangani harmonisasi frekuensi global.

2.7.3 Peran Periodic Noise dalam Deteksi Deepfake

Periodic noise merupakan fitur penting yang dimanfaatkan dalam banyak penelitian deteksi *deepfake* berbasis frekuensi. Beberapa alasan mengapa artefak ini sangat relevan:

1. Tanda unik dari citra sintetis (*synthetic fingerprinting*)

Periodic noise tidak ada pada citra asli. Kemunculannya mengindikasikan adanya proses pembangkitan sintetis yang tidak mampu meniru distribusi frekuensi alami [8, 9, 24].

2. Stabil untuk berbagai jenis *deepfake*

Qian *et al.* [11] dan SpecXNet oleh Alam *et al.* [13] menunjukkan bahwa ciri frekuensi, termasuk *periodic noise*, lebih *stable* dan *generalizable* dibanding fitur spasial, bahkan terhadap *deepfake* baru (*cross-GAN* dan *cross-dataset*).

3. Dapat diekstraksi secara efektif dengan FFT atau DCT

Representasi FFT menampilkan *periodic noise* sebagai *spike* terlokalisasi pada frekuensi tertentu. Hal ini memudahkan model untuk mengekstrak pola anomali yang konsisten [30, 31].

4. Digunakan dalam model frekuensi mutakhir

Model seperti FSBI [16] *Frequency-Aware Deepfake Detection* [12] dan *Frequency-Domain Masking* [17] menggunakan komponen frekuensi sebagai fitur utama, termasuk artefak periodik, untuk meningkatkan performa deteksi.

2.7.4 Contoh Pola Periodic Noise pada Spektrum Frekuensi

Periodic noise pada domain frekuensi umumnya muncul sebagai titik-titik terang yang simetris terhadap pusat spektrum akibat sifat *conjugate symmetry* pada transformasi *fourier*. Selain itu, *periodic noise* dapat membentuk garis vertikal atau horizontal pada frekuensi rendah hingga menengah, serta pola *grid* dua dimensi yang tidak ditemukan pada citra non-

manipulatif. Pola-pola ini menunjukkan adanya struktur berulang pada domain spasial yang termanifestasi sebagai *spike* terlokalisasi pada domain frekuensi [29, 32].

2.8 Warping dalam Domain Frekuensi

Warping merupakan bentuk distorsi geometris yang terjadi akibat proses manipulasi citra atau video, khususnya pada teknik sintesis wajah berbasis *deep learning* seperti *Generative Adversarial Networks* (GAN). Dalam konteks *deepfake*, *warping* sering muncul sebagai konsekuensi dari proses *face alignment*, *resizing*, *warping*, dan *blending* antara wajah sumber dan wajah target. Distorsi ini tidak selalu tampak jelas secara visual, namun dapat dianalisis secara efektif melalui domain frekuensi, baik pada komponen frekuensi rendah (*low-frequency*) maupun frekuensi tinggi (*high-frequency*) [8, 29].

2.8.1 Low-Frequency Warping

Low-frequency warping mengacu pada distorsi yang memengaruhi komponen frekuensi rendah dari citra, yaitu bagian yang merepresentasikan struktur global seperti bentuk wajah, proporsi objek, dan perubahan pencahayaan secara halus. Pada proses *deepfake*, *low-frequency warping* sering muncul akibat transformasi geometris global, seperti *affine transformation* atau *non-rigid warping*, yang digunakan untuk menyesuaikan pose dan ekspresi wajah sumber dengan wajah target [7].

Distorsi pada frekuensi rendah biasanya tidak menghasilkan artefak tajam, tetapi menyebabkan efek tidak konsisten pada bentuk wajah secara keseluruhan, seperti wajah yang tampak sedikit melebar, menyempit, atau tidak simetris. Meskipun sulit dideteksi secara visual oleh manusia, ketidakwajaran distribusi spektral pada frekuensi rendah dapat menjadi indikator penting dalam deteksi *deepfake* berbasis analisis frekuensi [14, 11].

Beberapa penelitian menunjukkan bahwa model generatif cenderung gagal mereproduksi distribusi frekuensi alami secara konsisten, termasuk pada frekuensi rendah, terutama akibat proses *upsampling* dan *decoder* pada GAN [8, 21]. Hal ini menyebabkan pola spektral global yang berbeda antara citra asli dan citra hasil manipulasi.

2.8.2 High-Frequency Warping

High-frequency warping berkaitan dengan distorsi pada komponen frekuensi tinggi yang merepresentasikan detail lokal seperti tekstur kulit, tepi objek, rambut, dan kerutan

wajah. Pada *deepfake*, distorsi ini sering muncul akibat proses *rescaling*, *face swapping*, dan *blending* yang tidak sempurna antara wajah sintetis dan latar belakang asli [4, 9].

Warping pada frekuensi tinggi biasanya menghasilkan artefak yang lebih mudah dikenali secara spektral, seperti pola berulang (*checkerboard artifacts*), ketajaman tepi yang tidak alami, atau hilangnya detail tekstur kulit. Artefak ini sangat berkaitan dengan kegagalan jaringan generatif dalam merekonstruksi komponen frekuensi tinggi secara konsisten [21, 24].

Pendekatan deteksi *deepfake* modern banyak memanfaatkan anomali pada frekuensi tinggi, karena perbedaan antara citra asli dan hasil sintesis lebih menonjol pada domain ini. Metode berbasis DCT, FFT, maupun *frequency-aware CNN* menunjukkan bahwa manipulasi wajah sering meninggalkan jejak *warping* pada spektrum frekuensi tinggi yang dapat dipelajari secara efektif oleh model deteksi [16, 23, 26].

2.9 Deep Learning

Deep learning merupakan cabang dari *machine learning* yang menggunakan jaringan saraf tiruan (*artificial neural networks*) banyak lapisan untuk mengekstraksi representasi fitur secara bertingkat (*feature hierarchy*) dari data mentah seperti citra, suara, atau teks. Pendekatan ini memungkinkan sistem belajar mengenali pola kompleks tanpa memerlukan rekayasa fitur manual (*manual feature engineering*) [33]. Teknologi *deep learning* inilah yang kemudian menjadi dasar dari *deepfake*. Istilah *deepfake* terbentuk dari gabungan *deep learning* dan *fake*, merujuk pada konten visual atau audio yang dimodifikasi dengan jaringan saraf dalam hingga menyerupai rekaman asli [19].

Salah satu bentuk implementasi paling umum dari *deep learning* adalah *Convolutional Neural Network* (CNN), yang dirancang khusus untuk mengenali pola spasial pada data visual [6]. CNN menggunakan operasi konvolusi untuk mengekstraksi fitur spasial dari citra dan telah menjadi tulang punggung dalam banyak penelitian deteksi *deepfake*, seperti *ResNet* [5] dan *XceptionNet* [6] merupakan contoh arsitektur CNN yang banyak digunakan karena kemampuannya dalam mempelajari representasi visual yang efisien dan akurat untuk klasifikasi gambar atau deteksi manipulasi wajah.

2.9.1 Arsitektur Dasar Deep Learning

Deep learning tersusun atas jaringan saraf tiruan berlapis banyak (*multi-layer neural networks*) yang bekerja dengan memproses data melalui neuron-neuron buatan. Setiap

neuron menerima input, mengalikan bobot (*weight*), menjumlahkan bias, lalu melewatkannya melalui fungsi aktivasi seperti ReLU, *sigmoid*, atau *softmax*. Melalui pelatihan (*training*), jaringan akan melakukan pembaruan bobot (*weight update*) dengan algoritma optimisasi seperti *Stochastic Gradient Descent* (SGD) atau *Adaptive Moment Estimation* (ADAM) sehingga model dapat mempelajari pola dari data [7].

Dalam konteks pengolahan citra, lapisan awal cenderung mempelajari fitur sederhana seperti tepi, garis, dan tekstur, sedangkan lapisan yang lebih dalam mempelajari pola kompleks seperti bentuk objek, ekspresi wajah, dan struktur wajah manusia. Hierarki pembelajaran fitur inilah yang membuat deep learning unggul pada tugas deteksi visual.

2.9.2 Peran Deep Learning dalam Pembuatan Deepfake

Deep learning merupakan fondasi utama dari teknologi *deepfake* modern. Arsitektur generatif seperti *Generative Adversarial Networks* (GAN) dan *encoder-decoder* digunakan untuk menghasilkan manipulasi wajah, ekspresi, atau gerakan bibir secara realistis. GAN bekerja dengan dua jaringan generator dan *discriminator* yang dilatih secara *adversarial* sehingga generator terus meningkatkan kualitas citra sintetis hingga sangat mirip dengan citra asli [8, 9, 19].

Kemampuan GAN untuk menghasilkan detail wajah dan tekstur kulit yang halus menjadikan *deepfake* berkembang pesat. Namun proses generatif ini juga meninggalkan jejak matematis seperti artefak frekuensi tinggi dan distorsi *spektral*, yang kemudian menjadi dasar bagi berbagai teknik deteksi berbasis frekuensi [8, 9, 11].

2.9.3 Peran Deep Learning dalam Deteksi Deepfake

Selain digunakan untuk menghasilkan *deepfake*, *deep learning* juga berperan penting dalam pendeteksiannya. Arsitektur CNN seperti *ResNet*, *MesoNet*, dan *XceptionNet* digunakan untuk mengekstraksi fitur spasial dan mendeteksi ketidakwajaran visual pada citra wajah palsu [3, 4, 5, 6, 7].

CNN terbukti efektif mendeteksi anomali yang merupakan artefak umum dari proses manipulasi generatif seperti:

1. Ketidaksesuaian tekstur kulit
2. Batas *blending* wajah yang tidak natural
3. Distorsi wajah lokal akibat *face warping*
4. Ketidakkonsistenan pencahayaan atau pose

XceptionNet yang menggunakan *depthwise separable convolution*, telah diakui memiliki sensitivitas lebih baik terhadap pola tekstur dan detail halus, sehingga banyak digunakan dalam penelitian deteksi *deepfake* modern dan kompetisi *benchmark* seperti *FaceForensics++* [3, 4, 6, 7].

Dalam penelitian ini, *deep learning* berperan sebagai *ekstraktor* fitur spasial melalui *XceptionNet*, dan dikombinasikan dengan analisis domain frekuensi (FFT) untuk menangkap artefak *spektral* yang tidak dapat dianalisis oleh metode spasial saja [13, 16, 17, 23].

2.9.4 Convolution Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan salah satu arsitektur utama dalam *deep learning* yang dirancang khusus untuk mengolah data berbentuk *grid*, seperti citra dua dimensi. CNN memanfaatkan operasi konvolusi untuk mengekstraksi fitur lokal secara hierarkis, sehingga mampu mengenali pola sederhana (tepi, tekstur) pada lapisan awal dan pola yang semakin kompleks (bagian wajah, objek) pada lapisan yang lebih dalam. Pendekatan ini berbeda dengan *multilayer perceptron* biasa karena CNN mengeksplorasi struktur spasial citra melalui *local receptive field* dan *weight sharing* sehingga jumlah parameter menjadi jauh lebih sedikit dan proses pelatihan lebih efisien [28, 33].

Secara umum, arsitektur CNN tersusun atas beberapa jenis lapisan utama, yaitu *convolutional layer*, *non-linear activation* (misalnya ReLU), *pooling layer*, dan *fully connected layer* di bagian akhir untuk melakukan klasifikasi. *Convolutional layer* melakukan operasi *filter* menggunakan *kernel* yang digeser secara spasial pada citra untuk menghasilkan *feature map*. *Weight sharing* membuat satu filter yang sama digunakan di seluruh posisi citra sehingga CNN bersifat *translationally equivariant* terhadap pola tertentu. *Pooling layer* (seperti *max-pooling*) kemudian mereduksi resolusi spasial *feature map* sambil mempertahankan informasi penting sehingga model menjadi lebih tahan terhadap variasi kecil posisi dan *noise*. Seluruh parameter jaringan dipelajari secara *end-to-end* menggunakan algoritma *backpropagation* dan optimisasi gradien turun [28, 33].

Dalam bidang visi komputer, CNN telah menjadi *backbone* utama untuk berbagai tugas pengenalan citra dan wajah. Arsitektur-arsitektur seperti *ResNet* memanfaatkan *residual connection* untuk mengatasi degradasi performa pada jaringan sangat dalam dan berhasil mencapai performa *state-of-the-art* pada berbagai *benchmark* klasifikasi citra [5]. Sementara itu, *XceptionNet* mengusulkan *depthwise separable convolution* untuk mengurangi kompleksitas komputasi tanpa mengorbankan akurasi, dan banyak diadopsi

dalam berbagai studi deteksi *deepfake* sebagai *feature extractor* utama pada domain spasial [3, 6, 7]. Model ringan seperti *MesoNet* juga dirancang sebagai CNN berukuran kompak khusus untuk deteksi pemalsuan wajah pada video, dengan fokus pada artefak *meso-level* di area wajah [4].

Pada konteks deteksi *deepfake*, CNN digunakan untuk mempelajari artefak manipulasi yang sulit ditangkap oleh pengamatan manusia, seperti tekstur kulit yang tidak konsisten, *edge* yang tidak alami, atau pola *noise* yang ditinggalkan oleh proses generatif. Studi literatur menunjukkan bahwa sebagian besar detektor *deepfake* modern menggunakan CNN sebagai komponen utama, baik untuk citra statis maupun *frame* video, dengan performa yang sangat kompetitif pada berbagai *dataset* seperti *FaceForensics++* [14, 15, 20, 7]. Dalam skenario ini, CNN biasanya menerima *input* berupa *patch* wajah yang telah dipotong, kemudian mengeluarkan probabilitas apakah wajah tersebut asli atau hasil manipulasi.

Perkembangan terbaru menunjukkan bahwa CNN tidak hanya efektif di domain spasial, tetapi juga dapat digabungkan dengan analisis frekuensi untuk meningkatkan kemampuan generalisasi. Pendekatan seperti *Thinking in Frequency* memanfaatkan CNN yang dioptimalkan untuk memanfaatkan petunjuk pada domain frekuensi (misalnya melalui representasi FFT), sehingga jaringan lebih peka terhadap distorsi tinggi frekuensi yang dihasilkan oleh proses generatif [11]. Model lain seperti *SpecXNet*, FSBI, serta serangkaian metode *frequency-aware deepfake detection* memodifikasi arsitektur CNN atau *input*-nya dengan memasukkan kanal-kanal frekuensi tambahan atau modul khusus untuk menonjolkan komponen frekuensi tinggi, sehingga artefak yang tidak terlihat di domain spasial dapat dimanfaatkan secara lebih efektif untuk deteksi [13, 16, 17, 23, 33].

Selain memodelkan informasi spasial, CNN juga sering dikombinasikan dengan pemodelan temporal untuk video. Salah satu pendekatan umum adalah menggunakan CNN untuk mengekstraksi fitur per-*frame*, kemudian meneruskannya ke model sekuensial seperti LSTM atau GRU untuk menangkap dinamika temporal antar-*frame*, misalnya pada gerakan wajah dan sinkronisasi bibir. Pendekatan ini digunakan dalam berbagai karya deteksi *deepfake* berbasis *spatio-temporal*, termasuk yang mempelajari fitur pergerakan wajah dan artefak *temporal* pada video *deepfake* [26, 27]. Pendekatan *spatio-temporal* serupa juga diadopsi oleh *Haliassos et al.* yang memanfaatkan representasi CNN pada area mulut dan jaringan temporal untuk mendeteksi ketidakwajaran pola gerak bibir pada video sintetis [34]. Di luar domain forensik media, CNN juga digunakan secara luas bersama model sekuensial untuk tugas-tugas lain seperti peramalan beban dan konsumsi energi, menunjukkan bahwa

arsitektur ini bersifat serbaguna dan dapat menangani data spasial maupun *spatio-temporal* di berbagai domain aplikasi [35].

Berikut komponen-komponen kunci *depthwise separable convolution* yang menjadi inti efisiensi XceptionNet, salah satu CNN paling banyak digunakan dalam deteksi *deepfake*:

1. Depthwise Separable Convolution

Arsitektur XceptionNet merupakan salah satu model *Convolutional Neural Network* (CNN) modern yang dirancang untuk meningkatkan efisiensi ekstraksi fitur pada citra dengan memanfaatkan *depthwise separable convolution*. Pendekatan ini diperkenalkan oleh Chollet [6] sebagai pengembangan dari konsep *Inception Module*, dengan asumsi bahwa korelasi spasial dan korelasi kanal dapat dipisahkan sehingga proses konvolusi dapat dilakukan secara lebih optimal.

Pada penelitian deteksi *deepfake*, *XceptionNet* banyak digunakan karena kemampuannya dalam mengekstraksi pola tekstur halus yang sering muncul sebagai artefak manipulasi wajah [4, 7]. Berbeda dengan konvolusi standar yang melakukan operasi terhadap seluruh kanal masukan secara bersamaan, *depthwise separable convolution* memecah operasi tersebut menjadi dua tahap, yaitu *depthwise convolution* dan *pointwise convolution*. Pemisahan ini secara signifikan mengurangi jumlah parameter dan kompleksitas komputasi tanpa mengurangi kapasitas representasi fitur, sehingga model menjadi lebih efisien dan stabil saat digunakan pada citra wajah beresolusi tinggi.

2. Depthwise Convolution

Tahap pertama adalah *depthwise convolution*, yaitu proses konvolusi yang dilakukan secara independen pada setiap kanal masukan. Jika suatu citra masukan memiliki M kanal dan kernel konvolusi berukuran $K \times K$, maka operasi *depthwise* akan menerapkan satu kernel per kanal secara terpisah. Secara matematis, *depthwise convolution* dapat dituliskan sebagai:

$$D_m(x, y) = \sum_{i=0}^{K-1} \sum_{j=0}^{K-1} I_m(x+i, y+j) \cdot W_m(i, j) \quad (2.5)$$

dengan:

- I_m adalah kanal ke- m dari citra masukan,
- W_m adalah kernel konvolusi untuk kanal ke- m ,
- D_m adalah hasil *depthwise convolution* pada kanal ke- m .

Pendekatan ini memungkinkan model mengekstraksi pola tekstur lokal secara lebih rinci, terutama pada bagian wajah yang sering mengandung artefak seperti *blending* dan *warping* pada *deepfake* [4].

3. Pointwise Convolution

Tahap kedua adalah *pointwise convolution*, yaitu penerapan kernel berukuran 1×1 untuk menggabungkan kembali seluruh kanal hasil depthwise menjadi satu set fitur baru. Tahap ini bertujuan menangkap korelasi antarkanal yang tidak diproses pada tahap sebelumnya. Secara matematis, *pointwise convolution* dapat dituliskan sebagai:

$$P(x, y) = \sum_{m=1}^M D_m(x, y) \cdot W_m^{pw} \quad (2.6)$$

dengan:

- a. D_m adalah keluaran depthwise,
- b. W_m^{pw} adalah bobot kernel 1×1 pada kanal ke- m .

Tahap ini membentuk representasi fitur yang lebih kaya karena menggabungkan informasi dari seluruh kanal, sekaligus tetap menjaga efisiensi komputasi.

4. Kompleksitas Depthwise Separable Convolution

Perbedaan signifikan antara konvolusi biasa dan depthwise separable convolution terletak pada kompleksitas komputasi, sebagaimana diformulasikan oleh Chollet [6].

- a. Konvolusi Standar

Total operasi konvolusi standar:

$$C_{standard} = K^2 \times M \times N \quad (2.7)$$

dengan N adalah jumlah kanal keluaran.

- b. Depthwise Separable Convolution

Operasi depthwise + pointwise:

$$C_{DSC} = K^2 \times M + (M \times N) \quad (2.8)$$

Sehingga efisiensi diperoleh karena:

$$C_{DSC} \ll C_{standard} \quad (2.9)$$

Efisiensi ini sangat relevan untuk penelitian deteksi *deepfake* yang menggunakan data dalam jumlah besar dan memerlukan proses pelatihan berulang-ulang.

5. Relevansi Depthwise Separable Convolution pada Deteksi Deepfake

XceptionNet terbukti efektif untuk pendeteksian manipulasi wajah karena:

- a. Sensitif terhadap pola tekstur lokal

Artefak *deepfake* biasanya muncul pada area transisi wajah, seperti sekitar mata, hidung, dan garis rahang. *Depthwise convolution* menyoroti detail lokal ini dengan baik.

- b. Stabil pada variasi kualitas video

Variasi kompresi (contoh dari *dataset* FaceForensics++) tidak mengganggu performa secara signifikan karena struktur konvolusi XceptionNet lebih tahan terhadap *compression noise* [7].

c. Kompatibel dengan analisis frekuensi

Kombinasi kanal RGB dan kanal frekuensi (hasil FFT) membutuhkan model yang ringan namun mampu menangkap interaksi tingkat tinggi. XceptionNet cocok untuk skenario *hybrid* ini.

d. Performa tinggi di berbagai *dataset deepfake*

Banyak penelitian menunjukkan XceptionNet unggul pada dataset FF++, DFDC, dan Celeb-DF [13, 7].

e. Kemampuan representasi spasial yang kuat

Depthwise separable convolution menghasilkan fitur berlapis-lapis yang mampu memisahkan pola alami dan pola palsu pada wajah sintetis.

6. Integrasi dengan FFT sebagai Channel Tambahan

Dalam penelitian ini, fitur frekuensi hasil transformasi FFT ditambahkan sebagai kanal keempat pada input XceptionNet. *Depthwise separable convolution* sangat cocok untuk pemrosesan data multi-kanal seperti ini, karena:


- a. setiap kanal ditangani secara independen (melalui *depthwise*),
- b. setiap kanal digabungkan dalam tahap *pointwise*.

Hal ini memungkinkan arsitektur memahami hubungan antara pola spasial (RGB) dan pola frekuensi (FFT), sebagaimana juga dilakukan pada pendekatan *SpecXNet* [13] dan FSBI [16].

2.10 XceptionNet

XceptionNet (*Extreme Inception Network*) merupakan arsitektur CNN yang diperkenalkan oleh Chollet pada tahun 2017 sebagai pengembangan dari konsep *Inception Module*. Arsitektur ini dibangun berdasarkan hipotesis bahwa korelasi spasial (*cross-channel*) dan korelasi antarkanal (*cross-spatial*) dapat dipisahkan secara penuh melalui *depthwise separable convolution*, sehingga operasi konvolusi menjadi lebih efisien tanpa mengorbankan kapasitas representasi fitur [6].

2.10.1 Arsitektur XceptionNet



Gambar 2.3 Arsitektur XceptionNet [6]

Arsitektur *XceptionNet* terdiri dari 36 lapisan konvolusional yang terorganisasi dalam tiga bagian utama:

1. Entry Flow

Bagian ini berfungsi sebagai tahap awal pemrosesan yang secara progresif mereduksi dimensi spasial citra masukan sambil meningkatkan jumlah kanal fitur. *Entry flow* terdiri dari dua lapisan konvolusi biasa di awal, diikuti oleh tiga blok *separable convolution* dengan *residual connections*. Setiap blok menggunakan *max-pooling* untuk mengurangi resolusi spasial, sehingga citra masukan berukuran 299x299 secara bertahap dikompresi menjadi *feature map* berukuran lebih kecil dengan 728 kanal [6].

2. Middle Flow

Bagian ini merupakan inti dari arsitektur yang terdiri dari delapan blok *separable convolution* yang identik, masing-masing dengan tiga lapisan *depthwise separable convolution* dan *residual connection*. Seluruh blok mempertahankan dimensi spasial dan jumlah kanal (728) yang sama, sehingga fokus pemrosesan adalah pada penyempurnaan representasi fitur tanpa mengubah dimensi. Konfigurasi ini memungkinkan model

mengekstraksi pola tekstur dan detail yang sangat halus, yang relevan untuk mendeteksi artefak manipulasi wajah [6].

3. *Exit Flow*

Bagian terakhir terdiri dari satu blok *separable convolution* dengan *max-pooling* untuk reduksi dimensi akhir, diikuti oleh dua lapisan *separable convolution* tambahan yang meningkatkan jumlah kanal menjadi 2048. Setelah itu, *global average pooling* diterapkan untuk menghasilkan vektor fitur satu dimensi, yang kemudian diteruskan ke lapisan *fully connected* untuk klasifikasi [6].

Seluruh lapisan *separable convolution* dalam arsitektur ini menggunakan fungsi aktivasi ReLU dan *batch normalization*, yang membantu menstabilkan proses pelatihan dan mempercepat konvergensi model.

2.10.2 Transfer Learning pada XceptionNet

Dalam penelitian deteksi *deepfake*, *XceptionNet* umumnya digunakan dengan pendekatan *transfer learning*, yaitu memanfaatkan bobot model yang telah dilatih sebelumnya pada *dataset* berskala besar seperti ImageNet. Pendekatan ini efektif karena fitur-fitur visual dasar yang dipelajari dari ImageNet, seperti deteksi tepi, tekstur, dan pola geometris, juga relevan untuk mengenali artefak manipulasi wajah pada *deepfake* [7].

Proses *transfer learning* dilakukan dengan menginisialisasi bobot *XceptionNet* dari model *pretrained* ImageNet, kemudian melakukan *fine-tuning* pada *dataset* deteksi *deepfake*. Strategi ini memungkinkan model untuk beradaptasi dengan pola-pola spesifik artefak manipulasi tanpa memerlukan pelatihan dari awal, sehingga lebih efisien dalam hal waktu pelatihan dan kebutuhan data [6, 7].

Normalisasi *input* pada *XceptionNet* menggunakan statistik ImageNet ($mean = [0.485, 0.456, 0.406]$, $std = [0.229, 0.224, 0.225]$) untuk memastikan distribusi data masukan konsisten dengan distribusi yang digunakan selama *pretraining*. Hal ini penting agar bobot *pretrained* dapat berfungsi secara optimal pada tahap awal *fine-tuning*.

2.10.3 Keunggulan XceptionNet dalam Deteksi Deepfake

XceptionNet memiliki sejumlah keunggulan yang menjadikannya arsitektur yang sangat sesuai untuk deteksi *deepfake*:

1. Sensitivitas terhadap Pola Tekstur Lokal

Depthwise separable convolution memungkinkan *XceptionNet* menangkap pola tekstur halus secara independen pada setiap kanal, sehingga sangat efektif dalam mendeteksi artefak lokal seperti batas *blending*, distorsi tekstur kulit, dan ketidakwajaran pada area transisi wajah [4, 7].

2. Efisiensi Parameter

Dibandingkan dengan arsitektur konvolusi standar, *XceptionNet* memiliki jumlah parameter yang lebih sedikit untuk kapasitas representasi yang setara, karena pemisahan konvolusi spasial dan antarkanal mengurangi redundansi parameter secara signifikan [6].

3. Performa Tertinggi pada *Benchmark* FaceForensics++

Pada *benchmark* FaceForensics++ tanpa kompresi, *XceptionNet* mencapai akurasi deteksi 99,26% dan melampaui *ResNet-50* maupun *MesoNet*. Namun, akurasi turun ke 81,00% pada kompresi berat (c40), menunjukkan ketergantungan model pada artefak visual berfrekuensi tinggi yang rusak oleh kompresi [3, 7].

4. Stabilitas pada Variasi Kompresi

XceptionNet terbukti mempertahankan performa yang stabil pada video dengan berbagai tingkat kompresi, termasuk kompresi tinggi yang umum ditemui pada media sosial. Hal ini penting karena sebagian besar *deepfake* di dunia nyata mengalami kompresi berulang [7].

5. Kompatibilitas dengan Analisis Frekuensi

Struktur *depthwise separable convolution* sangat cocok untuk memproses *input* multi-kanal yang mencakup kanal RGB dan kanal frekuensi (FFT). Setiap kanal diproses secara independen pada tahap *depthwise*, kemudian digabungkan pada tahap *pointwise*, sehingga model dapat mempelajari interaksi antara fitur spasial dan frekuensi secara efektif [13].

6. Standar dalam Penelitian Deteksi Deepfake

XceptionNet telah diadopsi secara luas sebagai *baseline* dan *backbone* utama dalam berbagai kompetisi dan publikasi deteksi *deepfake*, termasuk *SpecXNet* [13], sehingga memudahkan perbandingan hasil dengan penelitian sebelumnya [7].

2.11 *Squeeze-and-Excitation Networks*

Dalam arsitektur *deep learning* modern, tidak semua fitur yang diekstraksi oleh lapisan konvolusional memiliki tingkat kepentingan yang sama untuk tugas klasifikasi tertentu. Beberapa kanal fitur mungkin mengandung informasi yang sangat diskriminatif, sementara

kanal lainnya mengandung *noise* atau informasi yang tidak relevan. *Squeeze-and-Excitation Networks* (SE-Net) yang diperkenalkan oleh *Hu et al.* [36] mengatasi permasalahan ini melalui mekanisme *channel attention* yang memungkinkan jaringan untuk secara adaptif mempelajari bobot kepentingan setiap kanal fitur.

2.11.1 Konsep *Channel Attention*

Channel attention merupakan mekanisme yang memberikan bobot berbeda pada setiap kanal fitur berdasarkan konten input. Berbeda dengan konvolusi standar yang memperlakukan semua kanal secara seragam, *channel attention* memungkinkan jaringan untuk secara selektif menekan (*suppress*) kanal yang tidak informatif dan memperkuat (*enhance*) kanal yang diskriminatif. Pendekatan ini terinspirasi dari mekanisme atensi selektif pada sistem visual manusia yang secara alami memfokuskan perhatian pada informasi yang paling relevan [36].

2.11.2 Arsitektur SE Block

SE block terdiri dari tiga operasi berurutan yang diterapkan pada peta fitur keluaran lapisan konvolusional:

1. ***Squeeze (Kompresi Global)***, informasi spasial dari setiap kanal fitur dikompresi menjadi satu nilai skalar melalui operasi *global average pooling*. Untuk peta fitur $\mathbf{U} \in R^{C \times H \times W}$ dengan C kanal, operasi *squeeze* menghasilkan vektor deskriptor $\mathbf{z} \in R^C$:

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (2.10)$$

Setiap elemen z_c merepresentasikan respons global dari kanal ke- c , sehingga menangkap distribusi informasi pada kanal tersebut secara keseluruhan [36].

2. ***Excitation (Pemodelan Hubungan Antar Kanal)***, vektor deskriptor $\mathbf{z}$ diproses melalui dua lapisan *fully connected* (FC) yang membentuk arsitektur *bottleneck* untuk mempelajari hubungan non-linear antar kanal:

$$\mathbf{s} = \sigma(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \cdot \mathbf{z})) \quad (2.11)$$

di mana $\mathbf{W}_1 \in R^{\frac{C}{r} \times C}$ adalah matriks bobot reduksi, $\mathbf{W}_2 \in R^{C \times \frac{C}{r}}$ adalah matriks bobot ekspansi, r adalah rasio reduksi (*reduction ratio*), dan σ adalah fungsi *sigmoid* yang menghasilkan bobot gerbang pada rentang $[0, 1]$. Rasio reduksi r mengendalikan kapasitas dan biaya komputasi, nilai r yang lebih besar mengurangi jumlah parameter dalam *bottleneck* [36].

3. **Scale (Pengalian Elemen)**, bobot gerbang s yang telah dipelajari dikalikan secara elemen-per-elemen (*element-wise*) dengan peta fitur asli:

$$\tilde{u}_c = s_c \cdot u_c \quad (2.12)$$

di mana s_c adalah bobot skalar untuk kanal ke- c dan u_c adalah peta fitur kanal ke- c . Kanal dengan bobot s_c mendekati 1 dipertahankan, sedangkan kanal dengan bobot mendekati 0 ditekan [36].

2.11.3 Relevansi SE *Block* untuk Fusi *Multi-Domain*

Dalam konteks deteksi *deepfake* berbasis pendekatan *hybrid*, SE *block* memiliki peran penting sebagai mekanisme fusi adaptif. Ketika fitur dari domain spasial (XceptionNet) dan domain frekuensi (FreqCNN) digabungkan melalui konkatenasi, vektor fusi yang dihasilkan mengandung dimensi-dimensi fitur dari kedua domain yang mungkin memiliki tingkat relevansi berbeda tergantung pada jenis manipulasi yang dihadapi.

Mekanisme SE memungkinkan model untuk:

1. Menyesuaikan kontribusi relatif kedua domain secara adaptif berdasarkan input misalnya, memberikan bobot lebih tinggi pada fitur frekuensi ketika artefak spasial sulit dideteksi, atau sebaliknya.
2. Menekan fitur yang redundan atau mengandung *noise* dari salah satu cabang, sehingga proses klasifikasi tidak terganggu oleh informasi yang tidak relevan.
3. Mengoptimalkan interaksi lintas domain, SE *block* dapat mempelajari korelasi antara fitur spasial dan frekuensi yang tidak dapat ditangkap oleh konkatenasi sederhana.

Dibandingkan dengan mekanisme fusi sederhana seperti konkatenasi atau penjumlahan (*addition*), penggunaan SE *block* sebagai gerbang adaptif telah terbukti meningkatkan performa pada arsitektur *multi-branch* karena memungkinkan model untuk secara dinamis menyesuaikan strategi fusi berdasarkan karakteristik input [36].

2.12 FaceForensics

Dataset FaceForensics++ merupakan salah satu *dataset* standar yang paling banyak digunakan dalam penelitian deteksi *deepfake* karena menyediakan kumpulan video manipulasi wajah dengan kualitas, metode pemalsuan, dan tingkat kompresi yang beragam. *Dataset* ini pertama kali diperkenalkan oleh Rössler et al. [7] sebagai pengembangan dari *dataset* sebelumnya, FaceForensics, dengan meningkatkan variasi teknik pemalsuan serta memperluas jumlah sampel agar lebih representatif terhadap karakteristik *deepfake* modern.

Dalam konteks penelitian ini, FaceForensics++ dipilih karena menyediakan kondisi pengujian yang realistis serta mencakup berbagai teknik generatif yang umum digunakan pada sistem pemalsuan wajah berbasis GAN maupun encoder–decoder.

2.12.1 Struktur dan Komposisi Dataset

FaceForensics++ terdiri dari dua komponen utama, yaitu *original videos* dan *manipulated videos*. Kumpulan video asli diambil dari rekaman wawancara publik yang menampilkan variasi ekspresi, sudut pandang, dan kondisi pencahayaan. Video ini kemudian dimanipulasi menggunakan empat teknik utama:

1. *Deepfakes*, dengan menggunakan model encoder–decoder untuk menukar wajah sumber dengan wajah target.
2. *Face2Face*, mengubah ekspresi wajah target berdasarkan gerakan wajah sumber menggunakan teknik *facial reenactment*.
3. *FaceSwap*, menggantikan wajah target menggunakan metode penyalarsan geometris dan *blending* manual.
4. *NeuralTextures*, menggunakan *neural rendering* untuk menghasilkan ekspresi wajah sintesis berbasis peta tekstur.

Variasi ini penting karena setiap teknik menghasilkan jenis artefak yang berbeda, mulai dari kesalahan *warping*, ketidakselarasan detail, *texture inconsistency*, hingga pola spektral yang tidak wajar akibat proses generatif [7].

Dataset ini juga disediakan dalam tiga tingkat kompresi:

1. RAW (*lossless*): hampir tanpa kompresi, mempertahankan struktur tekstur yang paling jelas.
2. HQ (*high-quality*): menggunakan kompresi ringan (misalnya CRF rendah).
3. LQ (*low-quality*): kompresi berat, meniru kondisi unggahan media sosial.

Pembagian kualitas ini membuat dataset sangat relevan untuk menguji robustnes model terhadap noise kompresi dan degradasi kualitas, yang umum ditemui pada deepfake di dunia nyata.

2.12.2 Karakteristik Artefak pada FaceForensics++

Setiap teknik manipulasi pada FaceForensics++ menghasilkan pola artefak yang berbeda, baik pada domain spasial maupun domain frekuensi. Hal ini membuat dataset ini sangat berguna untuk penelitian *hybrid* seperti *XceptionNet*–FFT.

1. Artefak Spasial, artefak utama yang sering muncul meliputi:

- a. ketidaksesuaian warna kulit antara wajah sintetis dan latar,
- b. tepi wajah yang tidak rapi akibat *blending* yang buruk,
- c. distorsi geometri pada bagian mata dan mulut,
- d. ketidakkonsistenan ekspresi saat *frame* berubah cepat,
- e. *blurring* lokal pada area rekonstruksi.

Penelitian sebelumnya menunjukkan bahwa artefak ini paling jelas terlihat pada area transisi wajah, sehingga algoritma deteksi perlu fokus pada *patch* wajah, bukan keseluruhan citra [4, 7].

2. Artefak Frekuensi, artefak pada domain frekuensi yang muncul karena proses generatif tidak mampu mempertahankan distribusi spektral alami (*natural image statistics*). Pengukuran energi spektral *azimuth* pada citra GAN menunjukkan kelebihan energi pada band frekuensi tinggi dibanding citra natural, beserta penguatan harmonik akibat *upsampling* yang tidak ideal [8].

3. Dalam FaceForensics++, karakteristik artefak yang muncul meliputi:

- a. spektrum frekuensi tinggi yang tidak stabil,
- b. *Face2Face* meninggalkan pola *low-frequency warping*,
- c. *NeuralTextures* memperlihatkan tekstur frekuensi tinggi yang berulang,
- d. *FaceSwap* sering menunjukkan *spectral drop-off* yang tidak konsisten.

Keberagaman artefak ini menjadikan FaceForensics++ sangat ideal untuk model *hybrid* yang menggabungkan domain spasial dan frekuensi, sebagaimana dilakukan pada penelitian ini.

2.12.3 Alasan Pemilihan FaceForensics++ untuk Penelitian Ini

Ada beberapa alasan utama mengapa dataset FaceForensics++ menjadi pilihan tepat:

1. Representasi Teknik Deepfake yang Beragam

FaceForensics++ mencakup metode manipulasi GAN dan non-GAN, sehingga model dapat mempelajari berbagai pola pemalsuan, bukan hanya satu jenis teknik. Hal ini penting agar model memiliki kemampuan generalisasi yang baik.

2. Mendukung Evaluasi Cross-Compression

Penelitian deteksi *deepfake* sering gagal pada video berkualitas rendah. Karena *dataset* ini menyediakan berbagai tingkat kompresi, maka model dapat diuji apakah tetap akurat pada kondisi *real-world* seperti yang ditemukan di media sosial.

3. Kompatibel dengan Pendekatan Spasial–Frekuensi

Dataset ini memiliki kualitas detail spasial dan spektral yang cukup baik, sehingga transformasi FFT dapat menangkap perbedaan distribusi frekuensi dengan jelas. Penelitian semacam SpecXNet dan FSBI juga menggunakan dataset ini untuk validasi [13, 16].

4. Menjadi *Benchmark* Internasional

FaceForensics++ merupakan *benchmark* yang digunakan oleh lebih dari ratusan publikasi sejak 2019, sehingga hasil penelitian menjadi mudah dibandingkan dengan pekerjaan sebelumnya.

5. Proporsional dan Seimbang

Jumlah sampel asli dan palsu yang seimbang membantu mengurangi bias pelatihan.

2.12.4 Peran FaceForensics++ dalam Sistem Hybrid XceptionNet–FFT

Dalam penelitian ini, dataset FaceForensics++ digunakan untuk dua fungsi:

1. Pelatihan Model Spasial (*XceptionNet*)

XceptionNet akan menangkap pola spasial, tekstur, dan artefak lokal pada wajah.

2. Pelatihan *Fast Fourier Transform* (FFT)

FFT diterapkan pada citra hasil preprocessing FaceForensics++, sehingga saluran frekuensi dapat menangkap:

- a. ketidakstabilan spektral,
- b. pola frekuensi tinggi yang berlebihan,
- c. anomali distribusi amplitudo.

Kedua fitur ini kemudian digabungkan sebagai *channel fusion* sehingga model mampu mendeteksi baik manipulasi visual maupun statistik spektral. Dengan demikian, FaceForensics++ menjadi *backbone* penting dalam evaluasi performa sistem hybrid pada penelitian ini.

2.13 Celeb-DF

Celeb-DF (Celebrity DeepFake) merupakan *dataset* deteksi *deepfake* berskala besar yang dikembangkan untuk mengatasi keterbatasan *dataset* generasi sebelumnya dalam hal kualitas visual manipulasi. *Dataset* ini terdiri dari video selebriti yang dimanipulasi menggunakan teknik *face swapping* berbasis *deep learning* yang menghasilkan kualitas

manipulasi yang jauh lebih tinggi dibandingkan *dataset* sebelumnya seperti FaceForensics++ [18].

2.13.1 Komposisi dan Karakteristik Dataset

Celeb-DF terdiri dari dua versi, yaitu Celeb-DF (v1) dan Celeb-DF (v2), dengan versi kedua yang lebih luas digunakan dalam penelitian. Celeb-DF (v2) mencakup 590 video asli yang diambil dari wawancara selebriti di YouTube dan 5.639 video *deepfake* yang dihasilkan menggunakan model *encoder-decoder* yang telah disempurnakan. Video-video dalam *dataset* ini memiliki variasi yang tinggi dalam hal kondisi pencahayaan, resolusi, latar belakang, dan ekspresi wajah, sehingga lebih merepresentasikan kondisi *deepfake* di dunia nyata [18].

Dibandingkan dengan FaceForensics++, Celeb-DF memiliki beberapa perbedaan penting:

1. Kualitas manipulasi yang lebih tinggi, sehingga artefak visual seperti batas *blending* dan distorsi wajah lebih sulit diamati secara kasat mata.
2. Variasi subjek yang lebih beragam, mencakup berbagai etnis, usia, dan jenis kelamin.
3. Kondisi perekaman yang lebih bervariasi, termasuk pencahayaan alami dan buatan, serta resolusi yang berbeda-beda.

2.13.2 Peran Celeb-DF dalam Evaluasi Cross-Dataset

Dalam penelitian ini, Celeb-DF digunakan sebagai *dataset* sekunder untuk mengevaluasi kemampuan *cross-dataset generalization* dari model *hybrid* yang diusulkan. Model yang dilatih pada FaceForensics++ kemudian diuji pada Celeb-DF untuk mengukur sejauh mana model mampu mendeteksi *deepfake* dari sumber dan teknik manipulasi yang berbeda. Pengujian ini penting karena menunjukkan apakah model telah mempelajari fitur-fitur manipulasi yang bersifat universal, bukan hanya artefak spesifik dari satu *dataset* tertentu [14, 36].

Celeb-DF menjadi *benchmark* yang menantang karena kualitas manipulasinya yang tinggi membuat artefak spasial sangat minimal. Oleh karena itu, kemampuan model untuk memanfaatkan informasi domain frekuensi menjadi sangat krusial ketika diuji pada *dataset* ini, karena artefak frekuensi yang bersifat algoritmik cenderung lebih stabil meskipun kualitas visual manipulasi meningkat [8].

2.14 Analisis Citra

Analisis citra merupakan proses untuk memperoleh informasi dari sebuah citra digital melalui serangkaian operasi matematis, statistik, maupun transformasi domain. Analisis citra bertujuan mengekstraksi karakteristik penting seperti bentuk, tekstur, *edge*, *noise*, maupun struktur pola tertentu. Citra digital sendiri direpresentasikan sebagai fungsi dua dimensi $f(x, y)$ yang memetakan koordinat *pixel* ke intensitas cahaya, sehingga analisis citra dapat dilakukan baik dalam domain spasial (langsung pada *pixel*) maupun domain frekuensi (melalui transformasi seperti FFT) [28].

Metode analisis citra berbasis domain spasial berfokus pada karakteristik visual yang tampak langsung, seperti konsistensi pencahayaan, *texture descriptor*, dan informasi warna pada citra digital [28]. Pada deteksi *deepfake*, pendekatan spasial digunakan untuk mengidentifikasi anomali seperti ketidaksesuaian *blending* wajah, *warping artifacts*, *detail* kulit yang tidak konsisten, atau pola *blur* tidak alami [23]. Namun, penelitian menunjukkan bahwa artefak *deepfake* modern semakin sulit dideteksi hanya dengan pendekatan spasial, karena model generatif seperti GAN telah menghasilkan citra dengan detail visual yang sangat realistis [37].

Untuk mengatasi keterbatasan tersebut, analisis citra diperluas ke domain frekuensi, yang mampu mengungkap anomali spektral yang tidak terlihat secara langsung di domain spasial. Model GAN meninggalkan pola *high-frequency artifacts* yang konsisten lintas arsitektur, terutama akibat operasi *upsampling* dan ketidakseimbangan kernel konvolusi [8]. Distribusi frekuensi yang berbeda secara signifikan dari citra asli menjadi dasar metode deteksi domain frekuensi [9]. Dengan demikian, kombinasi analisis spasial dan frekuensi memberikan pendekatan yang lebih komprehensif dalam mendeteksi manipulasi visual pada citra *deepfake*.

2.15 Analisis Video

Analisis video merupakan perluasan dari analisis citra yang mempertimbangkan tidak hanya informasi spasial dari setiap *frame*, tetapi juga hubungan temporal *antar-frame*. Video digital dapat direpresentasikan sebagai fungsi tiga dimensi $f(x, y, t)$, di mana t merupakan urutan waktu [28]. Dengan demikian, analisis video melibatkan pemrosesan *frame-level* dan dinamika pergerakan (*temporal cues*) seperti perubahan ekspresi, kontinuitas gerakan, serta konsistensi pola wajah dari satu *frame* ke *frame* berikutnya [38].

Dalam konteks deteksi *deepfake*, manipulasi umumnya dilakukan pada setiap *frame* secara terpisah, sehingga artefak manipulasi dapat dideteksi pada tingkat *frame* individual. Studi oleh Sabir et al. menunjukkan bahwa *deepfake* sering menampilkan pola-pola tidak stabil seperti *jittering*, *flickering*, dan perubahan wajah yang tidak mulus antar-*frame* [38]. Artefak-arterfak ini dapat diidentifikasi melalui analisis *frame-by-frame* yang mengekstraksi fitur spasial dan frekuensi dari setiap *frame* secara independen.

Dalam penelitian ini, pendekatan yang digunakan adalah analisis pada tingkat *frame* individual (*frame-level analysis*), di mana setiap *frame* video diekstraksi dan diproses secara terpisah menggunakan CNN untuk fitur spasial dan FFT untuk fitur frekuensi. Pendekatan *frame-level* dipilih karena artefak manipulasi yang muncul akibat proses generatif, baik pada domain spasial maupun domain frekuensi, dapat dideteksi pada setiap *frame* tunggal tanpa memerlukan informasi sekuensial antar-*frame* [3, 7]. Selain itu, pendekatan ini lebih efisien secara komputasi dan memungkinkan integrasi yang lebih langsung dengan analisis domain frekuensi berbasis FFT.

2.16 Preprocessing

Preprocessing merupakan tahap fundamental dalam sistem deteksi *deepfake* karena kualitas data masukan sangat memengaruhi kemampuan model dalam mengekstraksi fitur baik pada domain spasial melalui XceptionNet maupun pada domain frekuensi melalui Fast Fourier Transform (FFT). Pada penelitian deteksi *deepfake* modern, *preprocessing* tidak hanya berfungsi sebagai proses penyiapan data, tetapi juga sebagai cara untuk menghilangkan *noise* visual, menjaga konsistensi bentuk wajah, serta menstabilkan distribusi frekuensi sebelum dilakukan transformasi [3, 4, 8, 11, 7].

Tahap *preprocessing* yang baik sangat diperlukan karena *deepfake* sering menampilkan variasi kualitas video, tingkat kompresi berbeda, posisi wajah yang tidak seragam, serta pola artefak yang tidak konsisten antar-*frame*. Penelitian terdahulu menunjukkan bahwa ketidakseragaman ini berdampak langsung pada performa model deteksi, terutama yang memanfaatkan sinyal frekuensi tinggi yang sensitif terhadap rotasi, translasi, dan perubahan intensitas [8, 9, 16].

Oleh karena itu, *preprocessing* pada penelitian ini dirancang untuk memastikan bahwa data masukan memiliki format yang seragam, representasi wajah yang stabil, dan struktur frekuensi yang tidak terdistorsi. Alur *preprocessing* mencakup: ekstraksi *frame*, deteksi wajah, *cropping*, *resize*, normalisasi, konversi skala warna, dan transformasi FFT.

2.16.1 Tahapan dan Alur Preprocessing

1. Ekstraksi Frame Video

Video deepfake direpresentasikan sebagai rangkaian frame, dan setiap frame berpotensi mengandung tingkat manipulasi berbeda. Pendekatan frame-level digunakan karena artefak manipulasi tidak selalu muncul konsisten sepanjang video [3]. Haq menunjukkan bahwa beberapa frame menampilkan distorsi tekstur lebih jelas sehingga pemrosesan per-frame membantu model menangkap sinyal manipulasi penting.

Selain itu, pemrosesan per-frame memungkinkan analisis lebih mendetail terhadap variasi temporal, seperti flickering dan inkonsistensi ekspresi, yang merupakan ciri khas dari banyak teknik deepfake.

2. Deteksi wajah dan cropping

Bagian wajah merupakan target utama manipulasi deepfake. Penelitian MesoNet menunjukkan bahwa kesalahan *blending* dan *warping* sering muncul pada tepi wajah serta area mata, hidung, dan mulut [4]. Rössler melalui FaceForensics++ menegaskan bahwa latar belakang justru menjadi noise bila tidak dipotong [7].

Dengan membatasi analisis hanya pada area wajah, jumlah fitur yang tidak relevan dapat diminimalkan, sehingga model memiliki kapasitas lebih besar untuk mempelajari pola-pola manipulasi.

3. *Resize*

Citra kemudian di-*resize* menjadi 224×224 *pixel* agar sesuai dengan input *XceptionNet*. Penyeragaman ukuran penting untuk menjaga konsistensi pola tekstur, karena *XceptionNet* sensitif terhadap variasi struktur local [6].

Ukuran 224×224 juga dipilih karena merupakan ukuran standar *feature extractor* pada banyak arsitektur visi komputer, sehingga mempermudah integrasi dengan model pra-latih (*pretrained model*) apabila diperlukan.

4. Normalisasi *Pixel*

Normalisasi *pixel* penting karena model CNN sangat sensitif terhadap variasi intensitas cahaya, sebagaimana ditunjukkan oleh Afchar et al. [4]. Normalisasi tidak hanya meningkatkan stabilitas pelatihan, tetapi juga membantu mempercepat konvergensi model dan mengurangi risiko gradient explosion maupun gradient vanishing.

Tabel 2.4 Tahapan Preprocessing

Tahap	Operasi	Tujuan Utama	Output
-------	---------	--------------	--------

1	Ekstraksi frame	Mengubah video menjadi deretan frame	Citra per-frame
2	Deteksi wajah	Menemukan lokasi (<i>bounding box</i>) wajah	Koordinat wajah
3	<i>Cropping</i>	Memotong area wajah dari background	<i>Patch</i> wajah
4	<i>Resize 224×224</i>	Menyeragamkan resolusi	Citra 224×224
5	Normalisasi <i>pixel</i>	Menstabilkan intensitas dan kontras	Citra ternormalisasi
6	Transformasi FFT	Mengubah ke domain frekuensi	Spektrum frekuensi
7	<i>Channel fusion</i>	Menggabungkan RGB dan kanal frekuensi	Tensor 4-channel

Tahapan 1–5 membentuk preprocessing spasial, sedangkan tahapan 6-7 menghubungkannya dengan representasi frekuensi yang digunakan sebagai fitur tambahan pada model hybrid

2.16.2 Fast Fourier Transform (FFT)

Fast Fourier Transform (FFT) merupakan algoritma efisien untuk menghitung Discrete Fourier Transform (DFT), yaitu proses yang mengubah citra dari domain spasial menjadi domain frekuensi. Transformasi ini memungkinkan analisis distribusi energi frekuensi pada citra sehingga pola-pola artefak halus yang tidak terlihat pada domain spasial dapat teridentifikasi. Pada penelitian deteksi *deepfake*, FFT menjadi komponen penting karena manipulasi berbasis GAN cenderung menimbulkan ketidakwajaran sinyal frekuensi, terutama pada rentang *high-frequency* akibat proses *upsampling*, *konvolusi*, dan operasi *blending* [8, 11, 16].

Dalam konteks deteksi, informasi frekuensi menjadi sangat berharga karena generator GAN secara matematis tidak mampu mempertahankan *natural image statistics* sehingga meninggalkan *spectral fingerprint* yang khas dan konsisten.

Secara matematis, DFT dua dimensi untuk citra berukuran $M \times N$ didefinisikan sebagai:

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \cdot e^{-j \cdot 2\pi \left(\frac{u \cdot x}{M} + \frac{v \cdot y}{N} \right)} \quad (2.13)$$

dengan:

$f(x, y)$ adalah intensitas *pixel* pada koordinat (x, y) ,

$F(u, v)$ adalah representasi frekuensi pada koordinat (u, v) ,

$j = \sqrt{-1}$ adalah bilangan imajiner.

Besarnya energi frekuensi (*magnitude spectrum*) dihitung melalui:

$$|F(u, v)| = \sqrt{\{(\Re(F(u, v)))^2 + (\Im(F(u, v)))^2\}} \quad (2.14)$$

Untuk memudahkan analisis, spektrum frekuensi biasanya dilakukan *log compression*:

$$S(u, v) = \log(1 + |F(u, v)|) \quad (2.15)$$

dengan ϵ sebagai konstanta kecil untuk menghindari $\log(0)$. Selain itu, digunakan pula *frequency shifting* (*fftshift*) sehingga komponen frekuensi rendah berada di pusat tampilan spektrum:

$$F_{shift(u,v)} = F\left(\left(u + \frac{M}{2}\right) \bmod M, \left(v + \frac{N}{2}\right) \bmod N\right) \quad (2.16)$$

Transformasi ini menghasilkan representasi frekuensi yang lebih mudah ditafsirkan dan lebih stabil untuk diproses oleh model deteksi.

Deepfake berbasis GAN menghasilkan pola-pola artefak yang tidak alami pada frekuensi tinggi akibat:

1. operasi *upsampling* (*nearest-neighbor*, *transposed convolution*),
2. ketidakstabilan filter pada generator,
3. proses *blending* antara wajah asli dan hasil sintesis,
4. kompresi video berulang kali.

Pola-pola ini sulit terdeteksi pada domain spasial namun sangat jelas pada domain frekuensi. Penelitian *Durall et al.* [8] menunjukkan bahwa citra sintetis memiliki distribusi frekuensi global yang berbeda secara konsisten dibanding citra asli. Temuan tersebut diperkuat *Qian et al.* [11] yang menunjukkan bahwa generator *deepfake* tidak mampu mereplikasi *natural image statistics* pada frekuensi tinggi.

Hasil transformasi FFT berupa spektrum magnitudo dua dimensi yang merepresentasikan distribusi energi frekuensi pada citra. Spektrum ini kemudian dikonversi menjadi satu kanal intensitas (*single-channel representation*) agar kompatibel dengan arsitektur CNN konvensional. Kanal frekuensi yang dihasilkan terutama menonjolkan pola-pola energi pada rentang frekuensi tinggi yang berkaitan dengan artefak generatif pada citra *deepfake*.

Dalam penelitian ini, FFT diterapkan pada citra hasil *cropping* dan *preprocessing* spasial, kemudian dikonversi ke skala log dan dinormalisasi. Representasi frekuensi

kemudian digabungkan sebagai *frequency channel* tambahan bersama citra RGB. Pendekatan *hybrid* ini memungkinkan model mempelajari pola manipulasi baik pada domain spasial melalui *XceptionNet* maupun pada domain frekuensi melalui spektrum FFT.

Sabir et al. [38] menemukan bahwa sinyal frekuensi tinggi lebih efektif dalam membedakan *deepfake* terkompresi tinggi, sedangkan *Wang et al.* [9] menunjukkan bahwa penggunaan informasi frekuensi meningkatkan *robustness* model terhadap variasi kualitas video. Oleh karena itu, integrasi FFT ke dalam *preprocessing* dianggap penting untuk meningkatkan akurasi dan stabilitas sistem deteksi pada penelitian ini. Maka dari itu, penelitian ini menambahkan informasi Frekuensi ke dalam informasi citra sebagai *channel* 4 yang akan membawa informasi mengenai penyebaran frekuensi.

Pemilihan FFT dalam penelitian ini didasarkan pada sifatnya yang mampu menangkap distribusi spektral global secara komprehensif dengan kompleksitas komputasi yang rendah. Dibandingkan metode frekuensi lain seperti DCT atau *Discrete Wavelet Transform* (DWT), FFT memberikan representasi frekuensi penuh yang lebih sesuai untuk mendeteksi pola artefak GAN yang bersifat global *spectral shift* seperti yang diidentifikasi oleh *Durall et al.* [8] dan *Qian et al.* [11]. Dengan demikian, FFT menjadi pilihan yang efektif dan efisien untuk dikombinasikan dengan model CNN berbasis spasial.

2.17 Optimasi Model

Pelatihan model *deep learning* memerlukan algoritma optimasi yang efisien untuk meminimalkan *loss function* dan memperbarui parameter jaringan secara iteratif. Dalam konteks deteksi *deepfake*, pemilihan metode optimasi yang tepat sangat penting karena model harus dilatih pada *dataset* besar dengan variasi kualitas citra dan jenis manipulasi yang beragam [39].

2.17.1 Stochastic Gradient Descent dan Perkembangannya

Stochastic Gradient Descent (SGD) merupakan metode optimasi dasar yang memperbarui parameter model menggunakan estimasi gradien dari *mini-batch* data, sehingga lebih efisien dibandingkan *full-batch gradient descent* pada *dataset* besar. Pembaruan parameter pada SGD dilakukan dengan:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \ell(f(x; \theta_t), y) \quad (2.17)$$

di mana η adalah *learning rate* [40, 39]. Namun, SGD memiliki kelemahan berupa sensitivitas tinggi terhadap pemilihan *learning rate* dan kecenderungan osilasi pada

permukaan *loss* yang tidak seragam. Untuk mengatasi keterbatasan tersebut, dikembangkan berbagai metode optimasi adaptif yang mengatur *learning rate* secara otomatis per parameter [41].

2.17.2 AdamW (*Decoupled Weight Decay Regularization*)

Adam (*Adaptive Moment Estimation*) merupakan metode optimasi yang menggabungkan konsep *momentum* dan *adaptive learning rate* dari RMSprop. Adam menghitung estimasi momen pertama (rata-rata gradien) dan momen kedua (rata-rata kuadrat gradien) untuk setiap parameter, kemudian menggunakan estimasi tersebut untuk menyesuaikan langkah pembaruan secara individual [42].

Persamaan pembaruan Adam adalah:

1. Estimasi momen pertama:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2.18)$$

2. Estimasi momen kedua:

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2.19)$$

3. Koreksi bias:

$$\widehat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (2.20)$$

dan

$$\widehat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (2.21)$$

4. Pembaruan parameter:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\widehat{v}_t} + \epsilon} \widehat{m}_t \quad (2.22)$$

di mana β_1 dan β_2 adalah koefisien peluruhan momen (umumnya $\beta_1 = 0.9$, $\beta_2 = 0.999$), dan ϵ adalah konstanta stabilitas numerik [42].

AdamW merupakan varian dari Adam yang diperkenalkan oleh Loshchilov dan Hutter [43] dengan mekanisme *decoupled weight decay*. Berbeda dengan implementasi *weight decay* pada Adam standar yang menambahkan regularisasi L2 ke gradien sebelum penskalaan adaptif, AdamW menerapkan *weight decay* secara langsung pada bobot setelah langkah pembaruan Adam. Perbedaan ini memastikan bahwa efek regularisasi konsisten untuk semua parameter, tidak bergantung pada *learning rate* adaptif masing-masing parameter. Dalam skenario *transfer learning*, di mana parameter *pretrained* dan parameter baru memiliki skala gradien yang sangat berbeda, konsistensi ini sangat penting untuk menjaga stabilitas pelatihan.

2.17.3 Keunggulan AdamW untuk Deteksi Deepfake

AdamW dipilih dalam penelitian ini sebagai metode optimasi utama karena beberapa alasan:

1. *Adaptive learning rate* per parameter memungkinkan konvergensi yang lebih stabil pada arsitektur *hybrid* yang memiliki parameter dengan skala gradien yang berbeda antara *branch* spasial dan frekuensi.
2. Koreksi bias pada momen pertama dan kedua membuat AdamW efektif bahkan pada tahap awal pelatihan ketika estimasi momen masih tidak akurat.
3. AdamW mengimplementasikan *decoupled weight decay* secara native, sehingga regularisasi lebih konsisten dan efektif pada arsitektur *hybrid* dengan parameter *pretrained* dan baru.
4. Dalam praktik pelatihan model deteksi *deepfake*, Adam telah terbukti menghasilkan konvergensi yang cepat dan stabil pada berbagai arsitektur CNN, termasuk *XceptionNet* [7].

2.17.4 Binary Cross-Entropy sebagai Fungsi Loss

Dalam deteksi *deepfake*, tugas klasifikasi bersifat biner, yaitu membedakan citra asli (*real*) dan citra hasil manipulasi (*fake*). Fungsi *loss* yang digunakan adalah *Binary Cross-Entropy with Logits* (BCEWithLogitsLoss), yang menggabungkan fungsi *sigmoid* dan *binary cross-entropy* dalam satu operasi yang stabil secara numerik:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(\sigma(z_i)) + (1 - y_i) \cdot \log(1 - \sigma(z_i))] \quad (2.23)$$

di mana z_i adalah *logit* keluaran model, $\sigma(z)$ adalah fungsi *sigmoid*, dan $y_i \in \{0,1\}$ adalah label kelas (0 untuk asli, 1 untuk palsu). Fungsi *loss* ini memastikan bahwa model dioptimalkan untuk menghasilkan probabilitas yang akurat dalam membedakan konten asli dan palsu [39].

2.18 Metrik Evaluasi Model

Evaluasi kinerja model merupakan tahap krusial dalam pengembangan sistem deteksi *deepfake*. Melalui proses evaluasi, peneliti dapat menilai sejauh mana model mampu membedakan citra asli dan citra hasil manipulasi, serta mengidentifikasi kelemahan model ketika dihadapkan pada variasi distribusi data atau skenario *cross-dataset*. Hal ini penting

karena model generatif modern seperti GAN dan variannya terus menghasilkan konten dengan kualitas semakin realistis sehingga semakin sulit dibedakan secara visual [8, 9, 14].

Pada penelitian ini, metrik evaluasi yang digunakan meliputi *Confusion Matrix*, *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Seluruh metrik dihitung berdasarkan hubungan antara hasil prediksi model dan kelas sebenarnya pada data uji.

2.18.1 Confusion Matrix

Confusion matrix merupakan representasi berbentuk tabel yang menggambarkan performa model klasifikasi dengan membandingkan hasil prediksi dengan kondisi aktual. Melalui matriks ini, dapat terlihat jenis kesalahan apa yang dilakukan model serta apakah model lebih cenderung melakukan *false alarm* (FP) atau justru meloloskan *deepfake* (FN), yang berpotensi menimbulkan risiko keamanan signifikan [14, 15].

Tabel 2.5 Struktur Confusion Matrix

	Prediksi: Palsu	Prediksi: Asli
Aktual: Palsu	True Positive (TP)	False Negative (FN)
Aktual: Asli	False Positive (FP)	True Negative (TN)

Keterangan:

1. TP: Model benar mendeteksi *deepfake*.
2. TN: Model benar mendeteksi konten asli.
3. FP: Konten asli salah diklasifikasikan sebagai *deepfake* (*false alarm*).
4. FN: *Deepfake* gagal terdeteksi (paling berbahaya).

2.18.2 Accuracy

Accuracy mengukur seberapa besar proporsi prediksi model yang benar terhadap seluruh data.

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)} \quad (2.24)$$

Meskipun sederhana dan umum digunakan, akurasi tidak selalu memberikan gambaran yang representatif, terutama pada *dataset* yang tidak seimbang (misalnya jika jumlah citra asli lebih banyak daripada citra palsu). Pada penelitian *deepfake*, hal ini sering terjadi karena *dataset* asli umumnya memiliki distribusi lebih besar [14].

2.18.3 Precision

Precision mengukur ketepatan model dalam memberikan label “palsu”. Nilai ini menunjukkan seberapa banyak prediksi *deepfake* yang benar-benar merupakan *deepfake*.

$$Precision = \frac{TP}{(TP+FP)} \quad (2.25)$$

Nilai *precision* yang tinggi menunjukkan bahwa model jarang memberikan *false accusation* terhadap citra asli. Hal ini sangat penting pada skenario forensik digital, keamanan media, maupun investigasi yang tidak mengizinkan kesalahan dalam menandai konten asli sebagai palsu [14, 15].

2.18.4 Recall

Recall menunjukkan kemampuan model mendeteksi seluruh *deepfake* yang ada pada data uji.

$$Recall = \frac{TP}{TP+FN} \quad (2.26)$$

Nilai *recall* yang tinggi berarti model jarang meloloskan *deepfake*. Mengingat *deepfake* sering menampilkan artefak halus yang sulit dikenali secara visual [8, 9], *recall* menjadi metrik penting untuk memastikan tidak ada manipulasi berbahaya yang lolos dari pendeteksian.

2.18.5 F1-Score

F1-Score adalah rata-rata harmonik dari *Precision* dan *Recall*, dan digunakan untuk memberikan penilaian yang lebih stabil ketika terjadi ketidakseimbangan antara jumlah data asli dan palsu atau ketika *Precision* dan *Recall* tidak seimbang.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2.27)$$

Dalam penelitian *deepfake*, F1-Score sering dipilih sebagai metrik utama karena lebih mencerminkan performa realistis model pada kondisi data yang kompleks dan tidak seimbang [14, 16].

2.18.6 AUC (Area Under the ROC Curve)

AUC (*Area Under the Curve*) merupakan metrik evaluasi yang mengukur kemampuan model dalam membedakan dua kelas (asli dan palsu) secara keseluruhan, tanpa bergantung pada satu nilai *threshold* tertentu. AUC dihitung berdasarkan *ROC Curve* (*Receiver*

Operating Characteristic), yaitu kurva yang menggambarkan hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate* (FPR) pada berbagai nilai *threshold* klasifikasi.

True Positive Rate (TPR), yang identik dengan *Recall*, dihitung sebagai:

$$TPR = \frac{TP}{TP+FN} \quad (2.28)$$

Sedangkan *False Positive Rate* (FPR) dihitung sebagai:

$$FPR = \frac{FP}{FP+TN} \quad (2.29)$$

ROC Curve dihasilkan dengan memplot TPR terhadap FPR pada setiap kemungkinan nilai *threshold*. Model yang sempurna menghasilkan kurva yang mendekati sudut kiri atas grafik (TPR = 1, FPR = 0), dengan nilai AUC mendekati 1.0. Sebaliknya, model acak menghasilkan garis diagonal dengan AUC = 0.5.

AUC memiliki keunggulan penting dalam evaluasi deteksi *deepfake*:

1. *Threshold-independent*: AUC mengevaluasi performa model pada seluruh rentang *threshold*, sehingga memberikan gambaran yang lebih komprehensif dibanding metrik yang bergantung pada satu *threshold* tertentu seperti *accuracy* atau *precision* [14].
2. Stabil pada *dataset* tidak seimbang: AUC tidak terpengaruh oleh proporsi kelas dalam *dataset*, sehingga lebih andal ketika jumlah citra asli dan palsu tidak seimbang.
3. Standar evaluasi *cross-dataset*: Dalam skenario *cross-dataset generalization*, AUC menjadi metrik utama karena mampu menunjukkan kemampuan diskriminasi model secara keseluruhan, terlepas dari distribusi data uji yang mungkin berbeda dari data pelatihan [16, 12].

Dalam penelitian ini, AUC digunakan sebagai metrik utama untuk pemilihan model terbaik selama proses pelatihan, karena kemampuannya dalam memberikan evaluasi yang *robust* dan tidak bergantung pada pemilihan *threshold* tertentu.

2.18.7 Perhitungan Metrik Evaluasi

Untuk memberikan gambaran yang lebih jelas mengenai proses evaluasi model deteksi *deepfake*, berikut disajikan contoh perhitungan menggunakan nilai *True Positive* (TP), *False Positive* (FP), *True Negative* (TN), dan *False Negative* (FN). Contoh ini bersifat ilustratif dan tidak berasal dari hasil eksperimen penelitian.

Untuk menghitung total sampel (N), dapat digunakan persamaan dibawah:

$$N = TP + TN + FP + FN \quad (2.30)$$

Misalkan sebuah model deteksi menghasilkan:

TP = 180 $\rightarrow$ *deepfake* yang benar terdeteksi sebagai palsu

FP = 20 → konten asli yang *salah* diklasifikasikan sebagai palsu

TN = 160 → konten asli yang benar terdeteksi sebagai asli

FN = 40 → *deepfake* yang gagal terdeteksi (*missed detection*)

Untuk menghitung total sampel (N):

$$\begin{aligned} N &= TP + TN + FP + FN \\ &= 180 + 160 + 20 + 40 \\ &= 400 \end{aligned}$$

1. Menghitung *Accuracy*

Accuracy menghitung proporsi prediksi yang benar dari seluruh data:

$$\begin{aligned} Accuracy &= \frac{(TP + TN)}{TP + TN + FP + FN} \\ &= \frac{(180 + 160)}{400} \\ &= \frac{340}{400} \\ &= 0.85 \rightarrow 85\% \end{aligned}$$

Interpretasi dari contoh perhitungan *Accuracy* diatas adalah, model berhasil menghasilkan prediksi yang benar pada 85% kasus.

2. Menghitung *Precision*

Precision mengukur ketepatan prediksi "palsu" model:

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} \\ &= \frac{180}{180 + 20} \\ &= \frac{180}{200} \\ &= 0.90 \rightarrow 90\% \end{aligned}$$

Interpretasi dari contoh perhitungan *Precision* diatas adalah, model berhasil menyatakan video *deepfake* yang merupakan *video deepfake* dengan tingkatan ketepatan 90%.

Kesimpulan, semakin tinggi precision maka semakin kecil resiko *false accusation*.

3. Menghitung *Recall* (Sensitivitas)

Recall mengukur kemampuan model dalam menangkap seluruh *deepfake*:

$$\begin{aligned} Recall &= \frac{TP}{TP + FN} \\ &= \frac{180}{180 + 40} \end{aligned}$$

$$= \frac{180}{220}$$

$$= 0.818 \rightarrow 81.8\%$$

Interpretasi dari contoh perhitungan *Recall* diatas adalah, model berhasil mendeteksi 81.8% *deepfake* yang ada. Perhitungan *Recall* digunakan untuk menghitung tingkat kelolosan video *deepfake*.

4. Menghitung *F1-Score*

F1-Score adalah rata-rata harmonik *Precision* dan *Recall*:

$$F1 - Score = 2 \times \frac{(Precision \times Recall)}{Precision + Recall}$$

$$= 2 \times \frac{(0.90 \times 0.818)}{0.90 + 0.818}$$

$$= 2 \times \frac{0.7362}{1.718}$$

$$= \frac{1.4724}{1.718}$$

$$= 0.857 \rightarrow 85.7\%$$

Interpretasi dari contoh perhitungan *F1-Score* diatas adalah, model memiliki nilai 85.7% dalam kemampuannya untuk menghindari *false positive* dan *false negative*.

Tabel 2.6 Ringkasan Hasil Perhitungan Metrik

Metrik	Rumus	Hasil
Accuracy	$\frac{(TP + TN)}{TP + TN + FP + FN}$	85%
Precision	$\frac{TP}{TP + FP}$	90%
Recall	$\frac{TP}{TP + FN}$	81.8%
F1-Score	$2 \times \frac{(Precision \times Recall)}{Precision + Recall}$	85.7%

Berdasarkan hasil perhitungan, model menunjukkan performa yang baik dengan tingkat ketelitian tinggi dalam mendeteksi *deepfake* (*Precision* = 90%). Meskipun demikian, masih terdapat *deepfake* yang tidak terdeteksi (*Recall* = 81.8%). Nilai *F1-Score* (85.7%)

mengindikasikan bahwa model mampu mempertahankan keseimbangan antara menghindari *false positive* dan *false negative*.

Dengan demikian, model berada dalam kategori performa baik, tetapi peningkatan pada aspek recall tetap diperlukan, terutama untuk mencegah *deepfake* lolos dari sistem deteksi, sebagaimana direkomendasikan dalam studi-studi terkini [14, 16, 12].

2.18.8 Relevansi Metrik Evaluasi terhadap Penelitian Deepfake

Dalam konteks penelitian deteksi *deepfake* berbasis pendekatan *hybrid FFT + XceptionNet*, penggunaan metrik evaluasi tidak hanya menjadi alat ukur performa, tetapi juga indikator penting untuk menilai kemampuan generalisasi dan ketahanan model ketika diuji pada manipulasi generatif yang semakin kompleks. Hal ini relevan karena model *deepfake* modern berbasis GAN mampu menghasilkan konten dengan kualitas sangat realistis, sehingga membuat proses pendeteksian menjadi jauh lebih menantang [8, 9, 14].

1. *Accuracy* memberikan gambaran umum terhadap tingkat keberhasilan prediksi model. Namun, pada kasus *deepfake*, akurasi perlu ditafsirkan hati-hati, terutama ketika *dataset* tidak seimbang atau memiliki variasi kualitas manipulasi yang berbeda-beda [14].
2. *Precision* menjadi metrik penting untuk meminimalkan *false positive*, yaitu kondisi ketika konten asli secara keliru diklasifikasikan sebagai palsu. Hal ini penting pada aplikasi seperti forensik digital dan keamanan media, di mana kesalahan dalam menandai konten asli sebagai *deepfake* dapat menimbulkan konsekuensi serius [14, 15].
3. *Recall* mengukur kemampuan model dalam mendeteksi seluruh *deepfake* yang ada. Nilai *recall* sangat krusial karena banyak *deepfake* yang mengandung artefak halus pada domain frekuensi tinggi, yang sering kali sulit diamati langsung pada domain spasial [8, 11, 16]. Oleh karena itu, *recall* menjadi indikator penting dalam memastikan bahwa *deepfake* berkualitas tinggi tidak lolos dari pendeteksian.
4. *F1-Score*, sebagai *harmonic mean* antara *Precision* dan *Recall*, memberikan penilaian yang lebih stabil ketika kedua metrik tersebut tidak seimbang. Pada penelitian *deepfake*, kondisi ini sering terjadi karena *dataset* biasanya mengandung variasi kualitas citra dan beragam jenis teknik manipulasi [14, 16, 12].

Selain itu, *Confusion Matrix* digunakan untuk memperoleh gambaran menyeluruh mengenai pola kesalahan prediksi model, apakah model lebih cenderung menghasilkan *false alarm* (FP) atau melewatkan *deepfake* (FN). Analisis ini sangat penting terutama pada

skenario *cross-dataset* dan cross-GAN, di mana distribusi data uji berbeda dari data pelatihan [12, 20].

Secara keseluruhan, kombinasi metrik evaluasi tersebut memberikan pemahaman komprehensif mengenai performa pendekatan hybrid *FFT* + *XceptionNet*, termasuk kemampuan model untuk tetap *robust*, *stabil*, dan *adaptif* terhadap variasi jenis deepfake. Hal ini sejalan dengan berbagai penelitian yang menekankan pentingnya detektor yang mampu menangkap petunjuk spasial dan frekuensi secara bersamaan untuk meningkatkan generalisasi pada dataset dan model generatif yang berbeda [11, 16, 17, 23].

2.19 Cross Dataset Generalization

Cross-dataset generalization merupakan konsep penting dalam penelitian deteksi *deepfake* yang menggambarkan kemampuan sebuah model untuk mempertahankan performa ketika diuji pada dataset yang berbeda dari *dataset* pelatihan. Konsep ini muncul sebagai respons terhadap fakta bahwa *deepfake* di lingkungan nyata sering kali memiliki karakteristik yang sangat berbeda dengan dataset benchmark yang umum digunakan dalam penelitian akademik. *Rössler et al.* menunjukkan bahwa dataset seperti FaceForensics++ hanya mencakup jenis manipulasi wajah tertentu dengan kondisi visual yang relatif seragam [7]. Karena itu, model yang dilatih pada *dataset* tunggal cenderung mengalami penurunan akurasi secara signifikan ketika diuji pada dataset lain yang memiliki distribusi data berbeda.

Dalam konteks deteksi *deepfake*, tantangan *cross-dataset* terutama disebabkan oleh fenomena domain *shift*. Domain *shift* terjadi ketika model menemukan pola visual atau statistik baru yang tidak muncul pada dataset pelatihan. Bentuk domain *shift* dapat berupa variasi kualitas video, tingkat kompresi, perangkat perekaman, kondisi pencahayaan, hingga teknik manipulasi generatif yang berbeda [8]. *Zhang et al.* juga menegaskan bahwa setiap metode generatif berbasis GAN menghasilkan artefak sintesis yang memiliki pola distribusi berbeda, sehingga membuat model berbasis fitur spasial saja mudah terjebak pada *dataset-specific artifacts* [9].

Penelitian-penelitian modern menunjukkan bahwa pendekatan berbasis domain frekuensi cenderung memiliki kemampuan generalisasi lebih baik dibanding fitur spasial murni. *Durall et al.* menemukan bahwa sebagian besar model GAN gagal mereplikasi *natural spectral statistics*, sehingga muncul pola spektral yang konsisten pada berbagai jenis deepfake, terlepas dari dataset asal [8]. *Qian et al.* memperkuat temuan tersebut dengan menunjukkan bahwa petunjuk frekuensi tinggi biasanya bersifat lebih stabil terhadap variasi

domain, sehingga model yang mengeksploitasi sinyal frekuensi mampu mendeteksi manipulasi pada *dataset unseen* lebih baik [11]. *Hasanaath et al.* juga membuktikan bahwa penggunaan fitur frekuensi eksplisit meningkatkan robustnes model terhadap kompresi dan *noise* yang bervariasi antar *dataset* [16].

Sebaliknya, pendekatan berbasis CNN murni pada domain spasial umumnya sangat sensitif terhadap distribusi tekstur dataset pelatihan. *Afchar et al.* dan *Chollet* menunjukkan bahwa CNN secara alami mempelajari pola spasial lokal yang bergantung pada tekstur permukaan, sehingga performanya dapat menurun pada dataset yang memiliki karakteristik visual berbeda [4, 6]. Temuan ini menjelaskan mengapa model deteksi *deepfake* berbasis fitur spasial sering gagal melakukan generalisasi lintas dataset, terutama ketika menghadapi variasi kualitas video atau teknik manipulasi baru.

Oleh karena itu, dalam kajian literatur terkini, kemampuan *cross-dataset generalization* menjadi indikator utama kualitas model deteksi *deepfake* modern. Penelitian seperti *SpecXNet* [13] dan *FSBI* [16] menunjukkan bahwa model *hybrid* yang menggabungkan domain spasial dan domain frekuensi memiliki performa generalisasi lebih baik dibanding model berbasis domain tunggal. Hal ini disebabkan oleh sifat pelengkap kedua domain: domain spasial menangkap anomali tekstur dan struktur wajah, sementara domain frekuensi menangkap artefak spektral yang lebih universal antar dataset.

Secara keseluruhan, konsep *cross-dataset generalization* menegaskan bahwa deteksi *deepfake* tidak dapat bergantung pada pola *dataset* tertentu, tetapi harus mampu mengidentifikasi karakteristik manipulasi yang bersifat umum dan stabil. Oleh karena itu, banyak penelitian terkini mengarah pada integrasi fitur spasial dan frekuensi untuk memperoleh representasi fitur yang lebih robust terhadap perbedaan distribusi data antar dataset [8, 13, 11].

2.20 Cross-GAN pada Deteksi Deepfake

Dalam konteks deteksi *deepfake*, *Cross-GAN* merujuk pada skenario ketika model deteksi dilatih menggunakan sampel *deepfake* yang dihasilkan oleh satu jenis arsitektur/model GAN tertentu, tetapi kemudian diuji pada *deepfake* yang dihasilkan oleh GAN/teknik generatif lain (misalnya arsitektur generator berbeda, proses *upsampling* berbeda, atau pipeline manipulasi berbeda). Tujuan evaluasi *Cross-GAN* adalah mengukur kemampuan generalisasi detektor terhadap variasi metode generatif yang tidak terlihat saat

pelatihan (*unseen manipulations*), karena di dunia nyata jenis *deepfake* baru terus berkembang dan tidak selalu tersedia datanya untuk dilatih terlebih dahulu [14, 15, 19].

Secara praktis, *Cross-GAN* sering dibahas bersama skenario *cross-dataset*, karena perbedaan GAN biasanya juga beriringan dengan perbedaan *dataset*, kualitas kompresi, resolusi, serta kondisi pengambilan video. *Dataset* seperti FaceForensics++ banyak digunakan untuk menguji *robustness* model pada variasi manipulasi dan kompresi, namun generalisasi lintas-metode generasi tetap menjadi tantangan utama [7].

2.20.1 Faktor Penyebab Kesulitan Generalisasi *Cross-GAN*

Kesulitan utama *Cross-GAN* muncul karena banyak detektor “belajar” menangkap artefak spesifik dari metode generasi tertentu, bukan ciri manipulasi yang bersifat umum. Ketika GAN/*pipeline* generatif berubah, pola artefaknya juga berubah sehingga model yang terlalu “spesialis” mudah gagal. Beberapa penyebab pentingnya:

1. Perbedaan artefak *upsampling* dan interpolasi

Banyak generator berbasis CNN menggunakan operasi *upsampling* (misalnya *transposed convolution*) yang dapat memunculkan pola khas seperti *checkerboard artifacts*. Artefak ini bisa menjadi “*shortcut*” yang dipelajari detektor, padahal pola tersebut dapat berbeda antar arsitektur generator [8, 21].

2. Perbedaan distribusi spektral (domain frekuensi)

Studi menunjukkan bahwa model generatif sering gagal mereplikasi distribusi spektral citra alami secara konsisten, sehingga muncul anomali tertentu pada komponen frekuensi (terutama frekuensi tinggi). Namun, bentuk anomali ini bisa bervariasi antar GAN, sehingga detektor yang hanya mengandalkan pola spektral “versi tertentu” dapat melemah pada *Cross-GAN* [8, 9, 24].

3. *Shortcut learning* pada petunjuk non-semantik

Detektor berbasis CNN (mis. XceptionNet atau arsitektur ringkas seperti MesoNet) dapat sangat kuat pada data pelatihan, tetapi berisiko memanfaatkan petunjuk non-semantik (kompresi, *noise* spesifik, tekstur tertentu) yang tidak stabil lintas GAN [3, 4, 6, 14].

2.20.2 Indikator Evaluasi *Cross-GAN*

Evaluasi *Cross-GAN* umumnya dilakukan dengan protokol:

1. *Train* pada *deepfake* dari satu/sekumpulan GAN atau metode manipulasi
2. *Test* pada *deepfake* dari GAN/metode lain yang tidak ada di-*train*,

Lalu membandingkan metrik (akurasi, AUC, F1) untuk melihat penurunan performa akibat *domain shift* [14, 15]. Jika penurunan performa besar, artinya model cenderung *overfit* pada artefak spesifik generator dan belum *robust* untuk penggunaan nyata.

2.20.3 Pendekatan untuk Meningkatkan Generalisasi *Cross-GAN*

Tantangan utama dalam skenario *Cross-GAN* adalah ketidakmampuan model deteksi untuk mempertahankan performa ketika dihadapkan pada *deepfake* yang dihasilkan oleh metode generatif yang berbeda dari data pelatihan. Hal ini terjadi karena banyak model cenderung mempelajari artefak spesifik dari satu jenis GAN, bukan karakteristik manipulasi wajah yang bersifat umum. Oleh karena itu, berbagai penelitian mengusulkan pendekatan yang berfokus pada pengurangan ketergantungan terhadap artefak generator tertentu dan peningkatan *robustness* fitur terhadap perubahan metode generasi [14, 15]

Pendekatan-pendekatan berikut merupakan strategi utama yang umum digunakan dalam literatur untuk meningkatkan generalisasi deteksi *deepfake* pada skenario *Cross-GAN*.

1. Pembelajaran berbasis domain frekuensi (*Frequency-Aware Learning*)

Karena proses generasi sering meninggalkan jejak pada spektrum (misalnya akibat *upsampling* atau interpolasi), beberapa pendekatan mengekstraksi fitur FFT/DCT atau mempelajari representasi di ruang frekuensi untuk meningkatkan generalisasi. Ide dasarnya adalah fitur frekuensi tertentu lebih stabil sebagai indikator manipulasi dibanding sinyal spasial mentah yang mudah berubah antar GAN [8, 11, 23, 10]. Pendekatan yang lebih baru juga menekankan pembelajaran yang eksplisit mengarah pada *generalizability* melalui pembelajaran ruang frekuensi [23], serta integrasi *masking*/interaksi spasial untuk mengurangi ketergantungan pada petunjuk semu [17].

2. Arsitektur *dual-domain* (spasial + frekuensi)

Untuk mengatasi kelemahan detektor spasial murni, pendekatan *dual-domain* memadukan fitur CNN dari citra/*frame* (spasial) dengan fitur frekuensi (misalnya FFT) agar model memperoleh informasi komplementer. Model seperti SpecXNet menekankan fusi *dual-domain* untuk ketahanan yang lebih baik pada variasi *deepfake*, termasuk skenario generalisasi [13, 11].

3. Memanfaatkan *discriminator* GAN atau prinsip *adversarial*

Sejumlah penelitian mengeksplorasi penggunaan diskriminator (atau karakteristik yang mirip diskriminator) karena diskriminator secara alami dilatih membedakan *real vs fake*

pada proses generasi. Namun, kemampuan generalisasi tetap bergantung pada variasi data dan stabilitas fitur yang dipakai [14, 20].

4. Fitur *temporal* dan *temporal-frequency* untuk video

Pada video *deepfake*, perbedaan antar *frame* (mis. inkonsistensi gerakan halus, perubahan tekstur antar *frame*) dapat menjadi petunjuk yang lebih sulit “disamarkan” oleh generator tertentu. Pendekatan berbasis *temporal* atau *temporal-frequency* mencoba menangkap pola periodik/perubahan waktu yang bisa membantu generalisasi pada *deepfake* video lintas metode [25].

2.20.4 Relevansi *Cross-GAN* terhadap Penelitian Ini

Pembahasan *Cross-GAN* penting karena sistem deteksi *deepfake* yang dipakai di dunia nyata harus mampu menghadapi metode generatif baru. Detektor yang hanya kuat pada satu jenis GAN berisiko gagal ketika penyerang mengganti arsitektur generator atau strategi *upsampling*. Oleh karena itu, banyak penelitian mengarah pada fitur yang lebih general (misalnya domain frekuensi, *dual-domain*, serta fitur temporal) untuk meningkatkan *robustness* dan generalisasi [13, 14, 15, 11, 23].

2.21 Dasar Pemilihan Metode

Semakin canggihnya model generatif dalam menghasilkan video dan citra *deepfake* yang hampir tidak dapat dibedakan secara visual dari data asli, pemilihan metode deteksi yang tepat menjadi faktor krusial dalam penelitian ini. Pendekatan spasial umumnya berfokus pada analisis fitur visual langsung (seperti tekstur, warna, dan tepi wajah), sementara pendekatan frekuensi berfokus pada identifikasi artefak matematis yang muncul akibat proses sintesis citra oleh model GAN.

Dalam penelitian ini, digunakan dua metode utama, yaitu FFT sebagai representasi domain frekuensi, dan *XceptionNet* sebagai model ekstraksi fitur spasial. Kedua metode ini dipilih karena telah terbukti unggul secara empiris dalam berbagai penelitian sebelumnya, khususnya dalam aspek akurasi deteksi, efisiensi komputasi, serta kemampuan generalisasi terhadap jenis *deepfake* baru yang belum pernah digunakan dalam proses pelatihan (*cross-dataset robustness*).

Berdasarkan kajian tersebut, terlihat bahwa sebagian besar penelitian terdahulu masih memisahkan pendekatan spasial dan frekuensi, atau hanya menggunakan salah satu di antaranya sebagai fitur tambahan. Penelitian ini berupaya mengisi *research gap* tersebut

dengan merancang model *hybrid* yang secara eksplisit menggabungkan representasi frekuensi dari FFT dan fitur spasial dari *XceptionNet* dalam satu kerangka kerja deteksi *deepfake*, sehingga diharapkan mampu meningkatkan akurasi dan kemampuan generalisasi lintas *dataset*.

2.21.1 Pemilihan Transformasi FFT dalam Deteksi Deepfake

Pendekatan berbasis FFT dipilih karena mampu mendeteksi artefak yang tidak terlihat secara visual di domain spasial, tetapi muncul sebagai pola khas di domain frekuensi. *Durall et al*, menjelaskan bahwa proses *upsampling* pada model *Generative Adversarial Networks* (GAN) menghasilkan distribusi spektrum yang tidak alami akibat terjadinya replikasi spektral atau duplikasi pola frekuensi yang menciptakan *spectral distortion* pada citra sintetis [8]. Pola ketidaksempurnaan tersebut menghasilkan jejak digital yang dikenal sebagai GAN *fingerprints*, yaitu pola periodik khas dari proses sintesis yang tidak ditemukan pada citra asli [9].

Metode FFT memiliki keunggulan dibanding transformasi lain seperti *Discrete Cosine Transform* (DCT) dan *Wavelet Transform*. FFT memiliki kompleksitas komputasi rendah ($O(n \log n)$) sehingga efisien untuk citra beresolusi tinggi [8]. Berbeda dari DCT yang bekerja per blok atau *Wavelet* yang memerlukan dekomposisi multiresolusi, FFT menganalisis spektrum frekuensi secara global tanpa mengubah dimensi data. Selain itu, FFT dapat menangkap informasi amplitudo dan fase dari seluruh rentang frekuensi, sehingga efektif mendeteksi *periodic noise* dan anomali spektral hasil *upsampling* GAN [9].

Tabel 2.7 Perbandingan tiga metode transformasi frekuensi [28]

Metode	Kelebihan	Kekurangan	Kompleksitas
FFT	Cepat, global, mampu tangkap pola spektrum.	Tidak lokal, sensitif rotasi.	$O(n \log n)$
DCT	Efisien untuk kompresi citra (JPEG).	Tidak menangkap fase.	$O(n^2)$
Wavelet	Analisis multi-resolusi, lokal.	Kompleks implementasi.	$O(n^2 \log n)$

Penelitian oleh *Zhang et al*. menunjukkan bahwa artefak frekuensi GAN bersifat algoritmik dan universal, membuat deteksi berbasis frekuensi lebih tangguh terhadap variasi *deepfake* dibanding pendekatan berbasis *pixel* [9]. *Hasanaath et al*. juga membuktikan bahwa metode frekuensi seperti FFT memiliki ketahanan lebih baik pada skenario lintas

dataset dibanding detektor spasial murni [16]. Dengan demikian, FFT dipilih karena mampu mendeteksi artefak tersembunyi hasil sintesis GAN secara efisien, umum, dan dengan kemampuan generalisasi yang lebih tinggi.

2.21.2 Pemilihan Arsitektur XceptionNet dalam Domain Spasial

Arsitektur *XceptionNet* (*Extreme Inception Network*) dipilih sebagai model untuk mengekstraksi fitur spasial tingkat tinggi secara efisien dengan menggunakan mekanisme *depthwise separable convolution*, yang memisahkan konvolusi per kanal (*depthwise*) dari penggabungan kanal (*pointwise*). Desain ini membuat *XceptionNet* lebih efisien secara parameter dibandingkan arsitektur konvensional seperti *ResNet* dan *EfficientNet*, sekaligus mempertahankan sensitivitas tinggi terhadap tekstur, tepi, dan pola detail pada citra wajah hasil manipulasi [3, 4].

Penelitian *Afchar et al.* dengan model *MesoNet* menunjukkan bahwa arsitektur CNN dangkal dapat mendeteksi wajah palsu secara efektif, meskipun akurasinya menurun ketika diuji pada *dataset* yang lebih kompleks. Sebaliknya, *Rössler et al.* [7] melaporkan bahwa *XceptionNet* mencapai akurasi deteksi hingga 99,26% pada *dataset* FaceForensics++, melampaui performa *ResNet* dan *MesoNet* dalam mendeteksi video *deepfake* [4]. Sementara itu, penelitian *Javid Al Haq* yang membandingkan *XceptionNet* dan *ResNet-50* dengan pendekatan *Gaussian filter* serta *Local Binary Pattern* (LBP) menemukan bahwa *XceptionNet* tidak hanya lebih akurat, tetapi juga lebih cepat dalam waktu klasifikasi [3].

Dibandingkan dengan *EfficientNet*, meskipun model tersebut unggul dalam efisiensi jumlah parameter, *XceptionNet* memiliki struktur *konvolusi* yang lebih peka terhadap variasi tekstur dan tepi karakteristik penting dalam mendeteksi artefak pada citra *deepfake*. Selain itu, *XceptionNet* telah diakui sebagai *baseline* kuat dan banyak digunakan dalam berbagai penelitian maupun kompetisi deteksi *deepfake*, seperti FaceForensics++ dan *SpecXNet*, yang membuktikan keandalannya secara empiris [13]. Oleh karena itu, *XceptionNet* dipilih karena:

1. Arsitekturnya efisien namun tetap mampu mengekstraksi fitur spasial kompleks,
2. Terbukti memiliki akurasi lebih tinggi dibanding *ResNet* dan *EfficientNet*,
3. Stabil dan telah menjadi standar arsitektur dalam berbagai studi deteksi *deepfake*.

Tabel 2.8 Perbandingan performa model CNN [3, 4, 13, 7]

Model	Akurasi (FaceForensics++)	Jumlah Parameter	Kelebihan
MesoNet	85–90%	4M	Ringan, cepat

ResNet-50	92–94%	25M	Stabil, general
XceptionNet	96–99%	22M	Akurasi tertinggi, efisien
EfficientNet	94–96%	18M	Optimal parameter, tapi kurang sensitif tekstur

2.21.3 Perbandingan Akurasi dan Ketahanan Metode FFT dan XceptionNet

Berbagai penelitian menunjukkan bahwa baik metode *Fast Fourier Transform* (FFT) maupun arsitektur *XceptionNet* memiliki tingkat akurasi dan *robustness* yang tinggi dalam mendeteksi *deepfake*, terutama dibandingkan dengan pendekatan konvensional berbasis domain tunggal.

Pada domain frekuensi, penelitian oleh *Durall et al.* dan *Zhang et al.* menunjukkan bahwa transformasi frekuensi melalui FFT mampu mengenali artefak universal yang dihasilkan oleh proses *upsampling* pada jaringan GAN [8, 9]. Artefak ini bersifat matematis dan muncul secara konsisten dalam spektrum frekuensi tinggi, sehingga memungkinkan deteksi *cross-GAN* bahkan terhadap model yang tidak pernah dilatih sebelumnya. Temuan ini diperkuat oleh *Hasanaath et al.* [16] yang memperkenalkan metode FSBI (*Frequency-Enhanced Self-Blended Image*), pemanfaatan informasi frekuensi secara eksplisit mampu meningkatkan kemampuan generalisasi lintas *dataset* serta ketahanan terhadap variasi kompresi dan *noise*. Penelitian lain oleh *Qian et al.* dan *Tan et al.* juga menegaskan bahwa artefak sintesis cenderung terkonsentrasi pada *high-frequency band*, dan model yang mampu memanfaatkan petunjuk frekuensi secara adaptif menunjukkan peningkatan signifikan dalam mendeteksi citra palsu generatif [11, 12].

Sementara itu, pada domain spasial, sejumlah penelitian menempatkan *XceptionNet* sebagai salah satu arsitektur paling unggul dalam deteksi *deepfake*. *Afchar et al.* [4] memperkenalkan *MesoNet* sebagai model ringan untuk mendeteksi *deepfake* berbasis wajah, namun *Rössler et al.* [7] menemukan bahwa *XceptionNet* mencapai akurasi tertinggi, yakni berkisar antara 96–99%, pada *dataset* FaceForensics++, melampaui *ResNet* dan *MesoNet*. Temuan ini diperkuat oleh *Javid Al Haq* [3], yang menunjukkan bahwa *XceptionNet* mempertahankan performa stabil dan akurat bahkan pada video dengan tingkat kompresi tinggi. Selain itu, penelitian oleh *Alam et al.* [13] dalam model *SpecXNet* juga memperlihatkan bahwa arsitektur *XceptionNet* lebih tangguh terhadap variasi *dataset* dan teknik manipulasi baru dibandingkan dengan *ResNet* maupun *EfficientNet*.

Dengan demikian, kombinasi antara FFT dan *XceptionNet* menjadi pendekatan optimal yang saling melengkapi. FFT memberikan kemampuan untuk mengekstraksi dan mengenali pola artefak yang tersembunyi di domain frekuensi seperti *spectral distortion* dan GAN *fingerprints* sedangkan *XceptionNet* unggul dalam mendeteksi anomali spasial pada struktur wajah dan tekstur visual. Integrasi keduanya menghasilkan sistem deteksi *deepfake* yang tidak hanya lebih akurat dan efisien, tetapi juga lebih tangguh terhadap variasi data, tingkat kompresi, serta teknik manipulasi baru, sebagaimana ditunjukkan pada penelitian-penelitian terkini [13, 16, 7, 17].

Tabel 2.9 Ringkasan Perbandingan FFT vs XceptionNet [3, 8, 9, 13, 16, 7]

Aspek Evaluasi	FFT (Domain Frekuensi)	XceptionNet (Domain Spasial)	Kombinasi Hybrid
Artefak yang terdeteksi	Pola spektrum, noise periodik	Tekstur, tepi, distorsi wajah	Gabungan keduanya
Robustness	Tinggi terhadap kompresi	Sedang	Sangat tinggi
Kebutuhan komputasi	Rendah	Sedang–Tinggi	Sedang
Generalisasi (cross-dataset)	Baik	Baik	Sangat baik
Akurasi (rata-rata)	90–93%	96–99%	98–99%

BAB III

TAHAPAN PELAKSANAAN

3.1 Kerangka Umum Penelitian

Penelitian ini merupakan penelitian eksperimental dalam bidang visi komputer dan pembelajaran mendalam (*deep learning*). Fokus utamanya adalah mendeteksi konten *deepfake*, yaitu manipulasi video wajah menggunakan teknik generatif. Pendekatan eksperimental dipilih karena tujuan penelitian adalah mengevaluasi kemampuan metode baru dalam kondisi terkontrol, di mana variabel seperti *dataset*, arsitektur, dan parameter pelatihan dapat dimanipulasi dan direplikasi.

3.1.1 Jenis dan Pendekatan Penelitian

Penelitian ini merupakan penelitian eksperimental di bidang *computer vision* dan *deep learning*. Fokus utama penelitian adalah merancang, mengimplementasikan, dan mengevaluasi model deteksi *deepfake* yang menggabungkan analisis domain spasial dan domain frekuensi secara bersamaan. Pendekatan eksperimental dipilih karena tujuan penelitian adalah mengevaluasi kemampuan metode baru dalam kondisi terkontrol, di mana variabel seperti *dataset*, arsitektur model, dan parameter pelatihan dapat dimanipulasi dan direplikasi secara konsisten.

Metode deteksi *deepfake* konvensional umumnya hanya memanfaatkan fitur spasial (tekstur, struktur wajah) atau bergantung pada model tunggal. Namun, pada kasus manipulasi yang canggih, artefak spasial dapat sangat halus sehingga sulit dideteksi oleh satu jenis fitur saja. Di sisi lain, citra hasil sintesis generatif (*GAN*) memiliki ketidaksempurnaan pada distribusi spektral yang tidak terlihat secara kasat mata namun terdeteksi melalui analisis frekuensi [8, 21]. Oleh karena itu, penelitian ini mengusulkan pendekatan hibrida yang memadukan dua *domain* analisis:

1. **Analisis domain spasial** melalui jaringan konvolusional XceptionNet [6], yang telah terbukti efektif dalam mengekstraksi fitur visual tingkat tinggi dari citra wajah.
2. **Analisis domain frekuensi** melalui transformasi Fourier cepat (*Fast Fourier Transform* / FFT) yang diproses oleh jaringan konvolusional khusus (*FreqCNN*) untuk menangkap artefak spektral yang dihasilkan oleh proses sintesis *deepfake*.

Sebagai bagian dari desain eksperimental, penelitian ini membangun tiga varian model sebagai perbandingan terkontrol:


1. **Model spasial** (*spatial*): hanya menggunakan fitur *domain* spasial (XceptionNet).
2. **Model frekuensi** (*freq*): hanya menggunakan fitur *domain* frekuensi (FreqCNN pada peta FFT).
3. **Model hibrida** (*hybrid*): menggabungkan kedua *domain* melalui arsitektur *late fusion* dengan mekanisme *Squeeze-and-Excitation* (SE) *gating*.

Desain tiga varian ini memungkinkan pengukuran kontribusi individual masing-masing *domain* serta evaluasi apakah penggabungan keduanya menghasilkan peningkatan performa deteksi dan generalisasi lintas *dataset*.

3.1.2 Tahapan Pelaksanaan Penelitian

Pelaksanaan penelitian ini terdiri dari lima tahapan utama:

1. **Pengumpulan Data**, yaitu menggunakan dua dataset *benchmark* standar untuk deteksi *deepfake*, yaitu FaceForensics++ (FFPP) dan Celeb-DF v2 (CDF).
2. **Preprocessing**, meliputi ekstraksi *frame* dari video, konversi domain frekuensi melalui FFT, normalisasi, serta augmentasi data.
3. **Perancangan Model**, merancang tiga arsitektur model: *spatial* (XceptionNet), *frequency* (FreqCNN), dan *hybrid* (HybridTwoBranch) dengan mekanisme *late fusion* dan SE *gating*.
4. **Pelatihan dan Optimasi**, dengan melatih setiap model menggunakan strategi *transfer learning*, *differential learning rate*, penjadwalan *learning rate* (*warmup + cosine decay*), dan *early stopping* berdasarkan AUC.
5. **Pengujian dan Evaluasi**, mengevaluasi setiap model secara *in-dataset* dan *cross-dataset* pada berbagai ukuran sampel, menggunakan metrik akurasi, presisi, *recall*, F1-score, dan AUC-ROC.



Gambar 3.1 Flowchart Utama *Pipeline* Penelitian

3.2 Dataset dan Sumber Data

Pemilihan *dataset* merupakan langkah krusial dalam penelitian deteksi *deepfake*. *Dataset* yang digunakan harus merepresentasikan keberagaman metode manipulasi dan tingkat kualitas visual yang berbeda agar model yang dikembangkan dapat dievaluasi secara komprehensif. Penelitian ini menggunakan dua *dataset benchmark* yang diakui secara luas dalam komunitas riset deteksi *deepfake*, yaitu FaceForensics++ dan Celeb-DF v2, yang masing-masing memiliki karakteristik dan tantangan yang berbeda. Selain itu, diuraikan pula strategi pembagian *dataset* dan variasi ukuran sampel yang dirancang untuk menganalisis ketahanan model pada berbagai kondisi ketersediaan data.

3.2.1 FaceForensics++ (FFPP)

Dataset pertama yang digunakan dalam penelitian ini adalah FaceForensics++ yang diperkenalkan oleh Rössler *et al.* [7] FaceForensics++ merupakan salah satu *benchmark* standar yang paling banyak digunakan dalam penelitian deteksi *deepfake*. *Dataset* ini terdiri dari video wajah asli yang bersumber dari YouTube serta video hasil manipulasi menggunakan empat metode yang berbeda:

1. **Deepfakes**, pertukaran wajah berbasis *autoencoder*.
2. **Face2Face**, transfer ekspresi wajah secara *real-time*.
3. **FaceSwap**, pertukaran wajah berbasis grafik komputer.
4. **NeuralTextures**, manipulasi berbasis *neural rendering*.

Keberagaman metode manipulasi ini menjadikan FaceForensics++ sangat cocok untuk menguji ketahanan (*robustness*) model terhadap berbagai jenis artefak *deepfake*. Video dalam *dataset* tersedia dalam tiga tingkat kompresi: *raw* (tanpa kompresi), *c23* (kompresi ringan), dan *c40* (kompresi berat). Pada penelitian ini digunakan tingkat kompresi *c23* yang merepresentasikan skenario distribusi video secara *online* yang realistis.

Pelabelan data dilakukan secara otomatis berdasarkan pencocokan kata kunci pada nama direktori. Video yang berada dalam direktori mengandung kata kunci "original", "real", atau "pristine" dilabeli sebagai *real* (label 0), sedangkan video dalam direktori mengandung kata kunci "fake", "manipulated", "deepfakes", "faceswap", "neuraltextures", atau "face2face" dilabeli sebagai *fake* (label 1).

3.2.2 Celeb-DF v2 (CDF)

Dataset kedua yang digunakan adalah Celeb-DF v2 (*Celeb-DeepFake*) yang diperkenalkan oleh Li *et al.* [18]. Celeb-DF berisi video wajah selebriti asli dan versi *deepfake*-nya yang dihasilkan menggunakan teknik *face swapping* tunggal. Dibandingkan FaceForensics++, *deepfake* dalam Celeb-DF memiliki kualitas visual yang lebih tinggi dengan artefak yang lebih halus dan sulit dideteksi secara kasat mata.

Celeb-DF digunakan secara khusus dalam penelitian ini untuk menguji kemampuan generalisasi lintas dataset (*cross-dataset generalization*). Karena Celeb-DF hanya menggunakan satu metode sintesis yang berbeda dari keempat metode dalam FaceForensics++, evaluasi silang antara kedua dataset ini mengukur sejauh mana model mampu mendeteksi *deepfake* dari metode yang belum pernah dilihat selama pelatihan.

3.2.3 Pembagian Dataset

Pembagian dataset dilakukan pada level video, bukan pada level *frame*, untuk mencegah kebocoran data (*data leakage*). Apabila pembagian dilakukan pada level *frame*, terdapat risiko *frame-frame* dari video yang sama tersebar ke dalam set pelatihan dan pengujian, sehingga model secara tidak sengaja menghafal karakteristik video tertentu alih-alih mempelajari pola *deepfake* secara umum.

Pembagian dilakukan secara terstratifikasi (*stratified split*) berdasarkan label untuk mempertahankan rasio kelas *real/fake* yang seimbang pada setiap subset. Proporsi pembagian yang digunakan adalah sebagai berikut:

Tabel 3.1 Komposisi total *dataset* yang digunakan

Dataset	Real videos	Fake videos	Total videos	Frame rate ekstraksi	Total frame (~)	Sumber
<i>FaceForensics++</i>	500	500 (125 per metode × 4 metode)	1.000	5 fps, max 50 <i>frame</i> /video	50.000	[7]
<i>Celeb-DF</i>	375	375	750	5 fps, max 50 <i>frame</i> /video	37.500	[18]

Tabel 3.2 Pembagian Dataset

Subset	Proporsi	Stratifikasi	Level Pembagian
Training	70%	Berdasarkan label	Video
Validation	15%	Berdasarkan label	Video
Testing	15%	Berdasarkan label	Video

Pembagian dilakukan menggunakan fungsi *train_test_split* dari pustaka *scikit-learn* dengan parameter *stratify* berdasarkan label dan *seed* = 42 untuk menjamin reproduktibilitas. Validasi tambahan dilakukan untuk memastikan tidak terdapat duplikasi *video_id* dan setiap kelas memiliki minimum 4 sampel yang diperlukan untuk pembagian terstratifikasi tiga arah.

3.2.4 Variasi Ukuran Sampel

Untuk menganalisis pengaruh jumlah data pelatihan terhadap performa model, eksperimen dilakukan pada beberapa variasi ukuran sampel. Jumlah sampel yang digunakan berbeda untuk setiap dataset, disesuaikan dengan ketersediaan data:

Tabel 3.3 Variasi Ukuran Sampel per Dataset

Dataset	Ukuran Sampel (jumlah video)
FaceForensics++ (FFPP)	100, 300, 600, 1000
Celeb-DF v2 (CDF)	100, 250, 500, 750

Pada setiap ukuran sampel, pengambilan video dilakukan secara seimbang antara kelas *real* dan *fake* (rasio 50:50). Dari setiap video yang terpilih, diekstraksi maksimum 50 *frame* pada laju 5 *frame per second* (FPS). Variasi ukuran sampel ini memungkinkan analisis terhadap ketahanan masing-masing arsitektur model pada kondisi data terbatas maupun melimpah.



Gambar 3.2 Contoh *Frame Real* dan *Fake* dari Dataset FaceForensics++ dan Celeb-DF

3.3 Tahapan Preprocessing Data

Tahapan *preprocessing* bertujuan untuk mengonversi data video mentah menjadi representasi yang dapat diproses oleh model *deep learning*. *Pipeline preprocessing* terdiri dari tiga tahapan utama:


1. ekstraksi *frame* dari video,
2. konversi domain frekuensi melalui FFT untuk menghasilkan peta *magnitude*
3. augmentasi data untuk meningkatkan keberagaman set pelatihan.

Setiap tahapan dirancang untuk mempertahankan informasi yang relevan sambil menstandarkan format data agar konsisten antar *dataset*.

3.3.1 Ekstraksi Frame dari Video

Tahap pertama *preprocessing* adalah mengekstraksi *frame* citra dari setiap video dalam dataset. Proses ini dilakukan menggunakan pustaka OpenCV dengan langkah-langkah sebagai berikut:

1. Setiap video dibuka dan dibaca laju *frame* aslinya (*native FPS*).
 2. Interval pengambilan *frame* dihitung berdasarkan target FPS: $interval = \max\left(\left\lceil \frac{FPS_{asli}}{FPS_{target}} \right\rceil, 1\right)$ dengan FPS target = 5.
 3. *Frame* diambil pada setiap interval yang telah dihitung, hingga maksimum 50 *frame* per video.
 4. Setiap *frame* disimpan sebagai berkas JPEG dengan penamaan berurutan: “frame_000000.jpg”, “frame_000001.jpg”, dan seterusnya.
 5. Label setiap video diinferensi secara otomatis dari nama direktori berdasarkan pencocokan kata kunci yang telah dikonfigurasi.
 6. Proses ekstraksi dilakukan secara paralel menggunakan *multiprocessing pool* untuk mempercepat pemrosesan pada *dataset* berskala besar. Hasil ekstraksi disimpan dalam berkas manifest CSV yang berisi kolom *video_id*, *label*, dan *frames_dir* sebagai referensi untuk tahap selanjutnya. Algoritma selengkapnya ditunjukkan pada Gambar 3.3
- Pseudocode* ekstraksi frame dari video



Gambar 3.3 *Pseudocode* ekstraksi frame dari video

Pemilihan 5 fps dan maksimum 50 *frame*/video merupakan kompromi antara cakupan temporal dan ukuran *dataset*. Pada 30 fps native, 5 fps memberikan satu sampel setiap 200ms, yang cukup untuk menangkap variasi ekspresi tanpa redundansi *frame*. Batas 50 *frame*/video membatasi total *frame* FFPP $n = 1000 \sim 50.000$, ukuran yang dapat dilatih pada satu sesi Colab Pro tanpa mengorbankan keberagaman video.

3.3.2 Deteksi Wajah dan Cropping

Bagian wajah merupakan target utama manipulasi *deepfake*, sementara latar belakang umumnya tidak mengandung informasi diskriminatif dan justru berperan sebagai *noise* [4, 7]. Oleh karena itu, setiap *frame* hasil ekstraksi terlebih dahulu melewati tahap deteksi dan pemotongan wajah sebelum dianalisis.

Deteksi wajah dilakukan menggunakan **MTCNN** (*Multi-task Cascaded Convolutional Networks*) [44] dari pustaka *facenet-pytorch*. MTCNN bekerja melalui tiga jaringan konvolusional bertingkat (*cascade*):

1. **P-Net** (*Proposal Network*), secara cepat menghasilkan banyak kandidat *bounding box* wajah beserta skor kepercayaannya.
2. **R-Net** (*Refine Network*), menyaring dan membuang kandidat palsu dari P-Net, serta memperhalus koordinat kotak.
3. **O-Net** (*Output Network*), memfinalisasi posisi *bounding box* wajah (dan titik *landmark*) dengan presisi tertinggi.

Detektor dikonfigurasi dengan ukuran wajah minimum 60 piksel dan ambang kepercayaan bertahap sebesar 0,6, 0,7, dan 0,7 untuk masing-masing tahap. Apabila pada satu *frame* terdeteksi lebih dari satu wajah, dipilih wajah dengan luas *bounding box* terbesar. Kotak terpilih kemudian diperluas dengan margin sebesar 30% pada setiap sisi untuk memastikan seluruh area wajah beserta konteks tepi (rahang, dahi) ikut terpotong, lalu *frame* dipotong sesuai kotak tersebut. Apabila tidak ada wajah yang terdeteksi pada suatu *frame*, *frame* penuh digunakan sebagai *fallback* agar tidak ada data yang hilang.

Pembatasan analisis hanya pada region wajah meminimalkan jumlah fitur tidak relevan, sehingga model memiliki kapasitas lebih besar untuk mempelajari pola-pola manipulasi. Secara empiris, penerapan *face cropping* meningkatkan performa model spasial secara substansial pada dataset FaceForensics++. *Frame* hasil *crop* selanjutnya diubah ukurannya menjadi 224×224 piksel sebelum memasuki tahap konversi domain frekuensi.

3.3.3 Konversi Domain Frekuensi (FFT)

Konversi domain frekuensi merupakan inti kontribusi penelitian ini. Proses ini mengubah setiap *frame* citra RGB menjadi representasi peta *magnitude* frekuensi menggunakan *Fast Fourier Transform* (FFT) 2 dimensi. Representasi frekuensi ini menangkap artefak spektral yang dihasilkan oleh proses sintesis *deepfake*, seperti *checkerboard artifacts* dari operasi *upsampling* pada GAN [21], distorsi distribusi spektral [8], dan ketidakkontinyuan pada batas *blending* [9].

1. Konversi RGB ke *Grayscale*

Langkah pertama adalah mengonversi citra RGB menjadi *grayscale* (satu kanal). Konversi dilakukan menggunakan standar ITU-R BT.601 dengan formula:

$$Y = 0,299R + 0,587G + 0,114B \quad (3.1)$$

di mana Y adalah nilai luminansi, dan R , G , B adalah nilai kanal warna merah, hijau, dan biru. Bobot yang berbeda pada setiap kanal mencerminkan sensitivitas mata manusia terhadap masing-masing warna. Konversi ke satu kanal cukup untuk analisis frekuensi karena informasi luminansi merepresentasikan distribusi intensitas spasial yang diperlukan untuk mendeteksi artefak spektral.

2. Transformasi Fourier 2D

Citra *grayscale* kemudian diubah ukurannya menjadi 224×224 dan ditransformasi ke domain frekuensi menggunakan *Discrete Fourier Transform* (DFT) 2 dimensi. DFT 2D didefinisikan sebagai:

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \cdot e^{-j \cdot 2\pi \left(\frac{u \cdot x}{M} + \frac{v \cdot y}{N} \right)} \quad (3.2)$$

di mana $f(x, y)$ adalah nilai piksel pada posisi (x, y) , $F(u, v)$ adalah koefisien frekuensi pada koordinat frekuensi (u, v) , M dan N adalah dimensi citra (keduanya 224), dan $j = \sqrt{-1}$ adalah unit imajiner.

Setelah transformasi, dilakukan operasi *FFT shift* yang memindahkan komponen frekuensi nol (*DC component*) dari sudut matriks ke posisi tengah. Hal ini menyebabkan frekuensi rendah terletak di bagian tengah peta frekuensi dan frekuensi tinggi di bagian tepi, sehingga memudahkan interpretasi visual dan analisis.

3. *Magnitude Spectrum, High Pass Filtering dan Log Scaling*

Dari hasil DFT yang berupa bilangan kompleks, dihitung *magnitude spectrum*:

$$|F(u, v)| = \sqrt{\text{Re}(F(u, v))^2 + \text{Im}(F(u, v))^2} \quad (3.3)$$

Sebelum transformasi logaritmik, *magnitude spectrum* dilewatkan melalui *Gaussian high-pass* filter yang dirancang untuk menekan dominasi komponen frekuensi rendah di sekitar pusat peta (setelah *fftshift*). Penekanan ini penting karena pada citra wajah, energi frekuensi terkonsentrasi pada komponen DC dan frekuensi rendah, yang sebagian besar merepresentasikan struktur global wajah (bentuk, pencahayaan) dan kurang informatif untuk deteksi *deepfake*. Sebaliknya, artefak sintesis *deepfake*, seperti *checkerboard patterns* dan *spectral rolloff* yang anomal, terutama termanifestasi pada komponen frekuensi menengah dan tinggi. *Mask high-pass Gaussian* didefinisikan sebagai:

$$H(u, v) = 1 - \exp\left(-\frac{(u-u_c)^2 + (v-v_c)^2}{2(\beta \cdot N)^2}\right) \quad (3.4)$$

di mana (u_c, v_c) adalah koordinat pusat peta frekuensi setelah *fftshift*, N adalah dimensi peta (224), dan $\beta = 0,15$ adalah *cutoff fraction* yang mengontrol radius penekanan ($\sigma = \beta \cdot N \approx 33,6$ piksel). *Magnitude* yang telah difilter kemudian dihitung sebagai $|F'(u, v)| = |F(u, v)| \cdot H(u, v)$.

Setelah *high-pass filtering*, dilakukan transformasi logaritmik untuk mengompresi rentang dinamis yang masih sangat lebar:

$$M_{\log}(u, v) = \log(1 + |F'(u, v)|) \quad (3.5)$$

Fungsi $\log(1 + x)$ (dikenal sebagai *log1p*) dipilih karena dua alasan:

- Menghindari permasalahan $\log(0)$ karena $\log(1 + 0) = 0$
- Mengompresi rentang dinamis sehingga detail pada frekuensi tinggi tidak tertutupi oleh dominasi komponen DC. Hasil akhir berupa matriks *float32* berukuran

224x224 dengan nilai tipikal pada rentang $[0, \sim 16]$ yang disimpan sebagai berkas *.npy* (*NumPy array*) dalam *cache* FFT.

4. Contoh Perhitungan FFT 2D

Sebagai ilustrasi, berikut ditunjukkan perhitungan FFT 2D pada matriks *grayscale* berukuran 4x4. Misalkan matriks piksel $f(x, y)$ adalah:

Tabel 3.4 Contoh Matriks *Grayscale* 4x4

	$y = 0$	$y = 1$	$y = 2$	$y = 3$
$x = 0$	100	120	100	120
$x = 1$	80	100	80	100
$x = 2$	100	120	100	120
$x = 3$	80	100	80	100

a. Menghitung $F(0,0)$, yaitu **komponen DC**

$$F(0,0) = \sum_{x=0}^3 \sum_{y=0}^3 f(x, y) \cdot e^{-j \cdot 2\pi(0)} \quad (3.6)$$

$$\begin{aligned} F(0,0) &= (100 + 120 + 100 + 120) + (80 + 100 + 80 + 100) \\ &\quad + (100 + 120 + 100 + 120) + (80 + 100 + 80 + 100) \\ F(0,0) &= 440 + 360 + 440 + 360 = 1600 \end{aligned}$$

Komponen DC merepresentasikan rata-rata intensitas keseluruhan citra, yaitu

$$\frac{1600}{16} = 100$$

b. Menghitung $F(0,1)$, yaitu **frekuensi horizontal pertama**

$$F(0,1) = \sum_{x=0}^3 \sum_{y=0}^3 f(x, y) \cdot e^{-j \cdot 2\pi(\frac{y}{4})} \quad (3.7)$$

Karena $e^{-j \cdot 2\pi(\frac{y}{4})}$ menghasilkan faktor $\{1, -j, -1, j\}$ untuk $y = 0, 1, 2, 3$:

i. Baris $x = 0$:

$$\begin{aligned} &100(1) + 120(-j) + 100(-1) + 120(j) \\ &0 + (-120j + 120j) = 0 \end{aligned}$$

ii. Baris $x = 1$:

$$\begin{aligned} &80(1) + 100(-j) + 80(-1) + 100(j) \\ &0 + (-100j + 100j) = 0 \end{aligned}$$

iii. Baris $x = 2$:

$$x = 0 \rightarrow 0$$

iv. Baris $x = 3$:

$$x = 1 \rightarrow 0$$

$$F(0,1) = 0$$

Hal ini menunjukkan bahwa pola frekuensi horizontal pada matriks ini simetris.

c. Menghitung $F(1,0)$, yaitu **frekuensi vertikal pertama**

$$F(1,0) = \sum_{x=0}^3 \sum_{y=0}^3 f(x,y) \cdot e^{-j \cdot 2\pi \left(\frac{x}{4}\right)} \quad (3.8)$$

Faktor $e^{-j \cdot 2\pi \left(\frac{x}{4}\right)}$ menghasilkan $\{1, -j, -1, j\}$ untuk $x = 0, 1, 2, 3$:

a. $x = 0$:

$$(100 + 120 + 100 + 120)(1) = 440$$

b. $x = 1$:

$$(80 + 100 + 80 + 100)(-j) = -360j$$

c. $x = 2$:

$$(100 + 120 + 100 + 120)(-1) = -440$$

d. $x = 3$:

$$(80 + 100 + 80 + 100)(j) = 360j$$

$$F(1,0) = 440 - 360j - 440 + 360j = 0$$

d. Menghitung $F(1,1)$

$$F(1,0) = \sum_{x=0}^3 \sum_{y=0}^3 f(x,y) \cdot e^{-j \cdot 2\pi \left(\frac{x+y}{4}\right)} \quad (3.9)$$

Faktor gabungan $e^{-j \cdot 2\pi \left(\frac{x+y}{4}\right)}$ untuk setiap (x,y) :

(x,y)	$f(x,y)$	$e^{-j \cdot 2\pi \left(\frac{x+y}{2}\right)}$	Hasil
(0,0)	100	1	100
(0,1)	120	$-j$	$-120j$
(0,2)	100	-1	-100
(0,3)	120	j	$120j$
(1,0)	80	$-j$	$-80j$
(1,1)	100	-1	-100
(1,2)	80	j	$80j$
(1,3)	100	1	100
(2,0)	100	-1	-100
(2,1)	120	j	$120j$
(2,2)	100	1	100
(2,3)	120	$-j$	$-120j$
(3,0)	80	j	$80j$

(3, 1)	100	1	100
(3, 2)	80	$-j$	$-80j$
(3, 3)	100	-1	-100

i. Penjumlahan bagian real

$$100 - 100 - 100 + 100 - 100 + 100 - 100 + 100 = 0$$

ii. Penjumlahan bagian imajiner

$$-120 - 80 + 80 + 120 + 120 - 120 + 80 - 80 = 0$$

$$F(1, 1) = 0 + 0j = 0$$

Matriks ini memiliki pola repetitif sempurna sehingga energi terkonsentrasi pada komponen DC. Pada citra wajah sesungguhnya, distribusi energi lebih tersebar dan perbedaan antara citra *real* dan *fake* terlihat dari pola distribusi frekuensi tinggi yang anomal.

e. *Magnitude* dan *Log Scaling*

Tabel 3.5 Contoh Perhitungan *Magnitude* dan *Log Scaling*

Komponen	$F(u, v)$	$ F(u, v) $	$\log(1 + F(u, v))$
$F(0, 0)$	1600	1600	7,378
$F(0, 1)$	0	0	0
$F(1, 0)$	0	0	0
$F(1, 1)$	0	0	0

Pada citra *deepfake* sesungguhnya, komponen frekuensi tinggi menunjukkan pola anomali yang khas, seperti *spectral rolloff* yang tidak wajar [8] atau puncak periodik akibat *checkerboard artifacts* dari operasi *transposed convolution* pada GAN [21].

3. Normalisasi FFT

Setelah seluruh *frame* dikonversi ke peta *magnitude* FFT dan disimpan dalam *cache*, dilakukan perhitungan statistik normalisasi per *dataset*. Normalisasi menggunakan *z-score*:

$$\hat{x} = \frac{x - \mu}{\sigma} \quad (3.10)$$

di mana μ dan σ adalah rata-rata dan simpangan baku global yang dihitung dari seluruh piksel dalam *cache* FFT dataset tersebut. Perhitungan dilakukan pada sampel acak

hingga 5.000 berkas *cache* menggunakan akumulasi satu lintasan (penjumlahan nilai dan kuadrat / *sum & sum-of-squares*) untuk efisiensi memori. Hasil disimpan dalam berkas *fft_stats.json* yang dimuat secara otomatis saat pelatihan.

Normalisasi per *dataset* ini penting karena setiap *dataset* memiliki karakteristik spektral yang berbeda akibat perbedaan kamera, resolusi, dan metode kompresi. Tanpa normalisasi yang tepat, fitur frekuensi dari *dataset* yang berbeda akan memiliki skala yang tidak sebanding.

3.3.4 Augmentasi Data

Augmentasi data merupakan teknik regularisasi yang diterapkan selama pelatihan untuk meningkatkan keberagaman data tanpa menambah jumlah sampel asli. Pada penelitian ini, strategi augmentasi dirancang secara terpisah untuk domain spasial dan domain frekuensi, karena karakteristik kedua representasi data yang berbeda secara fundamental. Selain itu, pada mode *hybrid*, konsistensi augmentasi antara kedua cabang dijaga untuk mempertahankan korespondensi spasial-frekuensi.

1. Augmentasi Domain Spasial

Augmentasi pada domain spasial diterapkan pada citra RGB selama pelatihan untuk meningkatkan keberagaman data dan mencegah *overfitting*. *Pipeline* augmentasi terdiri dari:

- a. **Resize**, citra diubah ukurannya menjadi 256×256 piksel (lebih besar dari ukuran input final).
- b. **RandomResizedCrop**, pemotongan acak ke ukuran 224×224 dengan skala antara 80%–100% dari citra asli. Augmentasi ini mensimulasikan variasi *zoom* dan posisi wajah.
- c. **ColorJitter**, yaitu perubahan acak pada kecerahan ($\pm 0,2$), kontras ($\pm 0,2$), saturasi ($\pm 0,1$), dan *hue* ($\pm 0,05$). Augmentasi ini mensimulasikan variasi kondisi pencahayaan, pengaturan kamera, dan karakteristik sensor yang berbeda antar video sumber.
- d. **RandomHorizontalFlip**, pembalikan horizontal dengan probabilitas 50%. Augmentasi ini memanfaatkan simetri bilateral wajah manusia.
- e. **ToTensor**, konversi ke tensor PyTorch dengan rentang nilai $[0, 1]$.
- f. **Normalize**, normalisasi menggunakan statistik ImageNet:

$$mean = [0,485; 0,456; 0,406]$$

$$std = [0,229; 0,224; 0,225]$$

- g. **RandomErasing**, penghapusan acak sebuah area persegi panjang pada tensor (probabilitas 10%, skala 2%–15% dari luas citra) yang diisi dengan nilai acak. Teknik ini diterapkan setelah normalisasi (beroperasi pada tensor, bukan citra PIL) dan mendorong model untuk tidak bergantung pada satu wilayah spesifik dari citra wajah, meningkatkan ketahanan terhadap oklusi parsial.

Pada tahap validasi dan pengujian, augmentasi acak tidak diterapkan. Citra hanya diubah ukurannya secara langsung ke 224×224 , dikonversi ke tensor, dan dinormalisasi.

Tahapan augmentasi visual pada cabang spasial (RGB)



Gambar 3.4 Tahapan augmentasi visual pada cabang spasial (RGB)

2. Augmentasi Domain Frekuensi

Augmentasi pada domain frekuensi memerlukan pendekatan yang berbeda dari domain spasial. Operasi spasial seperti pemotongan acak (*random crop*) atau rotasi tidak sesuai untuk peta *magnitude* FFT karena akan merusak lokalisasi frekuensi, setiap posisi piksel pada peta FFT merepresentasikan komponen frekuensi spesifik yang bergantung pada posisi absolutnya.

Oleh karena itu, augmentasi pada domain frekuensi dilakukan melalui injeksi *noise* Gaussian:

$$\hat{x}_{fft} = x_{fft} + \epsilon_1 \quad \epsilon_1 \sim \mathcal{N}(0, \sigma^2) \quad (3.11)$$

dengan $\sigma = 0,05$ (dikonfigurasi melalui parameter `fft_noise_sigma`). *Noise* diterapkan setelah normalisasi *z-score* dan hanya selama pelatihan. Rasional dari pendekatan ini adalah:


- Menyimulasikan variasi *noise* sensor dan artefak kompresi yang memengaruhi spektrum frekuensi
- Mencegah penghafalan (*memorization*) peta FFT yang identik di setiap *epoch* karena data FFT dimuat dari *cache* statis.

Selain injeksi *noise*, diterapkan pula **spectral band masking** dengan probabilitas 5%. Pada setiap *frame* yang terpilih secara acak, sebuah pita frekuensi, baik horizontal maupun vertikal dengan lebar acak antara 1 hingga $\lfloor \frac{H}{16} \rfloor$ piksel diisi dengan nilai nol:

$$\hat{x}_{fft}[r_1 : r_1 + w, :] = 0 \quad (\text{pita horizontal}) \quad (3.12)$$

$$\hat{x}_{fft}[:, c_1 : c_1 + w] = 0 \quad (\text{pita vertikal}) \quad (3.13)$$

di mana w adalah lebar pita acak dan r_1 atau c_1 adalah posisi awal acak. Pemilihan orientasi horizontal atau vertikal dilakukan dengan probabilitas 50:50. Teknik ini mencegah model bergantung pada satu pita frekuensi spesifik dan mendorong representasi frekuensi yang lebih merata dan *robust*.




Gambar 3.5 Contoh Penerapan *Spectral Band Masking* pada Peta *Magnitude FFT*

3. Konsistensi Augmentasi pada Mode Hybrid

Pada mode *hybrid*, di mana model menerima input RGB dan FFT secara bersamaan, konsistensi augmentasi antara kedua cabang sangat penting. Pembalikan horizontal

(*horizontal flip*) pada citra RGB tanpa pembalikan yang sama pada peta FFT akan merusak korespondensi spasial-frekuensi, karena $|DFT(\text{flip}(x))| = \text{flip}(|DFT(x)|)$. Untuk mengatasi hal ini, pembalikan horizontal pada mode *hybrid* diterapkan secara manual setelah kedua *input* dimuat, dengan keputusan acak yang sama (probabilitas 50%) diterapkan secara identik pada tensor RGB dan tensor FFT. Pada *pipeline* augmentasi spasial untuk mode *hybrid*, opsi *RandomHorizontalFlip* dinonaktifkan (*include_hflip=False*) agar pembalikan dapat dikontrol secara terpadu.

Perbandingan Peta Magnitude FFT: Frame Real vs Fake




Gambar 3.6 Perbandingan Peta *Magnitude* FFT: Frame *Real* vs *Fake*

3.4 Arsitektur Model yang Diusulkan

Penelitian ini mengusulkan satu arsitektur utama, yaitu *HybridTwoBranch* sebagai kontribusi. Sebagai pembanding (*baseline*) dalam *ablation study*, dirancang juga dua model satu-domain: *XceptionNet* spasial-saja dan *FreqCNN* frekuensi-saja. Tujuan *baseline* ini bukan kontribusi tersendiri, melainkan untuk memisahkan kontribusi masing-masing domain terhadap performa akhir model *hybrid*.

3.4.1 Model Spasial XceptionNet



Gambar 3.7 Diagram Arsitektur XceptionNet [6]

Model spasial merupakan *baseline* utama dalam penelitian ini yang menganalisis fitur visual langsung dari citra RGB. Arsitektur XceptionNet dipilih karena telah terbukti sebagai salah satu model paling efektif untuk deteksi *deepfake* pada domain spasial, sebagaimana ditunjukkan oleh Rössler *et al.* [7] yang melaporkan akurasi 96–99% pada dataset FaceForensics++. Bagian berikut menjelaskan komponen utama arsitektur XceptionNet yang digunakan dalam penelitian ini.

1. Depthwise Separable Convolution

XceptionNet [6] merupakan arsitektur *convolutional neural network* (CNN) yang dibangun sepenuhnya dari *depthwise separable convolution*. Berbeda dengan konvolusi standar yang menerapkan filter secara simultan pada dimensi spasial dan kanal, *depthwise separable convolution* memfaktorisasi operasi menjadi dua tahap terpisah:

- Konvolusi *depthwise***, menerapkan satu filter konvolusi per kanal input secara independen. Untuk input dengan C kanal dan filter berukuran $K \times K$, jumlah parameter adalah $C \times K \times K$.

- b. **Konvolusi *pointwise***, menerapkan konvolusi 1×1 untuk menggabungkan informasi lintas kanal. Untuk menghasilkan C' kanal output, jumlah parameter adalah $C \times C'$.

Contoh perhitungan perbandingan parameter, untuk input berukuran $H \times W$ dengan $C_{in} = 64$ kanal, filter 3×3 , dan $C_{out} = 128$ kanal output:

- a. Konvolusi standar:

$$C_{in} \times K^2 \times C_{out} = 64 \times 9 \times 128 = 73.728 \text{ parameter}$$

- b. Konvolusi *depthwise separable*:

- i. *Depthwise*:

$$C_{in} \times K^2 = 64 \times 9 = 576 \text{ parameter}$$

- ii. *Pointwise*:

$$C_{in} \times C_{out} = 64 \times 128 = 8.192 \text{ parameter}$$

- iii. Total:

$$576 + 8.192 = 8.768 \text{ parameter}$$

- c. Rasio pengurangan:

$$\frac{8.768}{73.728} \approx 11,9\%$$

pengurangan parameter sebesar $\sim 88\%$.

Efisiensi parameter ini memungkinkan XceptionNet memiliki kedalaman yang besar (36 *layer* konvolusional) dengan total $\sim 22,8$ juta parameter, sambil tetap mempertahankan kapasitas representasi yang tinggi.

Contoh perhitungan *Depthwise Separable Convolution*, misalkan input berukuran 3×3 dengan 2 kanal:

$$X_1 = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 2 \\ 0 & 1 & 3 \end{bmatrix}, X_2 = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 3 & 0 \\ 2 & 1 & 1 \end{bmatrix} \quad (3.14)$$

- a. *Depthwise*, filter 2×2 terpisah per kanal (tanpa *padding*, *stride* = 1):

$$W_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, W_2 = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad (3.15)$$

Konvolusi kanal 1 ($X_1 * W_1$) posisi (0, 0):

$$1 \times 1 + 2 \times 0 + 3 \times 0 + 1 \times 1 = 2 \quad (3.16)$$

Hasil lengkap kanal 1:

$$Y_1 = \begin{bmatrix} 2 & 3 \\ 4 & 4 \end{bmatrix}$$

Konvolusi kanal 2 ($X_2 * W_2$) posisi (0, 0):

$$2 \times 0 + 0 \times 1 + 1 \times 1 + 3 \times 10 = 1 \quad (3.17)$$

Hasil lengkap kanal 2:

$$Y_2 = \begin{bmatrix} 1 & 4 \\ 2 & 1 \end{bmatrix}$$

b. *Pointwise*, filter 1×1 berukuran (2, 1) misalnya [0,5; 0,5]:

$$Z(i, j) = 0,5 \times Y_1(i, j) + 0,5 \times Y_2(i, j) \quad (3.18)$$

$$Z = \begin{bmatrix} 1,5 & 3,5 \\ 3,0 & 2,5 \end{bmatrix}$$


Hasil akhir merupakan gabungan informasi lintas kanal yang diperoleh secara efisien melalui dua tahap terpisah.

2. Transfer Learning dari ImageNet

XceptionNet yang digunakan dalam penelitian ini diinisialisasi dengan bobot yang telah dilatih pada dataset ImageNet [6, 7], yang terdiri dari 1,4 juta citra dalam 1.000 kelas. *Transfer learning* dari ImageNet memberikan fondasi representasi visual yang kuat, fitur-fitur tingkat rendah (tepi, tekstur) dan tingkat menengah (pola, bentuk) yang telah dipelajari dari ImageNet relevan dan dapat ditransfer ke tugas deteksi *deepfake*.

Model diimplementasikan menggunakan pustaka *timm* (*PyTorch Image Models*) melalui pemanggilan `timm.create_model("xception", pretrained=True)`. Lapisan klasifikasi asli ImageNet (1.000 kelas) diganti dengan lapisan *fully connected* tunggal yang menghasilkan satu nilai *logit* untuk klasifikasi biner (*real vs fake*). Dimensi fitur yang dihasilkan oleh *backbone* XceptionNet setelah *global average pooling* adalah 2.048.

3.4.2 Model Frekuensi FreqCNN



Gambar 3.8 Diagram Arsitektur FreqCNN

Model frekuensi dirancang untuk mengekstraksi dan menganalisis artefak pada domain frekuensi yang tidak terdeteksi oleh model spasial. Berbeda dengan XceptionNet yang memproses citra RGB secara langsung, FreqCNN memproses peta *magnitude* FFT yang merepresentasikan distribusi energi frekuensi dalam citra. Arsitektur ini dibangun khusus untuk tugas ini dengan desain yang lebih ringan namun mampu menangkap pola spektral yang khas dari citra *deepfake*.

1. Arsitektur Konvolusional

FreqCNN adalah jaringan konvolusional ringan yang dirancang khusus untuk memproses peta *magnitude* FFT berdimensi satu kanal. Arsitektur ini terdiri dari blok-blok konvolusional residual bertingkat (*FreqBlock*) yang secara progresif mengekstraksi fitur frekuensi dari resolusi rendah hingga tinggi.


Setiap *FreqBlock* mengimplementasikan koneksi residual yang terinspirasi dari ResNet (He et al., 2016) dan terdiri dari dua jalur paralel:

- Jalur utama: $\text{Conv2d}(3 \times 3, \text{padding} = 1) \rightarrow \text{BatchNorm2d} \rightarrow \text{ReLU}$.
- Jalur pintasan (*shortcut*), konvolusi 1×1 untuk menyesuaikan dimensi kanal ketika jumlah kanal input berbeda dari output. Apabila dimensi sudah sama, jalur pintasan berupa operasi identitas (*identity*).

Kedua jalur dijumlahkan secara elemen (*residual addition*) sebelum *max pooling* dengan *stride 2*:

$$\mathbf{y} = \text{MaxPool}_{2 \times 2} (\text{Conv}_{3 \times 3}(\mathbf{x}) + \text{Shortcut}(\mathbf{x})) \quad (3.19)$$

Koneksi *residual* ini mencegah degradasi gradien pada jaringan yang lebih dalam dan memungkinkan setiap blok mempelajari representasi fitur tambahan (*residual*) di atas representasi yang sudah ada.



Gambar 3.9 Arsitektur FreqBlock dengan Koneksi *Residual*

Konfigurasi yang digunakan dalam penelitian ini adalah *depth* = 5 dengan *base_channels* = 64, menghasilkan progresi kanal [64,128,256,512,512]. Dua blok terakhir menggunakan jumlah kanal yang sama (512), di mana jalur pintasan pada blok kelima berupa operasi identitas karena dimensi input dan output sudah sesuai. Pemilihan *base_channels* = 64 (alih-alih nilai *default* 32) dilatarbelakangi oleh karakteristik input berupa *crop* wajah dengan distribusi spektral yang relatif kaya: kapasitas representasi yang lebih besar pada tahap awal jaringan memberikan ruang yang memadai untuk menangkap variasi artefak frekuensi yang halus tanpa kehilangan informasi pada lapisan-lapisan dangkal.

Tabel 3.6 Arsitektur Layer-by-Layer FreqCNN (*depth* = 5, *base_channels* = 64)

<i>Layer</i>	<i>Type</i>	<i>Dimensi Input</i>	<i>Dimensi Output</i>	<i>Parameter</i>
FreqBlock 1	Conv(1→64, 3×3) + BN + Shortcut(1×1) + MaxPool	(1, 224, 224)	(64, 112, 112)	~900
FreqBlock 2	Conv(64→128, 3×3) + BN + Shortcut(1×1) + MaxPool	(64, 112, 112)	(128, 56, 56)	~82.400
FreqBlock 3	Conv(128→256, 3×3) + BN + Shortcut(1×1) + MaxPool	(128, 56, 56)	(256, 28, 28)	~329.000
FreqBlock 4	Conv(256→512, 3×3) + BN + Shortcut(1×1) + MaxPool	(256, 28, 28)	(512, 14, 14)	~1.313.000

FreqBlock 5	Conv(512→512, 3×3) + BN + Identity + MaxPool	(512, 14, 14)	(512, 7, 7)	~2.361.000
Dropout2d(0,2)	<i>Spatial dropout</i>	(512, 7, 7)	(512, 7, 7)	0
AdaptiveAvgPool	<i>Global average pooling</i>	(512, 7, 7)	(512, 1, 1)	0
FC 1	Linear(512→256) + ReLU	(512)	(256)	~131.000
Dropout(0,3)	<i>Dropout</i>	(256)	(256)	0
FC 2	Linear(256→1)	(256)	(1)	~257
Total				~4,2 juta

Meskipun jumlah parameter FreqCNN (~ 4.2 juta) lebih besar dibandingkan konfigurasi *default depth* = 3, *base_channels* = 32 (~ 130.000), model ini tetap jauh lebih kecil dari XceptionNet (~ 22,8 juta parameter). Kedalaman 5 blok dipilih untuk mengekstraksi fitur frekuensi yang lebih kaya, dengan blok-blok tambahan memungkinkan model menangkap pola spektral pada berbagai tingkat abstraksi, dari artefak frekuensi rendah (seperti distribusi energi global) hingga anomali frekuensi tinggi (seperti *spectral rolloff* dan *checkerboard patterns*). Koneksi residual memastikan bahwa pelatihan tetap stabil meskipun kedalaman jaringan bertambah.

Kedalaman FreqCNN dapat dikonfigurasi melalui parameter *freq_depth* dan *freq_base_channels*. Jumlah kanal berlipat dua pada setiap blok hingga batas maksimum $8 \times \text{base_channels} = 512$ untuk konfigurasi *base_channels* = 64 yang digunakan dalam penelitian ini.

2. Contoh Perhitungan *Forward Pass*

Berikut ditunjukkan contoh perhitungan *forward pass* pada satu blok konvolusional FreqCNN dengan input sederhana berukuran 4×4 , satu kanal.

Input (peta *magnitude* FFT tersederhanakan):

$$X_1 = \begin{bmatrix} 2,1 & 3,5 & 1,2 & 4,0 \\ 0,8 & 2,3 & 3,1 & 1,5 \\ 4,2 & 1,0 & 2,7 & 3,3 \\ 1,6 & 3,8 & 0,5 & 2,9 \end{bmatrix} \quad (3.20)$$

Konvolusi dengan *kernel* 3×3 (misalkan bobot **W** dan bias $b = 0$), *padding* = 1:

Posisi (0,0) dengan *zero padding*:

$$\begin{aligned} z_{0,0} &= 0 \cdot w_{00} + 0 \cdot w_{01} + 0 \cdot w_{02} + \\ &\quad 0 \cdot w_{10} + 2,1 \cdot w_{11} + 3,5 \cdot w_{12} + \\ &\quad 0 \cdot w_{20} + 0,8 \cdot w_{21} + 2,3 \cdot w_{22} \end{aligned} \quad (3.21)$$

BatchNorm, setelah seluruh posisi dihitung, *batch normalization* menormalisasi output:


$$\hat{z}_i = \frac{z_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \cdot \gamma + \beta \quad (3.22)$$

Di mana μ_B dan σ_B^2 adalah rata-rata dan varians *mini-batch*, γ dan β adalah parameter *learnable*, dan $\epsilon = 10^{-5}$ mencegah pembagian dengan nol.

ReLU, $ReLU(\hat{z}) = \max(0, \hat{z})$. Nilai negatif diubah menjadi nol.

MaxPool2d(2), pada grid 2×2 , diambil nilai maksimum. Dari output 4×4 , dihasilkan peta fitur berukuran 2×2 .

3.4.3 Model Hybrid HybridTwoBranch (Late Fusion)



Gambar 3.10 Diagram Arsitektur HybridTwoBranch (Late Fusion)

Model *hybrid* merupakan kontribusi utama penelitian ini. Arsitektur HybridTwoBranch menggabungkan fitur dari domain spasial dan domain frekuensi melalui mekanisme *late fusion*, kedua cabang mengekstraksi fitur secara independen, kemudian fitur digabungkan dan diproses bersama untuk klasifikasi akhir.

1. Cabang Spasial (XceptionNet Backbone)

Cabang spasial menggunakan XceptionNet sebagai *feature extractor* dengan konfigurasi $num_classes=0$, yang berarti lapisan klasifikasi dihilangkan dan model hanya menghasilkan vektor fitur. *Input* berupa citra RGB berukuran $(3, 224, 224)$ yang telah dinormalisasi menggunakan statistik ImageNet. Output berupa vektor fitur berdimensi 2.048 yang merepresentasikan fitur spasial tingkat tinggi dari citra wajah.

2. Cabang Frekuensi (FreqCNN Backbone)

Cabang frekuensi menggunakan bagian *backbone* dari FreqCNN (blok konvolusional + *global average pooling*) tanpa lapisan klasifikasi. *Input* berupa peta *magnitude* FFT berukuran $(1, 224, 224)$ yang telah dinormalisasi menggunakan *z-score* per dataset. Output berupa vektor fitur berdimensi 512 ($base_channels = 64$) yang merepresentasikan pola frekuensi dalam citra.

3. *Projection Layers* dan Penyeimbangan Dimensi

Tantangan utama dalam *late fusion* adalah ketidakseimbangan dimensi antara kedua cabang. Cabang spasial menghasilkan vektor berdimensi 2.048, sedangkan cabang frekuensi hanya 512, dengan rasio 4:1. Apabila kedua vektor langsung digabungkan (*concatenation*), fitur spasial akan mendominasi proses klasifikasi karena magnitudonya yang jauh lebih besar.

Untuk mengatasi hal ini, kedua cabang diproyeksikan ke dimensi yang sama ($PROJ_DIM = 256$) melalui lapisan proyeksi:

$$\mathbf{h}_{spatial} = \text{ReLU}\left(\text{BN}(\mathbf{W}_s \cdot \mathbf{f}_{spatial} + \mathbf{b}_s)\right) \quad (3.23)$$

$$\mathbf{h}_{freq} = \text{ReLU}\left(\text{BN}(\mathbf{W}_f \cdot \mathbf{f}_{freq} + \mathbf{b}_f)\right) \quad (3.24)$$

di mana $\mathbf{W}_s \in \mathbb{R}^{256 \times 2048}$ dan $\mathbf{W}_f \in \mathbb{R}^{256 \times 512}$ adalah matriks bobot proyeksi, BN adalah *batch normalization* 1D, dan ReLU adalah fungsi aktivasi. Setelah proyeksi, kedua cabang memiliki representasi berdimensi sama (256) yang dapat digabungkan secara seimbang.

4. *Squeeze-and-Excitation (SE) Gating*

Setelah kedua vektor fitur terproyeksi digabungkan melalui konkatenasi ($\mathbf{h}_{fused} = [\mathbf{h}_{spatial}; \mathbf{h}_{freq}] \in \mathbb{R}^{512}$), diterapkan mekanisme *Squeeze-and-Excitation (SE) gating* [36] yang memungkinkan model mempelajari bobot kepentingan per dimensi fitur secara adaptif.

Arsitektur *SE gate* terdiri dari:

- Squeeze**, kompresi vektor fusi dari 512 dimensi ke 128 dimensi melalui transformasi linier, diikuti aktivasi ReLU.
- Excitation**, ekspansi kembali ke 512 dimensi melalui transformasi linier, diikuti fungsi *sigmoid* yang menghasilkan bobot gerbang (*gate weights*) pada rentang $[0, 1]$.
- Pengalihan elemen**, vektor fusi asli dikalikan secara elemen-per-elemen (*element-wise*) dengan bobot gerbang.

Secara matematis:

$$\mathbf{g} = \sigma(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \cdot \mathbf{h}_{fused} + \mathbf{b}_1) + \mathbf{b}_2) \quad (3.25)$$

$$\hat{\mathbf{h}}_{fused} = \mathbf{h}_{fused} \odot \mathbf{g} \quad (3.26)$$

di mana $\mathbf{W}_1 \in \mathbb{R}^{128 \times 512}$, $\mathbf{W}_2 \in \mathbb{R}^{512 \times 128}$, σ adalah fungsi *sigmoid*, dan $\odot$ adalah perkalian elemen. Mekanisme ini memungkinkan model untuk menekan (*suppress*) fitur

yang tidak informatif dan memperkuat (*enhance*) fitur yang diskriminatif, baik dari cabang spasial maupun frekuensi, secara adaptif berdasarkan input.

5. Classifier Head

Vektor fitur yang telah melalui SE *gating* ($\hat{\mathbf{h}}_{fused} \in \mathbb{R}^{512}$) diteruskan ke kepala klasifikasi (*classifier head*) yang terdiri dari:

- Dropout(0,5)**, regularisasi pada representasi fusi untuk mencegah *overfitting*, dengan tingkat *dropout* yang moderat agar tidak menghilangkan terlalu banyak sinyal pada *dataset* berukuran kecil.
- Linear(512 $\rightarrow$ 128)**, reduksi dimensi.
- ReLU**, fungsi aktivasi.
- Dropout(0,5)**, regularisasi tambahan.
- Linear(128 $\rightarrow$ 1)**, menghasilkan satu nilai *logit* untuk klasifikasi biner.

Output *logit* diproses oleh fungsi *loss* BCEWithLogitsLoss yang secara internal menerapkan fungsi *sigmoid* sebelum menghitung *binary cross-entropy*.

6. Contoh Perhitungan Late Fusion

Berikut ditunjukkan contoh perhitungan *late fusion* yang disederhanakan dengan dimensi kecil untuk ilustrasi.

- Fitur input (disederhanakan ke 4 dimensi per cabang):

$$\mathbf{f}_{spatial} = [0,2; 1,2; -0,3; 0,5], \mathbf{f}_{freq} = [0,4; -0,1; 0,7; 0,2] \quad (3.27)$$

- Proyeksi (4 $\rightarrow$ 4, disederhanakan tanpa BN):

Misalkan $\mathbf{W}_s$ dan $\mathbf{W}_f$ adalah matriks identitas, maka:

$$\mathbf{h}_{spatial} = \text{ReLU}(\mathbf{f}_{spatial}) = [0,8; 1,2; 0; 0,5]$$

$$\mathbf{h}_{freq} = \text{ReLU}(\mathbf{f}_{freq}) = [0,4; 0; 0,7; 0,2].$$

- Konkatenasi

$$\mathbf{h}_{fused} = [0,8; 1,2; 0; 0,5; 0,4; 0; 0,7; 0,2] \in \mathbb{R}^8 \quad (3.28)$$

- SE *Gating* (8 $\rightarrow$ 2 $\rightarrow$ 8, $\hat{\text{reduction}} = 4$):

$$\text{Squeeze: } \mathbf{s} = \text{ReLU}(\mathbf{W}_1 \cdot \mathbf{h}_{fused}).$$

$$\text{Misalkan hasilnya } \mathbf{s} = [1,5; 0,8]$$

$$\text{Excitation: } \mathbf{g} = \sigma(\mathbf{W}_2 \cdot \mathbf{s}).$$

$$\text{Misalkan hasilnya } \mathbf{g} = [0,9; 0,7; 0,3; 0,8; 0,6; 0,2; 0,9; 0,5]$$

Gating:

$$\hat{\mathbf{h}}_{fused} = \mathbf{h}_{fused} \odot \mathbf{g} = [0,72; 0,84; 0; 0,40; 0,24; 0; 0,63; 0,10] \quad (3.29)$$

Terlihat bahwa SE *gate* menekan dimensi ke-3 dan ke-6 (nilai *gate* rendah: 0,3 dan 0,2) sambil mempertahankan dimensi ke-1 dan ke-7 (nilai *gate* tinggi: 0,9 dan 0,9). Mekanisme ini memungkinkan model untuk secara adaptif memilih fitur yang paling diskriminatif dari kedua cabang.

e. Klasifikasi:

$$\text{Logit: } z = \mathbf{w}^T \hat{\mathbf{h}}_{\text{fused}} + \mathbf{b}.$$

Misalkan $z = 2,1$

$$\text{Probabilitas: } p = \sigma(2,1) = \frac{1}{1+e^{-2,1}} = 0,891$$

Prediksi: $p > 0,5 \Rightarrow \text{fake}$ (label 1).

3.4.4 Perbandingan Arsitektur Model

Untuk memberikan evaluasi yang komprehensif, penelitian ini membandingkan ketiga arsitektur model secara sistematis. Perbandingan ini memungkinkan analisis kontribusi individual masing-masing domain (spasial dan frekuensi) serta evaluasi apakah penggabungan keduanya melalui model *hybrid* menghasilkan peningkatan performa yang signifikan.

Tabel 3.6 merangkum perbedaan utama antara ketiga arsitektur, meliputi jenis input, *backbone* yang digunakan, mekanisme fusi, jumlah parameter, dan domain analisis. Sementara Tabel 3.7 merinci dimensi fitur pada setiap komponen model *hybrid*, menunjukkan aliran data dari *input* hingga keluaran *logit* klasifikasi.

Perbedaan paling mendasar antara ketiga model terletak pada domain informasi yang dieksploitasi: model spasial mengandalkan fitur visual tingkat tinggi dari XceptionNet yang telah *pretrained*, model frekuensi mengekstraksi pola spektral menggunakan FreqCNN yang dilatih dari awal, dan model *hybrid* menggabungkan keduanya melalui proyeksi dimensi seimbang dan SE *gating* yang adaptif. Desain tiga varian ini secara langsung menjawab rumusan masalah pertama dan kedua penelitian, yaitu bagaimana membangun detektor *deepfake* yang lebih akurat dan bagaimana mengevaluasi kontribusi masing-masing jenis fitur.

Tabel 3.7 Perbandingan Tiga Arsitektur Model

Aspek	<i>Spatial</i> (XceptionNet)	<i>Frequency</i> (FreqCNN)	<i>Hybrid</i> (HybridTwoBranch)
-------	---------------------------------	-------------------------------	------------------------------------

Input	RGB (3, 224, 224)	FFT (1, 224, 224)	RGB + FFT (terpisah)
<i>Backbone</i>	<i>XceptionNet (pretrained)</i>	FreqCNN (from scratch)	<i>XceptionNet</i> + FreqCNN
Dimensi fitur	2.048	512	$256 + 256 = 512$ (terproyeksi)
Mekanisme fusi	—	—	Konkatenasi + SE <i>Gating</i>
Total parameter	~22,8 juta	~4.2 juta	~27,7 juta
<i>Pretrained</i>	Ya (ImageNet)	Tidak	Parsial (cabang spasial)
Domain	Spasial	Frekuensi	Keduanya

Tabel 3.8 Dimensi Fitur per Komponen Model *Hybrid*

Komponen	Dimensi Input	Dimensi Output	Operasi
<i>XceptionNet backbone</i>	(3, 224, 224)	2.048	Ekstraksi fitur + GAP
FreqCNN <i>backbone</i>	(1, 224, 224)	512	5 FreqBlock <i>residual</i> + GAP
Proyeksi spasial	2.048	256	Linear + BN + ReLU
Proyeksi frekuensi	512	256	Linear + BN + ReLU
Konkatenasi	$256 + 256$	512	torch.cat
SE <i>Gate</i>	512	512	<i>Squeeze-Excitation</i>
<i>Classifier</i>	512	1	FC + <i>Dropout</i>

3.5 Strategi Pelatihan Model

Strategi pelatihan yang tepat sangat menentukan performa akhir model, terutama pada arsitektur *hybrid* yang menggabungkan komponen *pretrained* (XceptionNet) dengan komponen yang dilatih dari awal (FreqCNN). Beberapa teknik optimasi diterapkan untuk mengatasi tantangan ini, termasuk *transfer learning* dengan *backbone freezing*, *differential learning rate*, penjadwalan *learning rate* adaptif, serta mekanisme *early stopping* untuk mencegah *overfitting*. Bagian berikut menjelaskan setiap strategi secara detail.

3.5.1 Transfer Learning dan Backbone Freezing

Strategi *transfer learning* diterapkan pada model *spatial* dan *hybrid* yang menggunakan *backbone* XceptionNet. Bobot yang telah dilatih pada ImageNet memberikan inisialisasi yang kuat, sehingga model tidak perlu mempelajari fitur visual dasar dari awal.

Pada seluruh model yang menggunakan *backbone* XceptionNet *pretrained* yaitu model *spatial*, *hybrid*, dan *early fusion*, *backbone* dibekukan (*frozen*) selama 3 *epoch* pertama pelatihan. Selama periode ini, hanya parameter lapisan baru yang diperbarui: pada model *spatial*, lapisan klasifikasi akhir (*head*); pada model *hybrid*, FreqCNN, proyeksi, SE *gate*, dan *classifier*; pada model *early fusion*, seluruh parameter *backbone* dibekukan.

Pembekuan ini bertujuan agar lapisan-lapisan baru yang diinisialisasi secara acak dapat mempelajari representasi yang bermakna terlebih dahulu sebelum gradien mengalir ke *backbone* yang telah *pretrained*. Tanpa pembekuan, gradien acak dari lapisan baru yang belum terlatih dapat merusak bobot *pretrained* yang sudah optimal (*catastrophic forgetting*).

Pada *epoch* ke-4, seluruh parameter *backbone* dilepaskan (*unfreezing*) dengan pemanggilan `requires_grad_(True)`, memungkinkan *fine-tuning* menyeluruh untuk mengadaptasi fitur ImageNet ke domain deteksi *deepfake*.

3.5.2 Differential Learning Rate

Untuk melindungi bobot *pretrained* yang sudah berkualitas sambil memungkinkan lapisan baru belajar dengan cepat, digunakan *differential learning rate*, laju pembelajaran yang berbeda untuk kelompok parameter yang berbeda:

Tabel 3.9 *Learning Rate* per Kelompok Parameter

Kelompok Parameter	<i>Learning Rate</i>	Diterapkan Pada
<i>Backbone (pretrained)</i>	$2 \times 10^{-5} \left(\frac{base}{10} \right)$	Parameter <i>XceptionNet</i>
<i>Cabang Frekuensi</i>	$5 \times 10^{-5} (base \times 0,25)$	Parameter FreqCNN dalam model <i>hybrid</i>
<i>Head</i> (lapisan baru)	$2 \times 10^{-4} (base)$	Proyeksi, SEgate, <i>classifier</i> ; juga FreqCNN <i>standalone</i>

Learning rate backbone yang 10 kali lebih rendah memastikan bahwa *fine-tuning* dilakukan secara halus tanpa menghancurkan representasi visual yang telah dipelajari dari ImageNet, sementara lapisan baru mendapat *learning rate* yang lebih tinggi untuk konvergensi yang lebih cepat. Khusus pada model *hybrid*, cabang FreqCNN diberikan

learning rate menengah (25% dari *base*) untuk mencegah gradien dari *branch* frekuensi yang diinisialisasi secara acak mendominasi pembaruan bobot pada awal pelatihan, sekaligus menjaga keseimbangan kontribusi antara kedua cabang.


3.5.3 Penjadwalan *Learning Rate*

Penjadwalan *learning rate* menggabungkan dua fase menggunakan *SequentialLR*:

1. **Linear warmup** (3 epoch), *learning rate* dinaikkan secara linier dari 10% ke 100% dari nilai *base*. *LinearLR*(*start_factor*=0.1, *end_factor*=1.0, *total_iters*=3). Fase ini mencegah pembaruan bobot yang terlalu besar pada iterasi awal, terutama penting pada *backbone pretrained*.
2. **Cosine annealing** (epoch ke-4 hingga selesai), *learning rate* diturunkan secara halus mengikuti kurva kosinus dari nilai *base* menuju 1×10^{-6} . *CosineAnnealingLR*(*T_max*=max(*epochs*-3, 1), *eta_min*= $1e-6$). Penurunan yang mulus ini menghindari *shock* akibat penurunan LR yang tiba-tiba.

Kurva *learning rate* untuk pelatihan 30 epoch:

1. Epoch 1: LR = $0,1 \times \text{base} = 2 \times 10^{-5}$
2. Epoch 2: LR = $0,4 \times \text{base} = 8 \times 10^{-5}$
3. Epoch 3: LR = $0,7 \times \text{base} = 1,4 \times 10^{-4}$
4. Epoch 4: LR = $1,0 \times \text{base} = 2 \times 10^{-4}$ (puncak; *cosine decay* dimulai)
5. Epoch 4-30: *Cosine decay* dari 2×10^{-4} menuju 1×10^{-6}



Gambar 3.11 Kurva Penjadwalan *Learning Rate* (Warmup Cosine Decay)

3.5.4 Fungsi Loss, BCEWithLogitsLoss dengan Label Smoothing

Fungsi *loss* yang digunakan adalah *Binary Cross-Entropy with Logits* (BCEWithLogitsLoss), sebagaimana telah dibahas pada BAB II, yang menggabungkan fungsi *sigmoid* dan *binary cross-entropy* dalam satu operasi yang stabil secara numerik:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [w_p \cdot y_i \cdot \log(\sigma(z_i)) + (1 - y_i) \cdot \log(1 - \sigma(z_i))] \quad (3.30)$$

di mana z_i adalah *logit* (output model sebelum *sigmoid*), $\sigma(z) = \frac{1}{1+e^{-z}}$ adalah fungsi *sigmoid*, dan y_i adalah label target, dan w_p adalah *pos_weight* untuk penyeimbangan kelas.

1. Penyeimbangan Kelas (*pos_weight*)

Untuk menangani ketidakseimbangan kelas yang dapat terjadi pada pembagian dataset, diterapkan *positive class weighting*:

$$w_p = \frac{n_{neg}}{n_{pos}} \quad (3.31)$$

di mana n_{neg} dan n_{pos} adalah jumlah sampel kelas negatif (*real*) dan positif (*fake*) dalam set pelatihan. Bobot ini dikalikan pada komponen *loss* untuk sampel positif, sehingga kelas minoritas mendapat pengaruh lebih besar pada pembaruan gradien. Apabila dataset seimbang ($n_{neg} = n_{pos}$), maka $w_p = 1$ dan fungsi *loss* menjadi *BCEWithLogitsLoss* standar.

2. Label Smoothing

Label smoothing merupakan teknik regularisasi yang dapat diterapkan untuk mencegah model menjadi terlalu percaya diri (*overconfident*):

$$y'_i = y_i \times (1 - \alpha) + \alpha \times 0,5 \quad (3.32)$$

Sebagai ilustrasi, dengan $\alpha = 0,02$, transformasi ini mengubah label biner menjadi: $0 \rightarrow 0,01$ dan $1 \rightarrow 0,99$, sehingga model tidak perlu mendorong *logit* ke nilai ekstrem ($\pm \infty$). Pada konfigurasi akhir yang digunakan dalam eksperimen ini, *label smoothing* diaktifkan dengan $\alpha = 0,05$ sebagai regularisasi ringan untuk mencegah model menjadi terlalu percaya diri pada dataset dengan ukuran sampel kecil (mulai dari $n = 100$). Pada dataset berukuran kecil, sinyal positif yang terbatas menjadi semakin lemah apabila label di-*smooth*, sehingga model kesulitan membedakan kelas *real* dan *fake*.

3. Contoh Perhitungan BCEWithLogitsLoss

Sebagai ilustrasi, berikut ditunjukkan contoh perhitungan BCEWithLogitsLoss dengan *label smoothing* $\alpha = 0,05$ (nilai yang digunakan pada konfigurasi akhir), untuk satu sampel dengan *logit* $z = 2,5$, label asli $y = 1$ (*fake*), dan $w_p = 1$ (dataset seimbang).

a. Label Smoothing

$$y'_i = 1 \times (1 - \alpha) + \alpha \cdot 0,5 \quad (3.33)$$

$$y'_i = 1 \times (1 - 0,05) + 0,05 \cdot 0,5 = \mathbf{0,975}$$

b. *Sigmoid*

$$\sigma(2,5) = \frac{1}{1+e^{-2,5}} = \frac{1}{1+0,0821} = \frac{1}{1,0821} = \mathbf{0,924} \quad (3.34)$$

c. *Loss*

$$\begin{aligned} L &= -[y' \cdot \ln(\sigma) + (1 - y') \cdot \ln(1 - \sigma)] \\ &= -[0,975 \times (-0,0790) + 0,025 \times (-2,577)] \\ &= -[-0,0770 + (-0,0644)] \\ &= -(-0,1415) = \mathbf{0,1415} \end{aligned} \quad (3.35)$$

Nilai *loss* yang rendah (0,1415) menunjukkan bahwa prediksi model (probabilitas 0,924 untuk *fake*) sudah mendekati label target *ter-smooth* (0,975). Pada awal pelatihan, nilai *loss* umumnya jauh lebih tinggi dan menurun seiring konvergensi model.

3.5.5 Optimisasi AdamW dengan *Gradient Accumulation*

Optimizer yang digunakan adalah AdamW [43], varian dari Adam [42] dengan *decoupled weight decay*, dengan konfigurasi $lr = 2 \times 10^{-4}$ dan $weight_{decay} = 1 \times 10^{-4}$. Berbeda dengan Adam standar yang menambahkan regularisasi L2 ke gradien sebelum penskalaan adaptif, AdamW menerapkan *weight decay* secara langsung pada bobot setelah langkah pembaruan Adam. Perbedaan ini penting karena pada Adam standar, efektif regularisasi bervariasi antar parameter bergantung pada *learning rate* adaptifnya, sedangkan pada AdamW, regularisasi konsisten untuk semua parameter. Konsistensi ini sangat bermanfaat dalam skenario *transfer learning* di mana parameter *pretrained* dan parameter baru memiliki skala gradien yang sangat berbeda.

Gradient accumulation diterapkan dengan $accum_steps = 2$, yang berarti gradien diakumulasikan selama 2 *batch* sebelum pembaruan bobot dilakukan. Dengan ukuran *batch* per langkah sebesar 16, ukuran *batch* efektif menjadi $16 \times 2 = 32$. Teknik ini memungkinkan penggunaan *batch* efektif yang lebih besar tanpa meningkatkan kebutuhan memori GPU. *Loss* dibagi dengan $accum_steps$ sebelum *backpropagation* untuk menjaga skala gradien yang konsisten.

3.5.6 *Gradient Clipping*

Gradient clipping berdasarkan norma L2 diterapkan dengan batas $max_norm = 5,0$:

$$\mathbf{g} \leftarrow \begin{cases} \mathbf{g} & \text{jika } \|\mathbf{g}\|_2 \leq 5,0 \\ \frac{5,0 \cdot \mathbf{g}}{\|\mathbf{g}\|_2} & \text{jika } \|\mathbf{g}\|_2 > 5,0 \end{cases} \quad (3.36)$$

Ambang batas 5,0 dipilih untuk mengakomodasi *learning rate* yang lebih tinggi (2×10^{-4}) sambil tetap mencegah ledakan gradien (*gradient explosion*), terutama pada *epoch* ke-4 ketika *backbone* XceptionNet dilepaskan (*unfreezing*) dan aliran gradien dari seluruh jaringan secara tiba-tiba meningkatkan norma gradien. Pada implementasi dengan *mixed precision* (AMP), *scaler.unscale_()* dipanggil sebelum *clipping* untuk memastikan gradien berada pada skala aslinya.

3.5.7 Mixed Precision Training (AMP)

Pelatihan dengan presisi campuran (*Automatic Mixed Precision* / AMP) diterapkan pada GPU CUDA menggunakan *torch.cuda.amp.autocast()* dan *GradScaler*. Dalam mode ini, operasi *forward pass* dan *backward pass* dilakukan dalam format *float16* (setengah presisi), sedangkan pembaruan bobot oleh *optimizer* dilakukan dalam format *float32* (presisi penuh). AMP memberikan percepatan pelatihan hingga $\sim 2 \times$ dengan penurunan akurasi yang minimal. Optimisasi TF32 juga diaktifkan untuk GPU arsitektur Ampere ke atas.

3.5.8 Early Stopping

Mekanisme *early stopping* digunakan untuk menghentikan pelatihan secara otomatis ketika model tidak lagi menunjukkan peningkatan performa pada set validasi. Konfigurasi yang digunakan:

1. Metrik pemantauan: AUC validasi (metrik utama).
2. Kesabaran (*patience*): 12 *epoch* berturut-turut tanpa peningkatan AUC.
3. Jumlah *epoch* maksimum: 30.
4. Tindakan: Pelatihan dihentikan dan *checkpoint* terbaik digunakan untuk evaluasi.

Penggunaan *patience* 12 *epoch* memberikan waktu yang cukup bagi model untuk pulih dari degradasi performa sementara yang sering terjadi setelah *unfreezing backbone* pada *epoch* ke-4. Tanpa *patience* yang memadai, *early stopping* dapat menghentikan pelatihan terlalu dini sebelum model beradaptasi dengan parameter *backbone* yang baru dilepaskan.

AUC dipilih sebagai metrik pemantauan karena bersifat independen terhadap *threshold* mengevaluasi kemampuan model membedakan kelas positif dan negatif pada seluruh kemungkinan *threshold*, berbeda dengan akurasi yang bergantung pada satu nilai *threshold* tertentu.

3.5.9 Seleksi Model Terbaik

Pada setiap *epoch*, apabila AUC validasi meningkat dibandingkan nilai terbaik sebelumnya, *checkpoint* model disimpan dalam format `{"state_dict": ..., "epoch": ..., "config": ...}`. *Checkpoint* terbaik berdasarkan AUC validasi tertinggi digunakan untuk evaluasi akhir pada set pengujian.

Tabel 3.10 Ringkasan *Hyperparameter* Penelitian

Parameter	Nilai	Keterangan
<i>Optimizer</i>	AdamW	<i>Decoupled weight decay</i> (Loshchilov & Hutter, 2019)
<i>Learning rate (base)</i>	2×10^{-4}	Lapisan baru
<i>Learning rate (backbone)</i>	2×10^{-5}	<i>XceptionNet pretrained</i> (base/10)
<i>Weight decay</i>	1×10^{-4}	<i>Decoupled weight decay</i>
<i>Batch size</i>	16	Per langkah; efektif 32
<i>Gradient accumulation</i>	2 langkah	Semua model; <i>batch</i> efektif = 32
<i>Epoch maksimum</i>	30	Dibatasi <i>early stopping</i>
<i>Early stopping patience</i>	12	Tanpa peningkatan AUC
<i>Label smoothing</i>	0,0 (nonaktif)	Dinonaktifkan untuk dataset kecil
<i>Pos weight</i>	$n_{\text{neg}} / n_{\text{pos}}$	Penyeimbangan kelas
<i>Gradient clipping</i>	$\text{max_norm} = 5,0$	Norma L2
<i>LR warmup</i>	3 <i>epoch</i>	10% $\rightarrow$ 100% linear
<i>LR schedule</i>	<i>Cosine annealing</i>	<i>Decay</i> ke 1×10^{-6}
<i>Backbone freeze</i>	3 <i>epoch</i>	Semua model <i>pretrained</i>
<i>Mixed precision</i>	AMP (<i>float16</i>)	CUDA saja
<i>FreqCNN depth</i>	5	~ 4.2 juta parameter
<i>Seed</i>	0, 1, 2	Reproduktibilitas (3 <i>seed</i>)
<i>Framework</i>	PyTorch + timm	<i>XceptionNet</i> via timm

3.6 Desain Eksperimen

Desain eksperimen dirancang untuk mengevaluasi secara sistematis kontribusi masing-masing domain analisis serta keunggulan pendekatan *hybrid* dalam deteksi *deepfake*. Evaluasi dilakukan melalui eksperimen faktorial yang mengkombinasikan tiga variabel utama: arsitektur model, dataset pelatihan, dan ukuran sampel. Setiap konfigurasi diuji secara *in-dataset* maupun *cross-dataset* untuk mengukur kemampuan generalisasi, dan setiap eksperimen diulang dengan beberapa *seed* berbeda untuk memperoleh estimasi performa yang reliabel.

3.6.1 Matriks Eksperimen

Penelitian ini dirancang sebagai eksperimen faktorial yang menguji kombinasi dari tiga faktor utama: arsitektur model, *dataset* pelatihan, dan ukuran sampel. Setiap kombinasi dijalankan dengan tiga *seed* berbeda untuk memperoleh estimasi rata-rata dan simpangan baku yang reliabel.

Tabel 3.11 Matriks Eksperimen

Dimensi	Nilai	Jumlah
Model	<i>spatial, freq, hybrid</i>	3
Dataset pelatihan	FFPP, CDF	2
Ukuran sampel FFPP	100, 300, 600, 1000	4
Ukuran sampel CDF	100, 250, 500, 750	4
<i>Seed</i>	0, 1, 2	3
Evaluasi	<i>In-dataset, cross-dataset</i>	2

Total pelatihan: $3 \times 2 \times 4 \times 3 = 72$ run.

Total evaluasi: $72 \times 2 = 144$ evaluasi (setiap model dievaluasi secara *in-dataset* dan *cross-dataset*)

3.6.2 Evaluasi *In-Dataset*

Evaluasi *in-dataset* mengukur performa model pada set pengujian dari dataset yang sama dengan *dataset* pelatihan:

1. Model dilatih pada FFPP, lalu dievaluasi pada set pengujian FFPP.
2. Model dilatih pada CDF, lalu dievaluasi pada set pengujian CDF.

Evaluasi ini mengukur seberapa baik model mempelajari pola *deepfake* dari distribusi data pelatihannya.

3.6.3 Evaluasi *Cross-Dataset*

Evaluasi *cross-dataset* mengukur kemampuan generalisasi model pada *dataset* yang berbeda dari dataset pelatihan:

1. Model dilatih pada FFPP, lalu dievaluasi pada set pengujian CDF.
2. Model dilatih pada CDF, lalu dievaluasi pada set pengujian FFPP.

Evaluasi silang ini sangat penting karena dalam skenario nyata, detektor *deepfake* harus mampu mengenali manipulasi dari metode yang belum pernah dilihat selama pelatihan. Perbedaan performa antara evaluasi *in-dataset* dan *cross-dataset* diukur melalui metrik generalisasi *drop*:

$$\Delta = F1_{in-dataset} - F1_{cross-dataset} \quad (3.37)$$

Nilai Δ yang besar menunjukkan bahwa model terlalu bergantung pada pola spesifik dataset pelatihan dan tidak memiliki kemampuan generalisasi yang baik.

3.6.4 Variabel Penelitian

Variabel penelitian diklasifikasikan menjadi tiga jenis: variabel independen yang dimanipulasi secara sistematis, variabel dependen yang diukur sebagai indikator performa, dan variabel kontrol yang dijaga konstan untuk memastikan validitas perbandingan antar eksperimen. Tabel 3.11 merangkum seluruh variabel yang terlibat dalam penelitian ini.

Tabel 3.12 Variabel Penelitian

Jenis	Variabel	Nilai
Independen	Arsitektur model	<i>spatial, freq, hybrid</i>
	Dataset pelatihan	FFPP, CDF
	Ukuran sampel	100–1000 (bervariasi per dataset)
Dependen	<i>Accuracy, Precision, Recall, F1-Score, AUC</i>	Kontinu [0, 1]
	<i>Generalization drop (Δ)</i>	$F1_{in} - F1_{cross}$
Kontrol	<i>Hyperparameter</i> pelatihan	Tetap (Tabel 3.9)
	<i>Seed</i>	0, 1, 2
	Pembagian data	70/15/15 terstratifikasi
	Ukuran citra	224×224

3.7 Metode Evaluasi Model

Evaluasi model dilakukan pada *frame-frame* dari set pengujian (*test set*) yang telah dipisahkan pada level video untuk mencegah kebocoran data. Metrik evaluasi yang digunakan *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC beserta *confusion matrix* telah didefinisikan secara detail pada BAB II. AUC digunakan sebagai metrik utama untuk seleksi model dan *early stopping* karena sifatnya yang independen terhadap *threshold*. Selain evaluasi pada *threshold* tetap ($\theta = 0,5$), penelitian ini juga menghitung *threshold* optimal menggunakan statistik J Youden ($J = TPR - FPR$) yang memberikan keseimbangan optimal antara sensitivitas dan spesifisitas.

Pada bagian ini dibahas metrik tambahan yang spesifik untuk desain eksperimen silang dataset.

3.7.1 Generalization Drop

Metrik *generalization drop* mengukur degradasi performa model ketika dievaluasi pada dataset yang berbeda dari dataset pelatihan:

$$\Delta = F1_{in-dataset} - F1_{cross-dataset} \quad (3.38)$$

Nilai Δ yang mendekati nol menunjukkan generalisasi yang baik. Model mampu mendeteksi *deepfake* dari metode yang belum pernah dilihat. Nilai Δ yang besar menunjukkan bahwa model menghafal pola spesifik dataset pelatihan.

3.7.2 Contoh Perhitungan Metrik

Sebagai ilustrasi, berikut ditunjukkan contoh perhitungan seluruh metrik dari suatu *confusion matrix*:

Tabel 3.13 Contoh *Confusion Matrix*

	Prediksi <i>Fake</i>	Prediksi <i>Real</i>	Total
Aktual <i>Fake</i>	TP = 42	FN = 8	50
Aktual <i>Real</i>	FP = 5	TN = 45	50
Total	47	53	100

Tabel 3.14 Perhitungan Metrik Evaluasi

Metrik	Perhitungan	Hasil
<i>Accuracy</i>	$(42 + 45) / (42 + 45 + 5 + 8) = 87/100$	0,870

<i>Precision</i>	$42 / (42 + 5) = 42/47$	0,894
<i>Recall</i>	$42 / (42 + 8) = 42/50$	0,840
<i>F1-Score</i>	$2 \times 0,894 \times 0,840 / (0,894 + 0,840)$	0,866
AUC	(dihitung dari kurva ROC)	—

Dari contoh di atas, model berhasil mendeteksi 42 dari 50 *frame fake* (*recall* = 84%) dengan tingkat *false alarm* yang rendah (5 dari 50 *frame real* salah diklasifikasi, FPR = 10%). *F1-Score* sebesar 0,866 menunjukkan keseimbangan yang baik antara *precision* dan *recall*.

3.8 Analisis Sistem

Subbab ini menjabarkan kebutuhan perangkat keras dan perangkat lunak yang digunakan untuk mengimplementasikan dan menjalankan seluruh *pipeline* penelitian, mulai dari *preprocessing* hingga evaluasi, beserta justifikasi pemilihan setiap teknologi.

3.8.1 Kebutuhan Perangkat Keras

Pelatihan model *deep learning* membutuhkan akselerasi GPU. Penelitian ini dikembangkan dan dijalankan pada lingkungan Google Colab Pro. Spesifikasi perangkat keras dirangkum pada Tabel 3.17.

Tabel 3.15 Kebutuhan Perangkat Keras

Komponen	Spesifikasi	Peran
GPU	NVIDIA berdukungan CUDA (Tesla T4 15 GB / V100)	Pelatihan dan inferensi model; mendukung <i>mixed precision</i> (AMP) dan TF32 pada arsitektur Ampere ke atas
RAM	≥ 12 GB	Pemuatan <i>batch</i> citra dan <i>cache</i> FFT ke memori
Penyimpanan	Beberapa GB	Menyimpan <i>frame</i> hasil ekstraksi, <i>cache</i> FFT (.npy), dan <i>checkpoint</i> model
CPU	<i>Multi-core</i>	<i>Fallback</i> untuk eksperimen kecil; ekstraksi <i>frame</i> paralel via <i>multiprocessing</i>

3.8.2 Kebutuhan Perangkat Lunak

Implementasi menggunakan bahasa **Python 3.9** dengan ekosistem pustaka *deep learning* dan pemrosesan citra yang dirangkum pada Tabel 3.18.

Tabel 3.16 Kebutuhan Perangkat Lunak

Pustaka / Alat	Peran dalam penelitian	Justifikasi pemilihan
PyTorch (<i>torch</i>)	<i>Framework</i> utama: definisi model, <i>autograd</i> , <i>training loop</i> , <i>mixed precision</i> (AMP), optimisasi (AdamW), fungsi <i>loss</i> (<i>BCEWithLogitsLoss</i>), dan penjadwalan <i>learning rate</i>	Dukungan GPU penuh dan fleksibilitas tinggi untuk riset arsitektur kustom
<i>torchvision</i>	Transformasi dan augmentasi citra pada cabang spasial	Terintegrasi erat dengan PyTorch
<i>timm</i> (<i>PyTorch Image Models</i>)	Menyediakan arsitektur XceptionNet beserta bobot <i>pretrained</i> ImageNet	Implementasi <i>backbone</i> yang teruji dan akses langsung ke bobot <i>transfer learning</i>
<i>facenet-pytorch</i>	Menyediakan MTCNN untuk deteksi dan <i>cropping</i> wajah pada tahap <i>preprocessing</i> (subbab 3.3.2)	Detektor wajah ringan, akurat, dan mudah diintegrasikan
OpenCV (<i>opencv-python</i>)	Membaca video, mengekstraksi <i>frame</i> , dan konversi ruang warna (BGR→RGB, <i>grayscale</i>)	Pustaka standar untuk I/O video dan operasi citra
NumPy	Komputasi Transformasi Fourier 2D (<i>fft2</i> , <i>fftshift</i>) dan operasi numerik berbasis <i>array</i>	Fondasi komputasi numerik Python
scikit-learn	Pembagian <i>train/validation/test</i> terstratifikasi (<i>train_test_split</i>) dan perhitungan metrik (AUC)	Standar evaluasi dan pembagian data yang <i>reproducible</i>
pandas	Pengelolaan berkas manifes CSV (<i>video_id</i> , <i>label</i> , <i>frames_dir</i>) dan tabel hasil	Manipulasi data tabular yang efisien
Pillow (PIL)	Pemuatan dan manipulasi citra sebagai <i>backend</i> transformasi <i>torchvision</i>	Format citra standar di ekosistem Python
PyYAML	Membaca berkas konfigurasi terpusat <i>config.yaml</i>	Konfigurasi eksperimen yang ringkas dan mudah dibaca
tqdm	Menampilkan <i>progress bar</i> pada proses berdurasi panjang	Pemantauan eksekusi pipeline
matplotlib	Visualisasi hasil (kurva ROC, <i>learning curve</i>) pada BAB IV	Pembuatan grafik publikasi

3.8.3 Konfigurasi dan Orkestrasi *Pipeline*

Seluruh hyperparameter dipusatkan pada berkas *config.yaml*, antara lain: ukuran citra 224×224, *batch size* 16 dengan *gradient accumulation* 2 langkah (*batch* efektif 32), *learning*

rate awal 2×10^{-4} , *weight decay* 1×10^{-4} , maksimum 30 *epoch* dengan *early stopping* (*patience* 12), *label smoothing* 0,05, dan 3 *seed* untuk validitas statistik.

Seluruh tahap dijalankan melalui skrip terpadu *run_pipeline.py* yang memanggil secara berurutan: ekstraksi *frame* dan *cropping* wajah (*extract_frames.py*), pembangunan *split* dataset (*build_splits.py*), prakomputasi *cache* FFT (*compute_fft_cache.py*), pelatihan model (*train.py*), dan evaluasi (*eval.py*). *Mixed precision training* diaktifkan secara otomatis ketika perangkat CUDA tersedia.

3.8.4 Keluaran Sistem

Untuk setiap konfigurasi pelatihan, *checkpoint* dengan AUC validasi tertinggi disimpan sebagai *best.pt*. Hasil evaluasi akhir disimpan dalam bentuk tabel pada direktori *outputs/tables/*, yaitu *Table1_in_dataset.csv* (evaluasi *in-dataset*), *Table2_cross_dataset.csv* (evaluasi *cross-dataset*), dan *Table3_generalization_drop.csv* (penurunan generalisasi).

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil

Subbab Hasil harus menyesuaikan dengan judul / topik Skripsi / Tesis yang diangkat. Subbab Hasil dapat berupa temuan-temuan sebagai bentuk implementasi penyelesaian masalah atau hasil pengujian yang dilakukan sesuai dengan ruang lingkup yang telah ditentukan. Subbab Hasil dapat dipecah menjadi beberapa sub-sub bab sesuai dengan kebutuhan, sementara hasil tersebut harus dievaluasi / dikaji / didiskusikan untuk mengisi subbab Pembahasan.

4.2 Pembahasan

Subbab Pembahasan harus menyesuaikan dengan hasil pengujian dan dapat diuraikan dalam beberapa sub-sub bab sesuai kebutuhan. Pembahasan menjawab masalah yang diajukan pada Bab I.

BAB V

PENUTUP

Pada Program Sarjana (S-1), subbab Penutup dapat berisi Rangkuman atau dibagi dalam Kesimpulan dan Saran, sedangkan pada Program Magister (S-2), subbab Penutup dapat berisi Kesimpulan dan Saran.

Kesimpulan merupakan rangkuman yang diperoleh sebagai hasil akhir dari pelaksanaan penelitian. Kesimpulan harus rinci dan teliti sebagai inti sari dari hasil analisis, rancangan dan pengujian data / sistem / prototype model, dan / atau rencana strategi, temuan-temuan, interpretasi yang menjawab rumusan masalah. Sekurang-kurangnya setiap masalah penelitian menghasilkan satu temuan / jawaban. Kesimpulan adalah pernyataan mengenai generalisasi dari hasil penelitian. Dalam membuat kesimpulan, perlu diperhatikan bahwa hanya ada 1 (satu) kesimpulan untuk suatu hipotesis (jika penelitian yang dilakukan memperkenalkan hipotesis).

Saran ditujukan kepada teori / ilmu pengetahuan / dunia akademik, praktek / aplikasi terapan ke instansi / organisasi / objek penelitian untuk perumusan kebijakan lanjut, dan untuk penelitian lebih lengkap selanjutnya. Saran tidak boleh keluar dari topik penelitian dan harus rinci dan merupakan tindak lanjut yang dapat dilakukan untuk penelitian yang lebih jauh atau lebih dalam.

DAFTAR PUSTAKA

- [1] K. P. dan M. S., Deepfakes: a new threat to face recognition? Assesment and detection, 2019.
- [2] S. A. Andira dan M. E. Susila, (PDF) Overcoming Deepfake Porn Crimes In Indonesia, 2024.
- [3] J. A. Haq, Klasifikasi Cepat Model XceptionNet dan ResNet-50 Pada Video Deepfake Menggunakan Local Binary Pattern, 2021.
- [4] D. Afchar, V. Nozick dan J. Yamagishi, MesoNet: a Compact Facial Video Forgery Detection Network., 2018.
- [5] K. He, X. Zhang, S. Ren dan J. Sun, Deep Residual Learning for Image Recognition, Microsoft Research, 2015.
- [6] F. Chollet, Xception: Deep Learning with Depthwise Separable Convolutions, IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017.
- [7] A. Rössler, D. Cozzoliono, L. Verdoliva, C. Riess, J. Thies dan M. Nießner, FaceForensics++: Learning to Detect Manipulated Facial Images, 2019.
- [8] R. Durall, M. Keuper dan J. Keuper, Watch your Up-Convolution: CNN Based Generative Deep Neural Networks Failing to Reproduce Spectral Distributions, IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2020.
- [9] X. Zhang, S. Karaman dan S.-F. Chang, Detecting and Simulating Artifacts in GAN Fake Images, 2019.
- [10] O. Guidice, L. Guarnera dan S. Battiato, Fighting Deepfake by Detecting GAN DCT Anomalies.
- [11] Y. Qian, G. Yin, L. Sheng, Z. Chen dan J. Shao, Thinking in Frequency: Face Forgery Detection by Mining Frequency-aware Clues, AAAI Conference on Artificial Intelligence (AAAI), 2020.
- [12] C. Tan, Y. Zaho, S. Wei, G. Gu, P. Liu dan Y. Wei, Frequency-Aware Deepfake Detection: Improving Generalizability through Frequency Space Domain Learning, The Thirty-Eighth AAAI Conference on Artificial Intelligence (AAAI-24), 2024.

- [13 I. Alam, M. I. Tanvir dan S. S. Woo, SpecXNet: A Dual-Domain Convolutional
] Network for Robust Deepfake Detection, 2025.
- [14 M. S. Rana, M. N. Nobi, B. Murali dan A. H. Sung, Deepfake Detection: A Systematic
] Literature Review, IEEE Access, vol. 10, 2022.
- [15 J. Rao dan T. Uehara, A Chronological Review of Deepfake Detection: Techniques
] and Evolutions, Natural Language Processing, Information Retrieval and AI Trends,
2025.
- [16 A. A. Hasanaath, H. Luqman, R. Katib dan S. Anwar, FSBI: Deepfakes Deteciton with
] Frequency Enchanced Self-Blended Image, 2023.
- [17 X. Luo dan Y. Wang, Frequency-Domain Masking and Spatial Interaction for
] Generalizable Deepfake Detection, 2025.
- [18 Y. Li, X. Yang, P. Sun, Q. Honggang dan S. Lyu, Celeb-DF: A Large-scale
] Challenging Dataset for DeepFake Forensics, 2020.
- [19 A. Chadha, V. Kumar, S. Kashyap dan M. Gupta, Deepfake: An Overview,
] Proceedings of Second International Conference on Computing, Communications, and
Cyber-Security, 2021.
- [20 S. A. Aduwala, M. Arigala, S. Desai, H. J. Quan dan M. Eirinaki, Deepfake Detection
] using GAN Discriminators, IEEE Xplore, 2021.
- [21 A. Odena, V. Dumoulin dan C. Olah, Deconvolution and Checkerboard Artifacts,
] 2016.
- [22 Y. Dai, H. Lu dan C. Shen, Learning Affinity-Aware Upsampling for Deep Image
] Matting*, 2021.
- [23 T. Karras, T. Aila, S. Laine dan J. Lehtinen, Progressive Growing of GANs for
] Improved Quality, Stability, and Variation, 2018.
- [24 N. Mejri, K. Papadopoulus dan D. Aouada, Leveraging High-Frequency Components
] for Deepfake Detection, 2021.
- [25 T. Kim, J. Choi, Y. Jeong, H. Noh, J. Yoo, S. Baek dan J. Choi, Beyond Spatial
] Frequency: Pixel-wise Temporal Frequency-based Deepfake Video Detection, The
International Conference on Computer Vision (ICCV), 2025.

- [26 X. H. Nguyen, T. S. Tran, V. T. Le dan K. D. Nguyen, Learning Spatio-temporal
] features to detect manipulated facial videos created by the Deepfake techniques,
Forensic Science International: Digital Investigation 36, 2021.
- [27 D. Güera dan E. J. Delp, Deepfake Video Detection Using Recurrent Neural Networks,
] 15th IEEE International Conference on Advanced Video and Signal Based
Surveillance (AVSS), 2018.
- [28 R. C. Gonzalez dan R. E. Woods, Digital Image Processing, 2018.
]
- [29 A. V. Oppenheim, R. W. Schafer dan J. R. Buck, Discrete-Time Signal Processing,
] Prentice Hall, Inc., 1989.
- [30 W. Commons, “2D Fourier Transform and Base Images,” 2018. [Online]. Available:
] https://commons.wikimedia.org/wiki/File:2D_Fourier_Transform_and_Base_Images.png.
- [31 Stack Overflow, “What Does the Fourier Transform of an Image Show?,” [Online].
] Available: <https://stackoverflow.com/questions/4364823/what-does-the-fourier-transform-of-an-image-show>.
- [32 R. L. Easton Jr., Fundamentals of Digital Image Processing, 2010.
]
- [33 Y. LeCun, Y. Bengio dan G. Hinton, Deep Learning.
]
- [34 A. Haliassos, K. Vougioukas, S. Petridis dan M. Pantic, Lips Don’t Lie: A
] Generalisable and Robust Approach to Face Forgery Detection, 2021.
- [35 O. O. Akinrogunde, A. A. Adelakun, E. E. Theophilus dan T. G. Thomas, A systematic
] review of machine learning and deep learning approaches for load and energy
consumption prediction in contemporary power systems, Journal of Innovation
Materials, Energy, and Sustainable Engineering, 2025.
- [36 J. Hu, L. Shen dan G. Sun, Squeeze-and-Excitation Networks, IEEE/CVF Conference
] on Computer Vision and Pattern Recognition, 2018.
- [37 L. Ma, Z. Yan, Y. Chen, J. Xu, Q. Guo, H. Huang, Y. Liao dan H. Lin, From Specificity
] to Generality: Revisiting Generalizable Artifacts in Detecting Face Deepfakes, 2025.

- [38 E. Sabir, J. Cheng, A. Jaiswal, W. A. Almageed, I. Masi dan P. Natarajan, Recurrent
] Convolutional Strategies for Face Manipulation Detection in Videos, USC Information
Sciences Institute, Marina del Rey, CA, USA, 2019.
- [39 I. Goodfellow, Y. Bengio dan A. Courville, Deep Learning, MIT Press, 2016.
]
- [40 L. Bottou, Stochastic Gradient Descent Tricks, Montavon: Microsoft Research, 2012.
]
- [41 S. Ruder, An overview of gradient descent optimization algorithms, Insight Centre for
] Data Analytics, 2017.
- [42 D. P. Kingma dan J. Ba, Adam: A Method for Stochastic Optimization, 2017.
]
- [43 I. Loschilov dan F. Hutter, Decoupled Weight Decay Regularization, International
] Conference on Learning Representations, 2019.
- [44 K. Zhang, Z. Zhang, Z. Li dan Y. Qiao, Joint Face Detection and Alignment using
] Multi-task Cascaded Convolutional Networks, IEEE Signal Processing Letters, 2016.
- [45 H. Robbins dan S. Monro, A Stochastic Approximation Method, University of North
] Carolina, 1951.